Chương 2

Phương pháp luận

Chương này trình bày nền tảng toán học của bài toán dự báo chuỗi thời gian đa biến và cấu trúc của mô hình **DyTimeBase**. DyTimeBase giữ nguyên xương sống tuyến tính, độc lập kênh của TimeBase (rút một số ít *chuỗi cơ sở* từ các đoạn theo chu kỳ, rồi dự báo theo đoạn), và bổ sung một nhánh *trộn kênh* lấy từ DyTimeNet (khối CrossVBlock với chiến lược DropFusion và khối IntraVBlock). Điểm khác biệt cốt lõi là nhánh trộn kênh hoạt động trên *không gian cơ sở* gồm $P \cdot R$ số mỗi kênh, thay vì trên toàn bộ L điểm của chuỗi gốc.

2.1 Mô hình hóa toán học

2.1.1 Dữ liệu đầu vào

Xét một hệ thống quan sát gồm C biến số thay đổi theo thời gian. Một mẫu đầu vào là cửa sổ lịch sử độ dài L:

$$\mathcal{X}_{train} = \begin{bmatrix} x_1^{(1)} & x_1^{(2)} & \dots & x_1^{(C)} \\ \vdots & \vdots & \ddots & \vdots \\ x_L^{(1)} & x_L^{(2)} & \dots & x_L^{(C)} \end{bmatrix} \in \mathbb{R}^{L \times C}, \qquad \mathbf{x}^{(i)} = \left(x_1^{(i)}, \dots, x_L^{(i)}\right)^\top \in \mathbb{R}^L, \tag{2.1}$$

trong đó $x_t^{(i)}$ là giá trị của biến $X^{(i)}$ tại thời điểm t, đã được chuẩn hóa Z-score theo từng biến với trung bình và độ lệch chuẩn tính trên tập huấn luyện. Nhãn tương ứng là S bước tương lai:

$$\mathcal{X}_{test} = \begin{bmatrix} x_{L+1}^{(1)} & \dots & x_{L+1}^{(C)} \\ \vdots & \ddots & \vdots \\ x_{L+S}^{(1)} & \dots & x_{L+S}^{(C)} \end{bmatrix} \in \mathbb{R}^{S \times C}. \tag{2.2}$$

Ngoài L, S, C, mô hình dùng thêm các kích thước sau:

- P: độ dài đoạn, bằng chu kỳ tự nhiên của dữ liệu (ví dụ $P = 24$ với dữ liệu theo giờ có chu kỳ ngày).
- $N = \lceil L/P \rceil$ và $N' = \lceil S/P \rceil$: số đoạn của quá khứ và của tương lai.
- $R \ll N$: số chuỗi cơ sở (basis).
- D: số chiều ẩn của nhánh trộn kênh; $C' = \lfloor 0.75\, C \rfloor$: số chiều nút thắt của CrossVBlock; $D_{ff} = 2D$: số chiều ẩn của FFN trong IntraVBlock.

2.1.2 Đầu ra và Hàm mục tiêu

Mô hình $\mathcal{F}$ (với tập tham số Θ) nhận $\mathcal{X}_{train}$ và ước lượng đồng thời S bước tương lai của cả C biến:

$$\hat{\mathcal{X}} = \mathcal{F}(\mathcal{X}_{train}) \in \mathbb{R}^{S \times C}. \tag{2.3}$$

Sai số dự báo được đo bằng trung bình bình phương sai số:

$$\mathcal{L}_{MSE} = \frac{1}{S \times C} \sum_{t=1}^{S} \sum_{i=1}^{C} \left(x_{L+t}^{(i)} - \hat{x}_{L+t}^{(i)} \right)^2. \tag{2.4}$$

Khác với DyTimeNet, hàm mục tiêu khi huấn luyện DyTimeBase có thêm một số hạng điều chuẩn trực giao $\mathcal{L}_{orth}$ trên các chuỗi cơ sở. Số hạng này được định nghĩa ở mục 2.3.2, công thức (2.10):

$$\mathcal{L} = \mathcal{L}_{MSE} + \lambda_{orth}\, \mathcal{L}_{orth}, \tag{2.5}$$

trong đó $\lambda_{orth} \geq 0$ là siêu tham số. $\mathcal{L}_{orth}$ chỉ dùng khi huấn luyện; khi đánh giá, mô hình chỉ được đo bằng MSE và MAE.

2.2 Tổng quan kiến trúc của mô hình

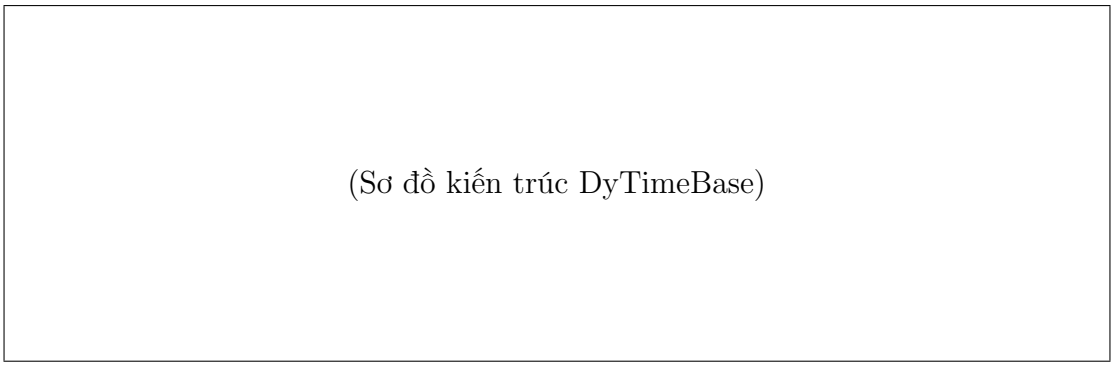
Hình 2.1 mô tả luồng dữ liệu của DyTimeBase. Mỗi mẫu đi qua các khối sau:

1. **Phân đoạn**: chuỗi độ dài L của mỗi kênh được cắt thành N đoạn dài P, xếp thành ma trận $P \times N$ (hàng là pha trong chu kỳ, cột là đoạn).
2. **Chuẩn hóa theo pha**: trừ trung bình của từng pha, tính trên N đoạn.
3. **Trích xuất cơ sở**: một ánh xạ tuyến tính $N \to R$ nén N đoạn thành R chuỗi cơ sở, cho ma trận $\mathbf{E}^{(i)} \in \mathbb{R}^{P \times R}$.
4. **Trộn kênh trong không gian cơ sở**, gồm bốn bước: mã hóa $P \cdot R \to D$, CrossVBlock (trộn C kênh với DropFusion), IntraVBlock (FFN theo từng kênh), và chiếu ngược $D \to P \cdot R$ (khởi tạo bằng 0) để ra phần hiệu chỉnh $\Delta\mathbf{E}^{(i)}$.
5. **Dự báo theo đoạn**: một ánh xạ tuyến tính $R \to N'$ trên $\mathbf{E}'^{(i)} = \mathbf{E}^{(i)} + \Delta\mathbf{E}^{(i)}$.
6. **Khôi phục và ghép**: cộng lại trung bình theo pha, trải N' đoạn thành chuỗi và lấy S bước đầu.

Mọi phép biến đổi theo trục thời gian đều chạy trên các kích thước N, R, P (cỡ vài chục) thay vì L, S (cỡ hàng trăm). Phần trộn kênh chạy trên vector D chiều của mỗi kênh. Vì vậy chi phí tính toán thấp hơn nhiều so với DyTimeNet (mục 2.3.6).

2.3 Xây dựng mô hình DyTimeBase

Các khối từ 2.3.1 đến 2.3.2 và khối 2.3.4 áp dụng *độc lập cho từng kênh* $i = 1, \ldots, C$. Chỉ khối 2.3.3 trao đổi thông tin giữa các kênh.



Hình 2.1: Overview Pipeline của mô hình DyTimeBase

2.3.1 Phân đoạn theo chu kỳ và Chuẩn hóa theo pha

a) Phân đoạn. Khi L không chia hết cho P, chuỗi được đệm thêm $\delta = NP - L$ giá trị ở đầu, lấy từ đoạn đầu tiên:

$$\bar{\mathbf{x}}^{(i)} = \left(x^{(i)}_{P-\delta+1}, \ldots, x^{(i)}_{P},\ x^{(i)}_{1}, \ldots, x^{(i)}_{L}\right)^{\top} \in \mathbb{R}^{NP} \tag{2.6}$$

($\delta = 0$ thì $\bar{\mathbf{x}}^{(i)} = \mathbf{x}^{(i)}$). Chuỗi sau đó được xếp thành ma trận đoạn $\mathbf{X}^{(i)} \in \mathbb{R}^{P\times N}$, mỗi cột là một đoạn dài P:

$$\left[\mathbf{X}^{(i)}\right]_{p,n} = \bar{x}^{(i)}_{(n-1)P+p}, \qquad p = 1, \ldots, P,\ n = 1, \ldots, N. \tag{2.7}$$

Hàng p của $\mathbf{X}^{(i)}$ gom các giá trị cùng pha p trong chu kỳ (ví dụ cùng giờ trong ngày) của N chu kỳ liên tiếp.

b) Chuẩn hóa theo pha (Period Normalization). Mỗi pha có mức trung bình riêng (ví dụ ban ngày phụ tải cao hơn ban đêm), nên mô hình trừ trung bình của từng pha:

$$\boldsymbol{\mu}^{(i)} = \frac{1}{N}\,\mathbf{X}^{(i)}\mathbf{1}_N \in \mathbb{R}^{P}, \qquad \tilde{\mathbf{X}}^{(i)} = \mathbf{X}^{(i)} - \boldsymbol{\mu}^{(i)}\mathbf{1}_N^{\top} \in \mathbb{R}^{P\times N}. \tag{2.8}$$

Tác dụng và ý nghĩa: Phép trừ này tách mẫu hình lặp lại trong một chu kỳ ra khỏi chuỗi, để các khối phía sau chỉ phải học phần dao động quanh mẫu hình đó. Bước này đóng vai trò tương tự RevIN trong DyTimeNet nhưng không chia cho độ lệch chuẩn. $\boldsymbol{\mu}^{(i)}$ được giữ lại để cộng trả ở bước cuối (2.23).

2.3.2 Khối Trích xuất cơ sở (Basis Extraction)

Một ánh xạ tuyến tính dùng chung cho mọi kênh nén N đoạn thành R chuỗi cơ sở:

$$\mathbf{E}^{(i)} = \tilde{\mathbf{X}}^{(i)}\mathbf{W}_B + \mathbf{1}_P\mathbf{b}_B^{\top} \in \mathbb{R}^{P\times R}, \qquad \mathbf{W}_B \in \mathbb{R}^{N\times R},\ \mathbf{b}_B \in \mathbb{R}^{R}. \tag{2.9}$$

Cột thứ r của $\mathbf{E}^{(i)}$ là $\sum_{n=1}^{N}[\mathbf{W}_B]_{n,r}\,\tilde{\mathbf{X}}^{(i)}_{:,n} + [\mathbf{b}_B]_r$, tức một tổ hợp tuyến tính của N đoạn quá khứ. Mỗi cột vì thế là một "đoạn đại diện" độ dài P, và cả cửa sổ L điểm được tóm tắt bằng R đoạn đại diện như vậy.

Ràng buộc trực giao. Để R chuỗi cơ sở mang thông tin khác nhau và không trùng lặp, mô hình phạt các tích vô hướng giữa hai chuỗi cơ sở khác nhau. Gọi $\mathbf{G}^{(i)} = \mathbf{E}^{(i)\top}\mathbf{E}^{(i)} \in \mathbb{R}^{R\times R}$ là ma trận Gram. Với một lô gồm B mẫu:

$$\mathcal{L}_{orth} = \frac{1}{B\,C}\sum_{b=1}^{B}\sum_{i=1}^{C}\left\|\mathbf{G}_b^{(i)} - \operatorname{diag}\left(\mathbf{G}_b^{(i)}\right)\right\|_F, \tag{2.10}$$

trong đó diag$(\cdot)$ giữ lại đường chéo và $\|\cdot\|_F$ là chuẩn Frobenius. Số hạng này đạt giá trị nhỏ nhất bằng 0 khi các cột của $\mathbf{E}^{(i)}$ đôi một trực giao.

2.3.3 Khối Trộn kênh trong không gian cơ sở

Các khối trước xử lý từng kênh riêng rẽ. Khối này cho các kênh trao đổi thông tin. Chỉ hai khối CrossVBlock (cùng DropFusion) và IntraVBlock được giữ nguyên từ DyTimeNet. Hai lớp bao quanh chúng là thiết kế mới của DyTimeBase:

- Lớp mã hóa $PR \to D$ thay cho phép chiếu thời gian $L \to D$ của DyTimeNet. Nó nhận các chuỗi cơ sở $\mathbf{E}^{(i)}$ ($P \cdot R$ số mỗi kênh) thay vì chuỗi gốc (L số mỗi kênh).
- Lớp chiếu ngược $D \to PR$, khởi tạo bằng 0, thay cho lớp chiếu ra $D \to S$ của DyTimeNet.

a) Làm phẳng và Mã hóa. Mỗi ma trận cơ sở được làm phẳng theo hàng, $\mathbf{e}^{(i)} = \mathrm{vec}(\mathbf{E}^{(i)}) \in \mathbb{R}^{PR}$ với $[\mathbf{e}^{(i)}]_{(p-1)R+r} = [\mathbf{E}^{(i)}]_{p,r}$. Các vector này được ghép thành $\bar{\mathbf{E}} = [\mathbf{e}^{(1)}, \ldots, \mathbf{e}^{(C)}] \in \mathbb{R}^{PR \times C}$ rồi chiếu xuống không gian ẩn D chiều. Phép biến đổi này cùng dạng với phép mã hóa thời gian $\mathcal{X}_{enc} = \mathbf{W}_{enc}^{\top}\mathcal{X}' + \mathbf{b}_{enc}$ của DyTimeNet (Đồ án I, công thức (2.6)), nhưng đầu vào là PR hệ số cơ sở thay cho L điểm:

$$\mathcal{X}_{enc} = \mathbf{W}_{enc}^{\top}\bar{\mathbf{E}} + \mathbf{b}_{enc}\mathbf{1}_C^{\top} \in \mathbb{R}^{D \times C}, \qquad \mathbf{W}_{enc} \in \mathbb{R}^{PR \times D},\ \mathbf{b}_{enc} \in \mathbb{R}^{D}. \tag{2.11}$$

b) Khối Liên biến CrossVBlock với DropFusion. Đầu tiên, $\mathcal{X}_{enc}$ được chuẩn hóa LayerNorm theo từng cột (từng kênh, trên D đặc trưng):

$$\mathcal{X}'_{enc} = \mathrm{LayerNorm}(\mathcal{X}_{enc}) \in \mathbb{R}^{D \times C}. \tag{2.12}$$

Tác dụng và ý nghĩa: LayerNorm đưa biểu diễn của mọi kênh về cùng thang đo, để phép trộn kênh phía sau không bị chi phối bởi các kênh có biên độ lớn.

Phép trộn kênh dùng hàm kích hoạt GELU:

$$\mathrm{GELU}(x) = x \cdot \Phi(x) = \frac{x}{2}\left(1 + \mathrm{erf}\left(\frac{x}{\sqrt{2}}\right)\right), \tag{2.13}$$

với $\Phi(x)$ là hàm phân phối tích lũy của phân phối chuẩn $\mathcal{N}(0,1)$.

Mỗi lớp tuyến tính trên trục kênh được thay bằng lớp DropFusion. Với đầu vào $\mathbf{Z} \in \mathbb{R}^{D \times C_{in}}$ và tham số $\mathbf{W}_{df} \in \mathbb{R}^{C_{in} \times C_{out}}$, $\mathbf{b}_{df} \in \mathbb{R}^{C_{out}}$, đầu tiên mặt nạ cạnh được áp lên ma trận trọng số:

$$\mathbf{W}_{masked} = \mathbf{W}_{df} \odot \mathcal{M}_1, \tag{2.14}$$

sau đó mặt nạ nút được áp lên đầu ra, kèm các hệ số bù năng lượng:

$$\mathrm{DF}(\mathbf{Z}; \mathbf{W}_{df}, \mathbf{b}_{df}) = \frac{1}{1-p_2}\left[\frac{\mathbf{Z}\,\mathbf{W}_{masked}}{1-p_1} + \mathbf{1}_D\mathbf{b}_{df}^{\top}\right] \odot \mathcal{M}_2, \tag{2.15}$$

trong đó:

- $\mathcal{M}_1 \in \{0,1\}^{C_{in} \times C_{out}}$ là *mặt nạ cạnh*. Mỗi phần tử bằng 0 với xác suất p_1, tức là cắt liên kết giữa một cặp kênh. Mặt nạ được lấy mẫu lại ở mỗi lô.
- $\mathcal{M}_2 \in \{0,1\}^{D \times C_{out}}$ là *mặt nạ nơ-ron*. Mỗi phần tử bằng 0 với xác suất p_2, tức là tắt đầu ra. Mặt nạ được lấy mẫu lại ở mỗi mẫu.

- Các hệ số $\frac{1}{1-p_1}$ và $\frac{1}{1-p_2}$ giữ cho kỳ vọng của tín hiệu không đổi giữa lúc huấn luyện và lúc kiểm thử.

Khi kiểm thử, $\mathcal{M}_1 = \mathcal{M}_2 = \mathbf{1}$, không nhân hệ số bù, và lớp trở thành $\mathrm{DF}(\mathbf{Z}) = \mathbf{Z}\mathbf{W}_{df} + \mathbf{1}_D\mathbf{b}_{df}^\top$.

CrossVBlock gồm hai lớp DropFusion theo cấu trúc nút thắt $C \to C' \to C$ (tham số $\mathbf{W}_{df,1} \in \mathbb{R}^{C\times C'}$, $\mathbf{W}_{df,2} \in \mathbb{R}^{C'\times C}$), xen giữa là GELU:

$$\mathcal{X}_{cross} = \mathrm{DF}\Big(\,\mathrm{GELU}\big(\mathrm{DF}(\mathcal{X}'_{enc}; \mathbf{W}_{df,1}, \mathbf{b}_{df,1})\big); \mathbf{W}_{df,2}, \mathbf{b}_{df,2}\Big) \in \mathbb{R}^{D\times C}. \tag{2.16}$$

Mỗi hàng của $\mathcal{X}'_{enc}$ là một đặc trưng (trong D đặc trưng) của cả C kênh. Phép nhân phải với $\mathbf{W}_{df,1}$, $\mathbf{W}_{df,2}$ trộn thông tin *giữa các kênh* trên từng đặc trưng đó.

c) Khối Nội biến IntraVBlock. Như DyTimeNet, một kết nối thặng dư cộng đặc trưng chéo với đặc trưng đã chuẩn hóa, để thông tin gốc của từng kênh không bị mất:

$$\mathcal{X}_{intra} = \mathcal{X}_{cross} + \mathcal{X}'_{enc} \in \mathbb{R}^{D\times C}. \tag{2.17}$$

Sau đó một mạng FFN hai lớp dùng chung được quét dọc theo từng kênh (từng cột), có LayerNorm phía trước và kết nối thặng dư:

$$\mathrm{FFN}(\mathbf{Z}) = \Big(\,\mathrm{Drop}\big(\,\mathrm{GELU}(\mathbf{Z}^\top\mathbf{W}_1 + \mathbf{1}_C\mathbf{b}_1^\top)\big)\mathbf{W}_2 + \mathbf{1}_C\mathbf{b}_2^\top\Big)^\top \in \mathbb{R}^{D\times C}, \tag{2.18}$$

$$\hat{\mathcal{X}}_{intra} = \mathcal{X}_{intra} + \mathrm{Drop}\Big(\,\mathrm{FFN}\big(\,\mathrm{LayerNorm}(\mathcal{X}_{intra})\big)\Big) \in \mathbb{R}^{D\times C}, \tag{2.19}$$

trong đó $\mathbf{W}_1 \in \mathbb{R}^{D\times D_{ff}}$, $\mathbf{W}_2 \in \mathbb{R}^{D_{ff}\times D}$, và Drop là Dropout thông thường với tỉ lệ p_{drop}. Phép chuyển vị $\mathbf{Z}^\top \in \mathbb{R}^{C\times D}$ đặt mỗi kênh thành một hàng, nên $\mathbf{W}_1$, $\mathbf{W}_2$ chỉ biến đổi trên D đặc trưng của từng kênh, không trộn các kênh.

d) Chiếu ngược và Hiệu chỉnh cơ sở. Biểu diễn ẩn được chiếu trở lại không gian cơ sở:

$$\Delta\bar{\mathbf{E}} = \mathbf{W}_{out}^\top\hat{\mathcal{X}}_{intra} + \mathbf{b}_{out}\mathbf{1}_C^\top \in \mathbb{R}^{PR\times C}, \qquad \mathbf{W}_{out} \in \mathbb{R}^{D\times PR}. \tag{2.20}$$

Cột thứ i được xếp lại thành $\Delta\mathbf{E}^{(i)} \in \mathbb{R}^{P\times R}$ (phép ngược của vec), rồi cộng vào cơ sở ban đầu:

$$\mathbf{E}'^{(i)} = \mathbf{E}^{(i)} + \Delta\mathbf{E}^{(i)}. \tag{2.21}$$

Tác dụng và ý nghĩa: $\mathbf{W}_{out}$ và $\mathbf{b}_{out}$ được khởi tạo bằng 0, nên ở thời điểm khởi tạo $\Delta\mathbf{E}^{(i)} = \mathbf{0}$ và DyTimeBase trùng khớp với TimeBase. Trong quá trình huấn luyện, nhánh trộn kênh chỉ thêm vào phần hiệu chỉnh nào giúp giảm sai số. Nhờ vậy mô hình không bắt đầu từ một mức tệ hơn xương sống độc lập kênh.

2.3.4 Khối Dự báo theo đoạn và Khôi phục thang đo

a) Dự báo theo đoạn. Một ánh xạ tuyến tính dùng chung sinh ra N' đoạn tương lai từ R chuỗi cơ sở đã hiệu chỉnh:

$$\hat{\mathbf{Y}}^{(i)} = \mathbf{E}'^{(i)}\mathbf{W}_F + \mathbf{1}_P\mathbf{b}_F^\top \in \mathbb{R}^{P\times N'}, \qquad \mathbf{W}_F \in \mathbb{R}^{R\times N'},\ \mathbf{b}_F \in \mathbb{R}^{N'}. \tag{2.22}$$

b) Khôi phục thang đo. Trung bình theo pha ở (2.8) được cộng trả lại cho mọi đoạn tương lai:

$$\hat{\mathbf{Y}}'^{(i)} = \hat{\mathbf{Y}}^{(i)} + \boldsymbol{\mu}^{(i)}\mathbf{1}_{N'}^\top. \tag{2.23}$$

c) Ghép đoạn. Các cột được nối tiếp nhau thành chuỗi, và mô hình giữ lại S bước đầu:

$$\hat{x}_{L+t}^{(i)} = \big[\hat{\mathbf{Y}}'^{(i)}\big]_{p,n} \quad \text{với } t = (n-1)P + p,\ t = 1,\dots,S, \qquad \hat{\mathcal{X}} = \big[\hat{x}_{L+t}^{(i)}\big]_{t,i} \in \mathbb{R}^{S\times C}. \tag{2.24}$$

2.3.5 Huấn luyện mô hình

Tham số được chia thành hai nhóm:

- Xương sống $\Theta_B = \{\mathbf{W}_B, \mathbf{b}_B, \mathbf{W}_F, \mathbf{b}_F\}$.
- Nhánh trộn kênh Θ_M: các tham số của (2.11)–(2.20), gồm cả tham số của các lớp LayerNorm.

Cả hai nhóm được tối ưu đồng thời theo hàm mục tiêu (2.5) bằng thuật toán Adam. Mỗi nhóm có một tốc độ học riêng: α_B cho xương sống và α_M cho nhánh trộn kênh. Với $\mathbf{g}_k = \nabla_\theta \mathcal{L}$ tại bước k:

$$\mathbf{m}_k = \beta_1 \mathbf{m}_{k-1} + (1-\beta_1)\mathbf{g}_k, \quad \mathbf{v}_k = \beta_2 \mathbf{v}_{k-1} + (1-\beta_2)\mathbf{g}_k^2, \quad \theta_{k+1} = \theta_k - \alpha \, \frac{\mathbf{m}_k/(1-\beta_1^k)}{\sqrt{\mathbf{v}_k/(1-\beta_2^k)} + \epsilon}, \tag{2.25}$$

trong đó $\alpha = \alpha_B$ nếu $\theta \in \Theta_B$ và $\alpha = \alpha_M$ nếu $\theta \in \Theta_M$.

Tốc độ học giữ nguyên trong 4 epoch đầu, sau đó giảm theo cấp số nhân với hệ số 0.8 mỗi epoch. Lịch này áp dụng cho cả hai nhóm:

$$\alpha^{(e)} = \begin{cases} \alpha, & e \le 4, \\ \alpha \cdot 0.8^{\,e-4}, & e > 4, \end{cases} \qquad e = 1, 2, \ldots \tag{2.26}$$

Huấn luyện chạy tối đa 30 epoch và dừng sớm nếu MSE trên tập Validation không giảm sau 5 epoch liên tiếp. Trọng số có MSE Validation thấp nhất được dùng để đánh giá trên tập Test.

2.3.6 Độ phức tạp tính toán

Số phép nhân–cộng (MACs) cho một mẫu là tổng của hai phần.

Xương sống, gồm (2.9) và (2.22):

$$\mathrm{MACs}_B = C\,P\,R\,(N + N'). \tag{2.27}$$

Nhánh trộn kênh, gồm mã hóa và chiếu ngược, CrossVBlock và IntraVBlock:

$$\mathrm{MACs}_M = \underbrace{2\,C\,P\,R\,D}_{\text{mã hóa, chiếu ngược}} + \underbrace{2\,D\,C\,C'}_{\text{CrossVBlock}} + \underbrace{2\,C\,D\,D_{ff}}_{\text{IntraVBlock}}. \tag{2.28}$$

Ví dụ với $C = 321$, $L = S = 720$, $P = 24$ ($N = N' = 30$), $R = 6$, $D = 64$, $C' = 240$, $D_{ff} = 128$:

- Xương sống: $\mathrm{MACs}_B \approx 2.8\mathrm{M}$.
- Nhánh trộn kênh: $\mathrm{MACs}_M \approx 5.9\mathrm{M} + 9.9\mathrm{M} + 5.3\mathrm{M}$.
- Tổng cộng: khoảng 23.8M MACs.

Để so sánh, DLinear cần $2CLS \approx 333\mathrm{M}$ MACs.

Bảng 2.1: Kích thước dữ liệu qua từng khối của DyTimeBase (một mẫu)

Khối	Phép biến đổi	Đầu ra	Công thức
Input	–	$\mathcal{X}_{train} \in \mathbb{R}^{L \times C}$	(2.1)
Phân đoạn	đệm, xếp $P \times N$	$\mathbf{X}^{(i)} \in \mathbb{R}^{P \times N}$	(2.6), (2.7)
Chuẩn hóa theo pha	trừ $\boldsymbol{\mu}^{(i)}$	$\tilde{\mathbf{X}}^{(i)} \in \mathbb{R}^{P \times N}$	(2.8)
Trích xuất cơ sở	Linear $N \to R$	$\mathbf{E}^{(i)} \in \mathbb{R}^{P \times R}$	(2.9), (2.10)
Mã hóa	Linear $PR \to D$	$\mathcal{X}_{enc} \in \mathbb{R}^{D \times C}$	(2.11)
CrossVBlock	LN, DF $C \to C' \to C$	$\mathcal{X}_{cross} \in \mathbb{R}^{D \times C}$	(2.12)–(2.16)
IntraVBlock	thặng dư, LN, FFN $D \to 2D \to D$	$\hat{\mathcal{X}}_{intra} \in \mathbb{R}^{D \times C}$	(2.17)–(2.19)
Chiếu ngược	Linear $D \to PR$ (khởi tạo 0)	$\mathbf{E}'^{(i)} \in \mathbb{R}^{P \times R}$	(2.20), (2.21)
Dự báo theo đoạn	Linear $R \to N'$	$\hat{\mathbf{Y}}^{(i)} \in \mathbb{R}^{P \times N'}$	(2.22)
Khôi phục, ghép	cộng $\boldsymbol{\mu}^{(i)}$, trải phẳng	$\hat{\mathcal{X}} \in \mathbb{R}^{S \times C}$	(2.23), (2.24)

2.3.7 Tóm tắt luồng dữ liệu

2.3.8 Các biến thể

- **Tham số riêng từng kênh** (*individual*): thay $\mathbf{W}_B$, $\mathbf{b}_B$, $\mathbf{W}_F$, $\mathbf{b}_F$ bằng $\mathbf{W}_B^{(i)}$, $\mathbf{b}_B^{(i)}$, $\mathbf{W}_F^{(i)}$, $\mathbf{b}_F^{(i)}$ cho từng kênh i. Số MACs không đổi, chỉ số tham số của xương sống tăng C lần. Biến thể này dùng cho bộ dữ liệu Weather.

- **Chuẩn hóa toàn cửa sổ**: thay $\boldsymbol{\mu}^{(i)}$ trong (2.8) bằng một trung bình vô hướng $\mu^{(i)} = \frac{1}{NP}\mathbf{1}_P^\top \mathbf{X}^{(i)} \mathbf{1}_N$.

- **Bỏ nhánh trộn kênh**: bỏ các bước từ (2.11) đến (2.21), tức $\mathbf{E}'^{(i)} = \mathbf{E}^{(i)}$. Khi đó mô hình đúng bằng TimeBase.

Chương 3

Thực nghiệm và kết quả

Chương này đánh giá DyTimeBase trên 5 bộ dữ liệu chuẩn ở cả hai mặt: độ chính xác dự báo và chi phí tính toán. Các thực nghiệm trả lời bốn câu hỏi:

1. DyTimeBase chính xác hơn hay kém hơn các mô hình hiện đại ở những bộ dữ liệu nào?
2. So với xương sống TimeBase trong cùng một quy trình huấn luyện, nhánh trộn kênh có cải thiện kết quả không?
3. DyTimeBase nhanh và nhẹ đến mức nào so với các mô hình khác khi chạy trên cùng một thiết bị?
4. Từng khối của nhánh trộn kênh (CrossVBlock, IntraVBlock) đóng góp bao nhiêu?

3.1 Mô tả dữ liệu thực nghiệm

Thực nghiệm dùng lại 5 bộ dữ liệu của Đồ án I: ETTh1, ETTh2, ETTm1, ETTm2 (nhiệt độ dầu và phụ tải máy biến áp, 7 biến) và Weather (21 chỉ số khí tượng). Đặc điểm chi tiết của từng bộ đã được mô tả ở Chương 3 của Đồ án I. Bảng 3.1 tóm tắt kích thước dữ liệu và số cửa sổ mẫu khi độ dài đầu vào là $L = 720$.

Bảng 3.1: Thống kê các bộ dữ liệu. Số cửa sổ tính với $L = 720$, $S = 96$ (huấn luyện / kiểm định / kiểm thử).

Dataset	Số biến C	Tần suất	Số bước dùng	Chia Train/Val/Test	Số cửa sổ
ETTh1, ETTh2	7	1 giờ	14 400	12/4/4 tháng	7 825 / 2 785 / 2 785
ETTm1, ETTm2	7	15 phút	57 600	12/4/4 tháng	33 745 / 11 425 / 11 425
Weather	21	10 phút	52 696	7 : 1 : 2	36 072 / 5 174 / 10 445

3.2 Thiết lập thực nghiệm

3.2.1 Tiền xử lý dữ liệu

Quy trình tiền xử lý giống Đồ án I, chỉ khác độ dài đầu vào:

- **Chuẩn hóa Z-score** theo từng biến, với trung bình và độ lệch chuẩn chỉ tính trên tập huấn luyện rồi dùng lại cho tập kiểm định và kiểm thử.

- **Cửa sổ trượt**: mỗi mẫu gồm $L = 720$ bước quá khứ và $S \in \{96, 192, 336, 720\}$ bước tương lai. Độ dài $L = 720$ được chọn để trùng với thiết lập của TimeBase [1], nhờ đó số liệu của các mô hình so sánh lấy từ [1] có cùng điều kiện đầu vào.
- **Chia dữ liệu theo thời gian**: tập kiểm định và kiểm thử được lấy thêm L bước phía trước làm đầu vào, nhưng toàn bộ nhãn dự báo nằm trong đúng tập tương ứng. Khi đánh giá, mọi cửa sổ của tập kiểm thử đều được dùng (không bỏ lô cuối).

3.2.2 Siêu tham số và quá trình huấn luyện

Siêu tham số của DyTimeBase gồm hai nhóm (Bảng 3.2):

- **Xương sống** (P, R, tốc độ học α_B, kích thước lô, λ_{orth}, tham số riêng từng kênh): lấy nguyên theo script chính thức của TimeBase cho từng bộ dữ liệu và từng độ dài dự báo.
- **Nhánh trộn kênh** (D, p_1, p_2): giữ nguyên bộ siêu tham số đã tối ưu bằng Grid Search cho DyTimeNet trong Đồ án I (Bảng 3.1). DyTimeBase *không* được tinh chỉnh thêm.

Bảng 3.2: Siêu tham số của DyTimeBase. Xương sống: theo script chính thức của TimeBase [1] cho từng độ dài dự báo $S \in \{96, 192, 336, 720\}$. Nhánh trộn kênh: giữ nguyên bộ đã tối ưu của DyTimeNet (Đồ án I, Bảng 3.1).

	Xương sống (theo $S = 96/192/336/720$)						Nhánh trộn kênh	
Dataset	P	R	α_B	Batch	λ_{orth}	Riêng kênh	D	p_1 / p_2
ETTh1	24/24/24/24	6/6/6/6	0.1/0.4/0.4/0.05	64/256/256/64	0.16/0.16/0.08/0.12	không	64	0.1 / 0.1
ETTh2	24/24/24/24	6/4/6/6	0.2/0.06/0.4/0.4	512/512/64/64	0.2/0.08/0.12/0.12	không	64	0.6 / 0.6
ETTm1	4/4/4/6	18/20/20/20	0.02/0.02/0.02/0.01	512/256/256/128	0.04/0.04/0.08/0.12	không	64	0.1 / 0.2
ETTm2	4/4/4/6	20/20/20/20	0.01/0.01/0.01/0.01	64/64/64/64	0.04/0.04/0.04/0.04	không	32	0.1 / 0.1
Weather	4/4/4/4	6/6/6/6	0.02/0.02/0.05/0.05	512/512/512/512	0.04/0.04/0.08/0.04	có	64	0.1 / 0.1

Các thiết lập chung cho mọi bộ dữ liệu:

- Hàm mục tiêu $\mathcal{L} = \mathcal{L}_{MSE} + \lambda_{orth}\mathcal{L}_{orth}$ (2.5), tối ưu bằng Adam không dùng weight decay và không cắt gradient.
- Tốc độ học của nhánh trộn kênh $\alpha_M = 5 \cdot 10^{-4}$ (bằng tốc độ học của DyTimeNet trong Đồ án I); lịch tốc độ học theo (2.26) áp dụng cho cả hai nhóm tham số.
- $C' = \lfloor 0.75\, C \rfloor$, $D_{ff} = 2D$, Dropout trong IntraVBlock $p_{drop} = 0.1$.
- Tối đa 30 epoch, dừng sớm khi MSE trên tập kiểm định không giảm sau 5 epoch; trọng số có MSE kiểm định thấp nhất được dùng để đánh giá trên tập kiểm thử.
- Mỗi cấu hình chạy với 3 seed (2021, 2022, 2023); kết quả báo cáo là trung bình của 3 lần chạy.

3.2.3 Các mô hình so sánh

DyTimeBase được so sánh với 11 mô hình, chia làm hai nhóm:

- **TimeBase***: TimeBase [1] cài đặt lại theo mã nguồn chính thức và chạy trong *cùng quy trình* với DyTimeBase (cùng dữ liệu, cùng siêu tham số xương sống, cùng 3 seed). Với cùng trọng số, đầu ra của bản cài đặt lại lệch so với mã nguồn chính thức không quá $3 \cdot 10^{-7}$. Đây là phép so sánh công bằng nhất, vì hai mô hình chỉ khác nhau đúng ở nhánh trộn kênh.
- **Số liệu công bố**: TimeBase†, SparseTSF [4], TimeMixer [5], FITS [6], iTransformer [7], DLinear [8], PatchTST [9], TimesNet [10], FEDformer [11], Autoformer [12] và Informer [13]. Kết quả lấy từ Table 10 của [1], nơi mọi mô hình được chạy với cùng $L = 720$ và cùng cách chia dữ liệu. Các mô hình Transformer cỡ lớn không được huấn luyện lại vì chi phí trên CPU quá cao (ví dụ, một epoch của PatchTST ở cấu hình Electricity mất khoảng 23 giờ, Bảng 3.7).

3.2.4 Môi trường thực nghiệm

Toàn bộ huấn luyện và đo đạc chạy trên một máy tính xách tay không có GPU: CPU AMD Ryzen 7 7840HS (8 nhân), 16 GB RAM (15.2 GB khả dụng), Windows 11, Python 3.13, PyTorch 2.6.0 (bản CPU).

3.3 Các chỉ số đánh giá

3.3.1 Chỉ số độ chính xác

Độ chính xác được đo bằng MSE và MAE như các công thức (3.1), (3.2) của Đồ án I:

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2, \qquad \mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \tag{3.1}$$

trong đó tổng lấy trên mọi cửa sổ kiểm thử, mọi bước dự báo và mọi biến. Sai số được tính trên thang đã chuẩn hóa Z-score, theo quy ước của các nghiên cứu được so sánh.

3.3.2 Chỉ số hiệu năng

Theo [1], hiệu năng được đo bằng năm chỉ số trên cấu hình Electricity ($C = 321$, $L = S = 720$):

- **Params**: số tham số huấn luyện được.
- **MACs**: số phép nhân–cộng để dự báo một mẫu.
- **Max Mem**: bộ nhớ đỉnh khi huấn luyện với lô 12 mẫu. Vì thiết bị không có GPU, đây là bộ nhớ RAM của tiến trình, không phải bộ nhớ GPU như trong [1].
- **Epoch Time**: thời gian một epoch huấn luyện, tính bằng thời gian một bước (đo thực tế) nhân với số bước của một epoch.
- **Infer Time**: thời gian dự báo một mẫu trên CPU.

Mỗi mô hình được đo trong một tiến trình riêng, với dữ liệu ngẫu nhiên cùng kích thước (tốc độ không phụ thuộc giá trị dữ liệu). Các mô hình so sánh được dựng từ mã nguồn chính thức: Time-Series-Library [3] với cấu hình script chính thức, PatchTST theo kho mã của [9], FITS theo kho mã của [6].

3.4 Kết quả thực nghiệm

3.4.1 So sánh độ chính xác

Bảng 3.3 và Bảng 3.4 trình bày MSE và MAE của 13 mô hình trên 5 bộ dữ liệu.

Xét MSE trung bình trên 4 độ dài dự báo:

- Trên **ETTm1**, DyTimeBase đạt MSE thấp nhất trong cả 13 mô hình (0.351), tốt hơn PatchTST (0.355) và số công bố của TimeBase (0.356).
- Trên **ETTh1** và **Weather**, DyTimeBase đứng thứ hai (0.403 và 0.221), chỉ sau số công bố của TimeBase (0.396 và 0.219), và tốt hơn PatchTST, SparseTSF, FITS cùng mọi mô hình Transformer.
- Trên **ETTh2** và **ETTm2**, DyTimeBase (0.358 và 0.263) kém nhóm mô hình tuyến tính mạnh (FITS, SparseTSF, TimeBase) và PatchTST.

Bảng 3.5 đếm số lần DyTimeBase thắng từng mô hình trên 20 cặp (bộ dữ liệu, độ dài dự báo). DyTimeBase thắng toàn bộ 20/20 trước TimeMixer, iTransformer, TimesNet, FEDformer, Autoformer và Informer, và thắng DLinear 17/20. Với nhóm mô hình mạnh nhất (SparseTSF, FITS, PatchTST), DyTimeBase ở mức ngang ngửa: thắng trên ETTh1, ETTm1, Weather và thua trên ETTh2, ETTm2. DyTimeBase vẫn kém số liệu công bố của TimeBase (thắng 5/20).

Bảng 3.5: DyTimeBase đối đầu từng mô hình theo MSE: số ô thắng / hòa / thua trên 20 ô (5 dataset × 4 độ dài dự báo, làm tròn 3 chữ số) và các dataset DyTimeBase có MSE trung bình tốt hơn hoặc kém hơn.

Mô hình	Thắng	Hòa	Thua	DyTimeBase tốt hơn	DyTimeBase kém hơn
TimeBase*	12	1	7	ETTh1, ETTh2, ETTm1	ETTm2, Weather
TimeBase†	5	1	14	ETTm1	ETTh1, ETTh2, ETTm2, Weather
SparseTSF	12	1	7	ETTh1, ETTm1, Weather	ETTh2, ETTm2
TimeMixer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
FITS	11	0	9	ETTh1, ETTm1, Weather	ETTh2, ETTm2
iTransformer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
DLinear	17	0	3	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
PatchTST	9	1	10	ETTh1, ETTm1, Weather	ETTh2, ETTm2
TimesNet	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
FEDformer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
Autoformer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
Informer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–

3.4.2 So sánh với TimeBase trong cùng quy trình

Số liệu công bố của TimeBase được chạy một lần, trong khi DyTimeBase là trung bình 3 seed. Bản TimeBase* chạy lại trong cùng quy trình cho kết quả kém hơn số công bố trên ETTh1, ETTh2 và ETTm1 (ví dụ 0.411 so với 0.396 trên ETTh1), nên so sánh

Bảng 3.3: Kết quả dự báo dài hạn (MSE), độ dài đầu vào $L = 720$ cho mọi mô hình. DyTimeBase và TimeBase*: tự chạy, trung bình 3 seed. Các cột còn lại (TimeBase† là số công bố): trích từ Table 10 của [1]. **Đậm**: tốt nhất; gạch chân: thứ hai.

Dataset	S	**DyTimeBase**	TimeBase*	TimeBase†	SparseTSF	TimeMixer	FITS	iTransformer	DLinear	PatchTST	TimesNet	FEDformer	Autoformer	Informer
ETTh1	96	**0.347**	0.358	0.349	0.362	0.410	0.380	0.389	0.378	0.377	0.437	0.485	0.555	1.269
	192	0.388	0.396	**0.387**	0.404	0.448	0.415	0.424	0.415	0.413	0.456	0.481	0.599	1.487
	336	0.420	0.423	**0.408**	0.435	0.482	0.439	0.456	0.449	0.436	0.494	0.522	0.853	1.544
	720	0.456	0.466	0.439	**0.426**	0.475	0.433	0.545	0.507	0.455	0.632	0.604	0.899	1.481
	TB	0.403	0.411	**0.396**	0.407	0.454	0.417	0.454	0.437	0.420	0.505	0.523	0.727	1.445
ETTh2	96	0.286	0.295	0.292	0.294	0.315	**0.271**	0.305	0.294	0.276	0.349	0.401	0.541	5.189
	192	0.347	0.352	0.339	0.340	0.383	**0.332**	0.405	0.412	0.342	0.500	0.425	1.207	6.514
	336	0.378	0.390	0.358	0.360	0.385	**0.355**	0.411	0.471	0.364	0.445	0.427	0.825	5.284
	720	0.421	0.413	0.400	0.383	0.432	**0.378**	0.448	0.740	0.395	0.438	0.462	1.772	4.955
	TB	0.358	0.363	0.347	0.344	0.379	**0.334**	0.392	0.479	0.344	0.433	0.429	1.086	5.486
ETTm1	96	**0.296**	0.318	0.311	0.314	0.332	0.313	0.315	0.314	0.298	0.359	0.406	0.455	0.632
	192	**0.328**	0.363	0.338	0.348	0.355	0.339	0.349	0.347	0.335	0.368	0.450	0.562	1.131
	336	**0.364**	0.372	**0.364**	0.368	0.386	0.367	0.381	0.367	0.366	0.429	0.436	0.737	1.391
	720	0.416	0.418	**0.413**	0.419	0.452	0.417	0.437	0.415	0.420	0.477	0.462	0.503	1.397
	TB	**0.351**	0.367	0.356	0.362	0.381	0.359	0.370	0.361	0.355	0.408	0.439	0.564	1.138
ETTm2	96	0.167	0.166	**0.162**	0.167	0.192	0.166	0.179	0.163	0.165	0.200	0.339	0.325	1.870
	192	0.237	**0.218**	**0.218**	0.219	0.253	**0.218**	0.239	0.223	0.219	0.274	0.397	0.369	2.807
	336	0.284	0.277	0.270	0.271	0.307	0.271	0.309	0.291	**0.268**	0.340	0.449	0.418	4.442
	720	0.366	0.355	**0.352**	0.353	0.380	**0.352**	0.387	0.407	**0.352**	0.384	0.451	0.612	5.258
	TB	0.263	0.254	**0.251**	0.253	0.283	0.252	0.278	0.271	**0.251**	0.299	0.409	0.431	3.594
Weather	96	**0.143**	0.144	0.146	0.174	0.163	0.176	0.159	0.174	0.149	0.176	0.289	0.323	0.283
	192	0.187	0.187	**0.185**	0.216	0.201	0.216	0.203	0.215	0.193	0.219	0.340	0.389	0.445
	336	0.240	0.238	**0.236**	0.260	0.258	0.261	0.253	0.262	0.240	0.277	0.370	0.497	0.587
	720	0.314	**0.309**	**0.309**	0.325	0.329	0.325	0.317	0.319	0.312	0.344	0.420	0.573	0.953
	TB	0.221	**0.219**	**0.219**	0.244	0.238	0.244	0.233	0.242	0.224	0.254	0.355	0.446	0.567

Bảng 3.4: Kết quả dự báo dài hạn (MAE), độ dài đầu vào $L = 720$ cho mọi mô hình. DyTimeBase và TimeBase*: tự chạy, trung bình 3 seed. Các cột còn lại (TimeBase† là số công bố): trích từ Table 10 của [1]. **Đậm**: tốt nhất; gạch chân: thứ hai.

Dataset	S	**DyTimeBase**	TimeBase*	TimeBase†	SparseTSF	TimeMixer	FITS	iTransformer	DLinear	PatchTST	TimesNet	FEDformer	Autoformer	Informer
	96	0.386	**0.384**	**0.384**	0.389	0.441	0.402	0.421	0.402	0.408	0.454	0.500	0.558	0.855
	192	**0.408**	0.410	0.410	0.412	0.465	0.424	0.446	0.425	0.431	0.469	0.498	0.575	0.943
ETTh1	336	0.428	0.421	**0.418**	0.428	0.490	0.439	0.469	0.449	0.446	0.494	0.521	0.702	0.945
	720	0.461	0.466	**0.446**	0.448	0.500	0.457	0.532	0.517	0.475	0.578	0.575	0.730	0.975
	TB	0.421	0.420	**0.414**	0.419	0.474	0.430	0.467	0.448	0.440	0.499	0.523	0.641	0.929
	96	0.344	0.354	0.345	0.346	0.380	**0.336**	0.361	0.360	0.339	0.403	0.451	0.559	1.812
	192	0.388	0.393	0.387	0.377	0.415	**0.374**	0.421	0.437	0.385	0.488	0.464	0.866	2.011
ETTh2	336	0.431	0.435	0.410	0.398	0.438	**0.396**	0.436	0.478	0.405	0.465	0.471	0.719	1.859
	720	0.462	0.460	0.448	0.425	0.471	**0.423**	0.470	0.609	0.434	0.465	0.493	1.062	1.884
	TB	0.406	0.410	0.397	0.387	0.426	**0.382**	0.422	0.471	0.391	0.455	0.470	0.801	1.891
	96	0.352	0.361	0.351	0.359	0.384	0.357	0.369	**0.350**	0.352	0.391	0.441	0.464	0.574
	192	0.371	0.393	0.371	0.376	0.398	**0.369**	0.388	0.381	0.373	0.398	0.477	0.514	0.802
ETTm1	336	0.394	0.394	0.386	0.386	0.416	**0.385**	0.409	0.387	0.394	0.438	0.466	0.608	0.923
	720	0.428	0.418	0.414	**0.413**	0.457	0.417	0.439	0.415	0.421	0.474	0.479	0.502	0.973
	TB	0.386	0.391	**0.381**	0.384	0.414	0.382	0.401	0.383	0.385	0.425	0.466	0.522	0.818
	96	0.262	0.257	**0.256**	0.259	0.285	**0.256**	0.274	0.257	0.260	0.288	0.406	0.391	1.002
	192	0.314	**0.293**	**0.293**	0.297	0.329	**0.293**	0.314	0.304	0.298	0.337	0.452	0.414	1.314
ETTm2	336	0.346	0.334	**0.328**	0.330	0.362	**0.328**	0.356	0.355	0.333	0.382	0.491	0.452	1.661
	720	0.396	0.383	**0.380**	**0.380**	0.412	**0.380**	0.407	0.433	0.386	0.407	0.499	0.594	1.914
	TB	0.330	0.317	**0.314**	0.317	0.347	**0.314**	0.338	0.337	0.319	0.353	0.462	0.463	1.473
	96	0.205	0.199	**0.198**	0.231	0.223	0.232	0.212	0.242	0.199	0.234	0.342	0.389	0.361
	192	0.250	0.242	**0.241**	0.267	0.254	0.268	0.252	0.277	0.243	0.270	0.394	0.423	0.461
Weather	336	0.300	0.285	**0.281**	0.299	0.300	0.299	0.291	0.319	**0.281**	0.311	0.408	0.495	0.526
	720	0.351	0.335	**0.331**	0.345	0.348	0.346	0.337	0.359	0.334	0.356	0.421	0.520	0.703
	TB	0.277	0.265	**0.263**	0.285	0.281	0.286	0.273	0.299	0.264	0.293	0.391	0.457	0.513

DyTimeBase với số công bố là bất lợi cho DyTimeBase. Bảng 3.6 so sánh trực tiếp với TimeBase*, nơi hai mô hình chỉ khác nhau ở nhánh trộn kênh.

Bảng 3.6: DyTimeBase so với TimeBase* chạy lại trong cùng quy trình (cùng xương sống, cùng siêu tham số xương sống). MSE trung bình ± độ lệch chuẩn qua 3 seed; cột cuối là chênh lệch tương đối.

Dataset	S	DyTimeBase	TimeBase*	Chênh lệch
	96	**0.3474 ± 0.0014**	0.3575 ± 0.0013	−2.8%
	192	**0.3882 ± 0.0014**	0.3963 ± 0.0026	−2.0%
ETTh1	336	**0.4204 ± 0.0051**	0.4226 ± 0.0006	−0.5%
	720	**0.4558 ± 0.0213**	0.4656 ± 0.0080	−2.1%
	TB	**0.4030**	0.4105	−1.8%
	96	**0.2856 ± 0.0021**	0.2953 ± 0.0004	−3.3%
	192	**0.3467 ± 0.0029**	0.3525 ± 0.0022	−1.7%
ETTh2	336	**0.3784 ± 0.0027**	0.3898 ± 0.0094	−2.9%
	720	0.4212 ± 0.0046	**0.4134 ± 0.0074**	+1.9%
	TB	**0.3580**	0.3627	−1.3%
	96	**0.2961 ± 0.0031**	0.3177 ± 0.0019	−6.8%
	192	**0.3276 ± 0.0003**	0.3626 ± 0.0219	−9.6%
ETTm1	336	**0.3642 ± 0.0065**	0.3717 ± 0.0042	−2.0%
	720	**0.4156 ± 0.0060**	0.4177 ± 0.0027	−0.5%
	TB	**0.3509**	0.3674	−4.5%
	96	0.1665 ± 0.0083	**0.1660 ± 0.0001**	+0.3%
	192	0.2369 ± 0.0043	**0.2182 ± 0.0001**	+8.6%
ETTm2	336	0.2837 ± 0.0086	**0.2767 ± 0.0106**	+2.5%
	720	0.3663 ± 0.0038	**0.3549 ± 0.0033**	+3.2%
	TB	0.2634	**0.2539**	+3.7%
	96	**0.1435 ± 0.0016**	0.1441 ± 0.0003	−0.4%
	192	0.1867 ± 0.0009	**0.1865 ± 0.0000**	+0.1%
Weather	336	0.2403 ± 0.0009	**0.2382 ± 0.0001**	+0.9%
	720	0.3141 ± 0.0063	**0.3092 ± 0.0003**	+1.6%
	TB	0.2211	**0.2195**	+0.8%

Nhánh trộn kênh giảm MSE trung bình trên ETTh1 (−1.8%), ETTh2 (−1.3%) và ETTm1 (−4.5%), nhưng tăng MSE trên ETTm2 (+3.7%) và Weather (+0.8%). Mức cải thiện lớn nhất xuất hiện ở các độ dài dự báo ngắn (ETTm1 với $S = 96$ và $S = 192$: −6.8% và −9.6%). Trên ETTm2, các lần chạy của DyTimeBase thường dừng sớm sau 6–7 epoch, cho thấy nhánh phi tuyến dễ quá khớp trên chuỗi tương đối trơn, nơi một mô hình tuyến tính đã đủ tốt.

3.4.3 Hiệu năng tính toán

Bảng 3.7: Hiệu năng tính toán trên cùng một máy CPU, cấu hình như Table 3 của [1]: Electricity ($C = 321$), $L = S = 720$. Max Mem: đỉnh bộ nhớ RAM khi huấn luyện với batch 12; Epoch Time: thời gian một bước huấn luyện (batch 12) nhân số bước của một epoch (1 414); Infer Time: dự báo 1 mẫu, 8 luồng. Sắp xếp theo Infer Time.

Mô hình	Params	MACs	Max Mem (MB)	Epoch Time (s)	Infer Time (ms)	So với DyTimeBase
TimeBase	0.40K	2.77M	117	20	0.34	0.52×
DyTimeBase	190.51K	23.81M	147	38	0.66	1.00×
SparseTSF	0.93K	12.71M	276	56	0.76	1.15×
FITS	133.64K	42.73M	210	78	1.70	2.59×
DLinear	1.04M	332.81M	150	55	1.93	2.94×
DyTimeNet (Đồ án I)	785.14K	211.80M	285	131	2.14	3.25×
iTransformer	5.47M	2.10G	997	695	10.66	16.23×
Informer	12.45M	7.91G	2 052	2 926	66.16	100.66×
Autoformer	12.14M	8.97G	5 057	5 302	83.39	126.88×
FEDformer	18.44M	8.99G	3 289	5 367	135.93	206.81×
TimeMixer	5.58M	29.97G	>11 264‡	16 716	247.46	376.51×
PatchTST	8.69M	16.08G	10 346	82 400	285.51	434.40×
TimesNet	151.32M	1081.75G	4 078	170 983	3 449.01	5 247.64×

‡ Vượt ngưỡng 11 GB RAM ở batch 12; Epoch Time của mô hình này đo ở batch 4.

Bảng 3.7 cho thấy:

- DyTimeBase nhanh thứ hai trong 13 mô hình khi suy luận (0.66 ms một mẫu), chỉ sau TimeBase (0.34 ms), và nhanh hơn SparseTSF, FITS, DLinear. So với các mô hình Transformer, DyTimeBase nhanh hơn iTransformer khoảng 16 lần, TimeMixer khoảng 377 lần và PatchTST khoảng 434 lần.
- Chi phí huấn luyện cũng thấp: 38 giây một epoch và 147 MB bộ nhớ, trong khi PatchTST cần hơn 10 GB và khoảng 23 giờ một epoch trên cùng thiết bị.
- So với DyTimeNet của Đồ án I ở cùng cấu hình, DyTimeBase có ít hơn khoảng 4.1 lần tham số (190.5K so với 785.1K), ít hơn khoảng 8.9 lần MACs (23.8M so với 211.8M) và suy luận nhanh hơn khoảng 3.2 lần.

Nguyên nhân là mọi phép biến đổi theo trục thời gian chạy trên các kích thước N, R, P (vài chục) thay vì L, S (hàng trăm), như đã phân tích ở mục 2.3.6.

3.4.4 Nghiên cứu loại bỏ (Ablation study)

Bảng 3.8 đánh giá đóng góp của từng khối trong nhánh trộn kênh. Các biến thể giữ nguyên mọi siêu tham số khác, chỉ bỏ đi một khối.

Bảng 3.8: Nghiên cứu loại bỏ (ablation) các khối của nhánh trộn kênh: MSE trung bình trên 4 độ dài dự báo và 3 seed. Dòng cuối giữ nguyên kiến trúc, chỉ tăng tốc độ học của nhánh trộn kênh từ $5 \cdot 10^{-4}$ lên $2 \cdot 10^{-3}$. **Đậm**: tốt nhất mỗi cột.

Biến thể	ETTh1	ETTh2	ETTm1	ETTm2	Weather	Trung bình
DyTimeBase (đầy đủ)	0.4030	0.3580	**0.3509**	0.2634	0.2211	0.3193
bỏ CrossVBlock	0.4028	0.3595	0.3554	0.2615	0.2226	0.3204
bỏ IntraVBlock	0.4004	0.3668	0.3524	0.2661	**0.2186**	0.3209
bỏ cả nhánh trộn kênh (= TimeBase*)	0.4105	0.3627	0.3674	**0.2539**	0.2195	0.3228
DyTimeBase, $\alpha_M = 2 \cdot 10^{-3}$	**0.3992**	**0.3569**	0.3554	0.2627	0.2203	**0.3189**

- Tính trung bình trên 5 bộ dữ liệu, DyTimeBase đầy đủ (0.3193) tốt hơn mọi biến thể đã bỏ khối: bỏ CrossVBlock (0.3204), bỏ IntraVBlock (0.3209) và bỏ cả nhánh (0.3228). Cả hai khối đều có đóng góp, và hai khối bổ trợ nhau: bỏ một khối thì vẫn giữ được một phần lợi ích.
- Trên Weather (21 biến), bỏ CrossVBlock cho kết quả kém nhất (0.2226), còn chỉ giữ CrossVBlock (bỏ IntraVBlock) cho kết quả tốt nhất (0.2186), tốt hơn cả TimeBase* (0.2195). Điều này phù hợp với giả thuyết rằng trộn kênh có ích hơn khi số biến lớn.
- Tăng tốc độ học của nhánh trộn kênh lên $2 \cdot 10^{-3}$ gần như không thay đổi kết quả (0.3189), nên cấu hình $\alpha_M = 5 \cdot 10^{-4}$ của Đồ án I được giữ nguyên.

3.4.5 Thảo luận và hạn chế

- Các chênh lệch trong nghiên cứu loại bỏ (0.3–1.1%) cùng cỡ với độ lệch chuẩn giữa các seed, nên chỉ cho thấy xu hướng, chưa đủ để khẳng định chắc chắn đóng góp của từng khối.
- DyTimeBase chưa vượt được số liệu công bố của TimeBase, và kém các mô hình tuyến tính mạnh trên ETTh2, ETTm2.
- Số liệu của các mô hình so sánh (trừ TimeBase*) được trích dẫn chứ không chạy lại; số tham số của Informer, Autoformer, FEDformer ở Bảng 3.7 (cấu hình script của Time-Series-Library) khác với số trong [1].
- Max Mem đo bằng RAM của CPU; Epoch Time của các mô hình lớn là ước tính từ thời gian một bước huấn luyện. MACs không tính phép biến đổi Fourier nhanh, nên FEDformer, FITS và TimesNet bị đếm thiếu một phần nhỏ.

Tóm tắt chương

DyTimeBase dự báo một mẫu trong 0.66 ms trên CPU, nhanh thứ hai trong 13 mô hình và nhanh hơn các mô hình Transformer từ 16 đến hàng nghìn lần. Về độ chính xác, DyTimeBase vượt toàn bộ các mô hình Transformer và DLinear, đạt kết quả tốt nhất trên ETTm1, đứng thứ hai trên ETTh1 và Weather, và ngang ngửa nhóm mô hình tuyến tính mạnh (SparseTSF, FITS) cùng PatchTST. So với TimeBase trong cùng quy trình, nhánh trộn kênh cải thiện kết quả trên 3/5 bộ dữ liệu.

Tài liệu tham khảo

[1] Q. Huang, Z. Zhou, K. Yang, Z. Yi, X. Wang, Y. Wang, "TimeBase: The power of minimalism in efficient long-term time series forecasting," in *Proc. ICML*, PMLR 267, pp. 26227–26246, 2025.

[2] T. Chen, J. Lai, Y. Sun, W. K. Chan, "DyTimeNet: Dynamic cross-variable dependency network with sparse strategy for multivariate time series forecasting," *Neurocomputing*, vol. 676, p. 132964, 2026.

[3] Y. Wang, H. Wu, J. Dong, Y. Liu, M. Long, J. Wang, "Deep time series models: A comprehensive survey and benchmark," *arXiv:2407.13278*, 2024.

[4] S. Lin, W. Lin, W. Wu, H. Chen, J. Yang, "SparseTSF: Modeling long-term time series forecasting with 1k parameters," in *Proc. ICML*, 2024.

[5] S. Wang, H. Wu, X. Shi, T. Hu, H. Luo, L. Ma, et al., "TimeMixer: Decomposable multiscale mixing for time series forecasting," in *Proc. ICLR*, 2024.

[6] Z. Xu, A. Zeng, Q. Xu, "FITS: Modeling time series with 10k parameters," in *Proc. ICLR*, 2024.

[7] Y. Liu, T. Hu, H. Zhang, H. Wu, S. Wang, L. Ma, M. Long, "iTransformer: Inverted transformers are effective for time series forecasting," in *Proc. ICLR*, 2024.

[8] A. Zeng, M. Chen, L. Zhang, Q. Xu, "Are transformers effective for time series forecasting?" in *Proc. AAAI*, 2023.

[9] Y. Nie, N. H. Nguyen, P. Sinthong, J. Kalagnanam, "A time series is worth 64 words: Long-term forecasting with transformers," in *Proc. ICLR*, 2023.

[10] H. Wu, T. Hu, Y. Liu, H. Zhou, J. Wang, M. Long, "TimesNet: Temporal 2D-variation modeling for general time series analysis," in *Proc. ICLR*, 2023.

[11] T. Zhou, Z. Ma, Q. Wen, X. Wang, L. Sun, R. Jin, "FEDformer: Frequency enhanced decomposed transformer for long-term series forecasting," in *Proc. ICML*, 2022.

[12] H. Wu, J. Xu, J. Wang, M. Long, "Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting," in *Proc. NeurIPS*, 2021.

[13] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, W. Zhang, "Informer: Beyond efficient transformer for long sequence time-series forecasting," in *Proc. AAAI*, 2021.