Dynamic Dependency Learning and Sparse Segment-Based Pattern Extraction for Multivariate Time Series Load Forecasting

Giảng viên hướng dẫn: PGS. TS. Nguyễn Thị Ngọc Anh
Sinh viên thực hiện: Nguyễn Hải Long
Mã số sinh viên: 20237355

Hà Nội, 10/2026

Nội dung chính

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
4. Kết luận
5. Tài liệu tham khảo

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
4. Kết luận
5. Tài liệu tham khảo

Bài toán dự báo phụ tải chuỗi thời gian đa biến

- **Bài toán:** từ L bước quá khứ của C biến, dự báo đồng thời S bước tương lai của cả C biến (năng lượng, thời tiết, giao thông...).
- **Vai trò:** dự báo phụ tải được xem là năng lực nền tảng cho quy hoạch và vận hành hệ thống điện[1].
- **Thách thức đa biến:** nắm phụ thuộc giữa các kênh và xử lý dịch chuyển phân phối ngày càng khó khi quy mô và lĩnh vực ứng dụng mở rộng[2].
- **Xu hướng hiện nay:** dùng cửa sổ quá khứ rất dài ($L = 720$) để nắm phụ thuộc dài hạn, kéo theo số tham số và khối lượng tính toán tăng mạnh[3].
- **Ba yêu cầu cần đáp ứng cùng lúc:**
  - *Nhẹ và nhanh*, để triển khai được trên thiết bị hạn chế tài nguyên.
  - *Khai thác mẫu hình chu kỳ* của chuỗi.
  - *Học quan hệ giữa các biến* mà không khuếch đại các phụ thuộc giả.

[1] Hong and Fan (2016): "Probabilistic electric load forecasting: A tutorial review".

[2] Kim et al. (2025): "A comprehensive survey of deep learning for time series forecasting: architectural diversity and open challenges".

[3] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

Đặc điểm 1: Tính lặp lại

- **Tương đồng theo chu kỳ:** các đoạn dài một chu kỳ (ví dụ mỗi ngày) có hình dạng rất giống nhau, với hệ số tương quan Pearson giữa các đoạn cao[4].
- **Phụ thuộc theo chu kỳ toàn cục:** tương quan giữa một đoạn và đoạn tương ứng ở xa trong chu kỳ toàn cục thường cao hơn tương quan với các đoạn liền kề[5]; dữ liệu điện có mẫu hình ngày dùng chung cho mọi ngày[6].
- **Hệ quả:** không nhất thiết phải mô hình hóa từng điểm thời gian. TimeBase chỉ dùng **0.39K tham số**, ít hơn DLinear hơn 2.6×10^3 lần về tham số và 120 lần về MACs, mà vẫn đạt độ chính xác cạnh tranh.

Dự báo trên **một vài "đoạn đại diện"** thay vì trên L điểm thời gian.

[4] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

[5] Cao et al. (2026): "Enhancing Multivariate Time Series Forecasting with Global Temporal Retrieval".

[6] Lin et al. (2024): "CycleNet: Enhancing Time Series Forecasting through Modeling Periodic Patterns".

Đặc điểm 2: Phụ thuộc chéo giữa các biến

- **Hai nhóm phương pháp theo cách xử lý biến**[7]:
  - **Độc lập biến (CI)** (PatchTST, DLinear, TimeBase): bền vững nhưng bỏ qua tương tác giữa các kênh.
  - **Phụ thuộc biến (CD)** (iTransformer, DyTimeNet): nắm được tương tác nhưng dễ bị nhiễu từ các kênh không liên quan[8].
- **Phụ thuộc thay đổi theo trạng thái:** cùng một cặp biến có thể liên kết mạnh ở kịch bản này nhưng yếu ở kịch bản khác; nhiễu cục bộ tạo ra tương quan giả[9].
- **Mẫu khác toàn cục:** tương quan đo trên từng mẫu có thể lệch đáng kể so với tương quan toàn cục của tập huấn luyện[10].
- **Phụ thuộc thưa:** DyTimeNet dùng chiến lược thưa *DropFusion* để giảm thông tin dư thừa khi học quan hệ liên biến[11].

---

[7] Han, Ye, and Zhan (2024): "The Capacity and Robustness Trade-off: Revisiting the Channel Independent Strategy for Multivariate Time Series Forecasting".

[8] Qiu et al. (2025): "DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting".

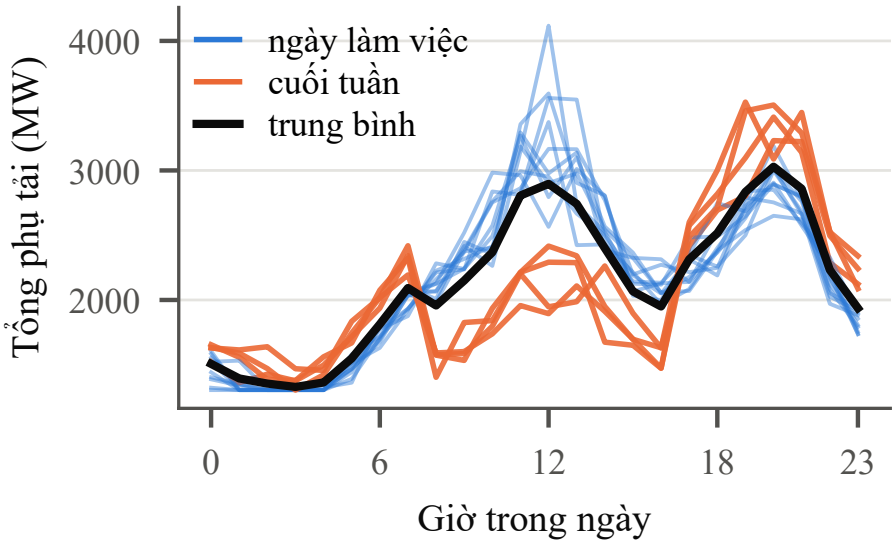
[9] Zhang, Fan, and Wang (2026): "What If We Let Forecasting Forget? A Sparse Bottleneck for Cross-Variable Dependencies".

[10] Lin et al. (2025): "Temporal Query Network for Efficient Multivariate Time Series Forecasting".

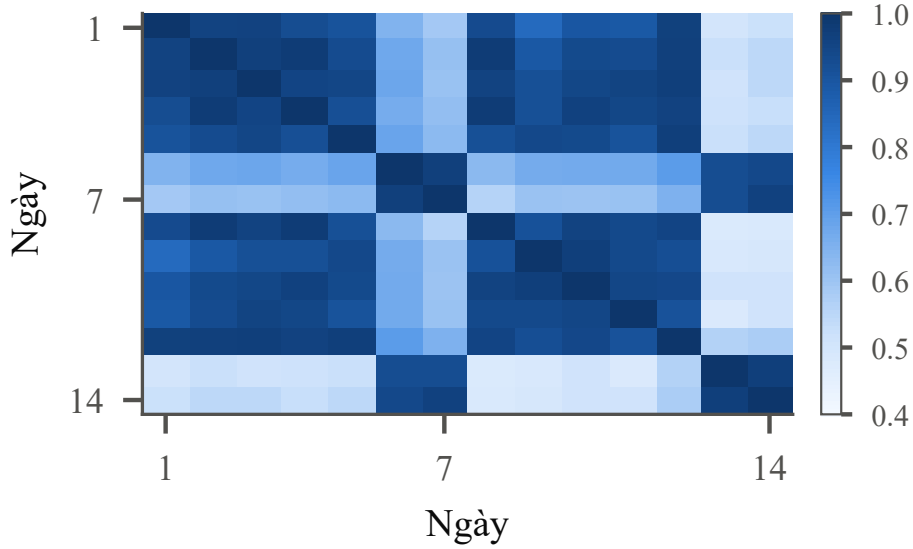
[11] Chen et al. (2026): "DyTimeNet: Dynamic cross-variable dependency network with sparse strategy for multivariate time series forecasting".

Minh chứng trên dữ liệu phụ tải Hà Nội

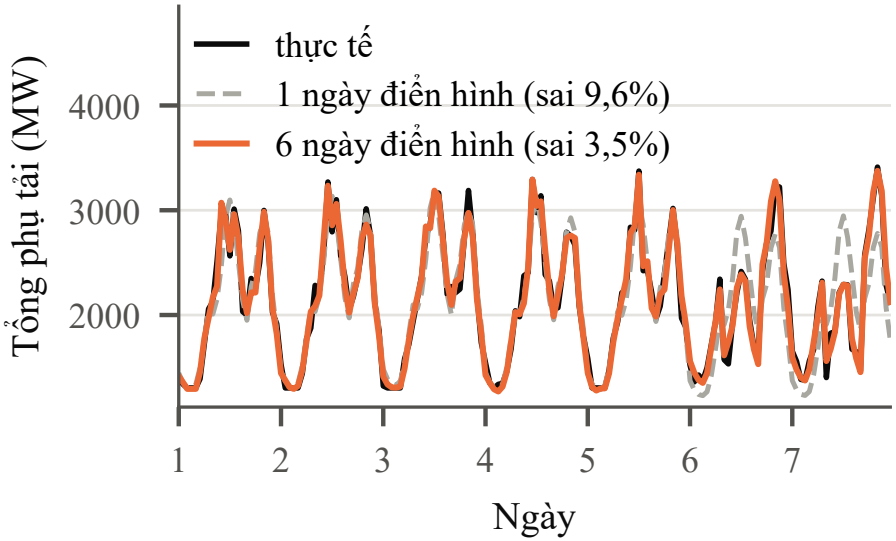
(a) 14 đoạn ngày liên tiếp



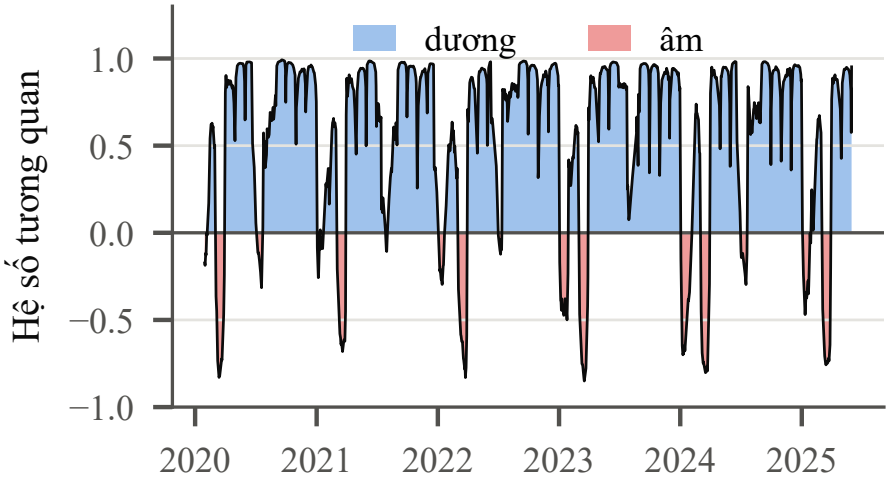
(b) Tương quan Pearson



(c) Dựng lại từ vài ngày điển hình



(d) Tương quan phụ tải – nhiệt độ



Related works: Sparse segment

- **Công trình tiêu biểu:** PatchTST chia mỗi chuỗi đơn biến thành các patch làm token cho Transformer[12]; TimesNet biến chuỗi 1D thành tensor 2D theo các chu kỳ để nắm biến thiên trong và giữa các chu kỳ[13]; SparseTSF dự báo tuyến tính giữa các chu kỳ[14]; TimeBase dự báo trên một số ít đoạn cơ sở[15].
- **So sánh, ưu điểm:** PatchTST dùng patch độ dài cố định, TimesNet tổ chức chuỗi theo chu kỳ của dữ liệu; token mức đoạn bền vững hơn với nhiễu cục bộ và rút ngắn chuỗi cần xử lý.
- **Nhược điểm:** đoạn được đưa vào backbone sâu nên mô hình vẫn phức tạp; SparseTSF, TimeBase rất nhẹ nhưng xử lý từng biến độc lập.

[12] Nie et al. (2023): "A Time Series is Worth 64 Words: Long-term Forecasting with Transformers".

[13] Wu et al. (2023): "TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis".

[14] Lin et al. (2024): "SparseTSF: Modeling Long-term Time Series Forecasting with 1k Parameters".

[15] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

Related works: Multivariate time series

- **Công trình tiêu biểu:** Informer cải thiện hiệu quả attention trên chuỗi dài[16]; FEDformer tích hợp phân rã với cấu trúc miền tần số[17]; JTFT kết hợp miền thời gian và miền tần số, dùng attention hạng thấp để nắm phụ thuộc giữa các chiều[18].
- **So sánh:** khác nhau ở cách biểu diễn tín hiệu (điểm, token tần số, thời gian–tần số), nhưng cùng dựa trên mạng sâu.
- **Ưu điểm:** biểu diễn mạnh đối với động học phức tạp, phi tuyến.
- **Nhược điểm**: chi phí backbone sâu lớn hơn nhiều so với ánh xạ tuyến tính; quan hệ liên biến được học lẫn trong backbone thay vì qua một cơ chế thưa, tường minh.

[16] Zhou et al. (2021): "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting".

[17] Zhou et al. (2022): "FEDformer: Frequency Enhanced Decomposed Transformer for Long-term Series Forecasting".

[18] Chen et al. (2024): "A Joint Time-Frequency Domain Transformer for multivariate time series forecasting".

Related works: Load forecasting

- **Mô hình thống kê:** ARIMA đa mùa vụ thích nghi dự báo phụ tải nước nóng sinh hoạt[19]; SARIMA kết hợp phân tích phổ dự báo nhu cầu điện đỉnh theo mùa[20]; các cách cổ điển (Fourier, làm trơn mũ, SARIMA) chưa phản ánh đặc trưng riêng và tương tác giữa các chu kỳ mùa vụ[21].
- **Mô hình học sâu:** DeepAR học một mô hình tự hồi quy toàn cục trên nhiều chuỗi liên quan và đưa ra phân phối dự báo[22]; TFT kết hợp chọn biến với attention có thể diễn giải cho dự báo đa tầm[23].
- **So sánh:** mô hình thống kê minh bạch, rẻ nhưng dựa trên giả định tuyến tính và thường xử lý các thành phần mùa vụ riêng rẽ; mô hình sâu nắm được tính phi tuyến nhưng nặng và không mô hình hóa tường minh việc biến nào ảnh hưởng biến nào.

---

[19] Nagpal et al. (2025): "An adaptive multi-seasonal ARIMA approach for domestic hot water load forecasting: A pilot study".

[20] Melchor Cruz, Hernández Armenta, and Badaoui (2025): "Seasonal forecasting of peak electricity demand using spectral analysis".

[21] Moon, Lee, and Song (2022): "Mixed pooling of seasonality for time series forecasting: An application to pallet transport data".

[22] Salinas et al. (2020): "DeepAR: Probabilistic forecasting with autoregressive recurrent networks".

[23] Lim et al. (2021): "Temporal Fusion Transformers for interpretable multi-horizon time series forecasting".

Related works: Dynamic dependency (1/2)

Công trình tiêu biểu:

- **MS-FLOW:** gộp token patch thành trạng thái mức biến, chỉ giữ Top-K cạnh cho mỗi biến trong đồ thị thích nghi theo mẫu, rồi lan truyền thông tin dọc các cạnh này[24].
- **xCPD:** mỗi cặp kênh–patch là một nút đồ thị, chia thành dải tần thấp/trung/cao, định tuyến tới các chuyên gia theo tần số[25].
- **DUET:** phân cụm mềm các kênh trong miền tần số bằng metric Mahalanobis học được và mặt nạ lấy mẫu Bernoulli, hợp nhất qua masked attention[26].
- **TQNet:** query học được dịch theo chu kỳ, key/value từ đầu vào gốc, chỉ một lớp attention kết hợp tương quan toàn cục và tương quan mức mẫu[27].

[24] Zhang, Fan, and Wang (2026): "What If We Let Forecasting Forget? A Sparse Bottleneck for Cross-Variable Dependencies".

[25] Li et al. (2026): "Routing Channel-Patch Dependencies in Time Series Forecasting with Graph Spectral Decomposition".

[26] Qiu et al. (2025): "DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting".

[27] Lin et al. (2025): "Temporal Query Network for Efficient Multivariate Time Series Forecasting".

Related works: Dynamic dependency (2/2)

- **Ưu điểm:** mô hình hóa phụ thuộc bền vững; TQNet và xCPD còn chú trọng hiệu quả.
- **Nhược điểm:** học trên token mức patch/điểm nên tăng theo C: DUET dùng ma trận $C \times C$ giữa mọi cặp kênh, xCPD dựng đồ thị $C \times N$ nút; MS-FLOW phải chọn K theo từng bộ dữ liệu; TQNet: ép mô hình hóa đa biến có thể gây hại khi tương quan yếu.

Related works: Pattern extraction (1/2)

Công trình tiêu biểu:

- **CycleNet:** học các chu kỳ lặp $Q \in \mathbb{R}^{W \times C}$ dùng chung cho cả bộ dữ liệu, loại khỏi đầu vào và chỉ dự báo phần dư; chỉ thêm $W \times C$ tham số, không thêm MACs[28].
- **TimeEmb:** tách thành phần bất biến (truy xuất từ ngân hàng embedding theo dấu thời gian) khỏi thành phần biến đổi (xử lý bằng bộ lọc tần số)[29].
- **GTR:** embedding toàn cục cho cả một chu kỳ, truy xuất đoạn theo vị trí tuyệt đối, hợp nhất bằng tích chập 2D; mô-đun chỉ 40.1K tham số[30].
- **LightGTS:** patch dài đúng một chu kỳ nội tại, giải mã song song; nhỏ hơn 10–100 lần các mô hình nền tảng khác[31].

[28] Lin et al. (2024): "CycleNet: Enhancing Time Series Forecasting through Modeling Periodic Patterns".

[29] Xia et al. (2025): "TimeEmb: A Lightweight Static-Dynamic Disentanglement Framework for Time Series Forecasting".

[30] Cao et al. (2026): "Enhancing Multivariate Time Series Forecasting with Global Temporal Retrieval".

[31] Wang et al. (2025): "LightGTS: A Lightweight General Time Series Forecasting Model".

Related works: Pattern extraction (2/2)

- **So sánh:** CycleNet, TimeEmb, GTR lưu mẫu hình *toàn cục* học trên cả tập huấn luyện; LightGTS trích mẫu hình *cục bộ* căn theo chu kỳ từ cửa sổ đầu vào.
- **Ưu điểm:** nắm cấu trúc chu kỳ với chi phí thấp.
- **Nhược điểm:** mẫu hình được trích xuất theo từng kênh. CycleNet thua iTransformer trên Traffic và nêu mô hình hóa liên kênh là hướng phát triển tương lai[32].

[32] Lin et al. (2024): "CycleNet: Enhancing Time Series Forecasting through Modeling Periodic Patterns".

Khoảng trống nghiên cứu

Nhóm mô hình	Ví dụ	Biểu diễn chu kỳ / đoạn	Học quan hệ liên biến	Rất nhẹ
Đoạn thưa, tuyến tính (CI)	SparseTSF, TimeBase	✓	×	✓
Mô hình sâu theo đoạn	PatchTST, TimesNet	✓	× / ngầm định	×
Mô hình sâu đa biến	Informer, FEDformer, JTFT, iTransformer	×	✓ dày đặc / hạng thấp	×
Mô hình phụ tải thống kê	ARIMA đa mùa vụ, phân tích phổ	✓	×	✓
Mô hình phụ tải học sâu	DeepAR, TFT	×	chỉ qua biến đồng hành	×
Trích xuất mẫu hình (CI)	CycleNet, TimeEmb, GTR, LightGTS	✓	×	✓
Phụ thuộc thưa / thích nghi	MS-FLOW, xCPD, DUET	patch	✓ thưa	một phần
Attention với query chu kỳ	TQNet	✓	✓	một phần
MLP trộn biến trên chuỗi gốc (chi phí theo L, S)	DyTimeNet	×	✓ thưa	×
DyBAS-Net (đề xuất)	–	✓ đoạn cơ sở	✓ thưa, động	✓

Mục đích nghiên cứu

Đề xuất mô hình **DyBAS-Net** (**Dy**namic cross-variable dependency on **BAS**is components), với các mục tiêu:

- **Trích xuất mẫu hình dựa trên đoạn thưa:** phân đoạn theo chu kỳ, chuẩn hóa từng pha, nén N đoạn quá khứ thành $R \ll N$ đoạn cơ sở trực giao.
- **Học phụ thuộc động trong không gian cơ sở:** đưa CrossVBlock với chiến lược DropFusion và IntraVBlock của DyTimeNet[33] vào xử lý $P \cdot R$ hệ số cơ sở của mỗi biến, thay vì L điểm thời gian.
- **Hiệu chỉnh an toàn:** nhánh trộn biến chỉ cộng một lượng hiệu chỉnh vào các thành phần cơ sở, khởi tạo bằng 0, nên mô hình xuất phát đúng từ backbone CI.
- **Hiệu quả:** phép tính trên trục thời gian chỉ ở kích thước mức đoạn (N, R, P, cỡ hàng chục) thay vì L, S (cỡ hàng trăm).
- **Đánh giá toàn diện:** so sánh độ chính xác với 14 mô hình trên 5 bộ dữ liệu, và đo chi phí tính toán của các mô hình trên *cùng một thiết bị*.

[33] Chen et al. (2026): "DyTimeNet: Dynamic cross-variable dependency network with sparse strategy for multivariate time series forecasting".

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
4. Kết luận
5. Tài liệu tham khảo

Input

Đầu vào $\mathcal{X} \in \mathbb{R}^{L \times C}$: một cửa sổ quá khứ độ dài L của C biến, $i = \overline{1, C}$ (cửa sổ được trượt trên cả tập train, val và test).

$$\mathcal{X} = \begin{bmatrix} x_1^{(1)} & x_1^{(2)} & \cdots & x_1^{(C)} \\ x_2^{(1)} & x_2^{(2)} & \cdots & x_2^{(C)} \\ \vdots & \vdots & \ddots & \vdots \\ x_L^{(1)} & x_L^{(2)} & \cdots & x_L^{(C)} \end{bmatrix} \quad (1)$$

Định nghĩa thành phần:

- $x_t^{(i)}$: Giá trị của biến thứ i tại thời điểm t.
- $i = \overline{1, C}$: Chỉ số biến.
- $t = \overline{1, L}$: Chỉ số mốc thời gian.

Giá trị thực $\mathcal{Y} \in \mathbb{R}^{S \times C}$: giá trị của S bước ngay sau cửa sổ:

$$\mathcal{Y} = \begin{bmatrix} x_{L+1}^{(1)} & x_{L+1}^{(2)} & \cdots & x_{L+1}^{(C)} \\ \vdots & \vdots & \ddots & \vdots \\ x_{L+S}^{(1)} & x_{L+S}^{(2)} & \cdots & x_{L+S}^{(C)} \end{bmatrix} \quad (2)$$

Output và Hàm mục tiêu

- **Ma trận kết quả dự báo ($\hat{\mathcal{Y}} \in \mathbb{R}^{S \times C}$):** được ước lượng đồng thời bởi mô hình $\mathcal{F}$ (**DyBAS-Net**):

$$\hat{\mathcal{Y}} = \mathcal{F}(\mathcal{X})$$

- **Sai số dự báo (MSE):**

$$\mathcal{L}_{MSE} = \frac{1}{S \times C} \sum_{t=1}^{S} \sum_{i=1}^{C} \left(x_{L+t}^{(i)} - \hat{x}_{L+t}^{(i)} \right)^2 \tag{3}$$

- **Hàm mục tiêu khi huấn luyện:** thêm ràng buộc trực giao trên các thành phần cơ sở:

$$\mathcal{L} = \mathcal{L}_{MSE} + \lambda_{orth} \mathcal{L}_{orth}, \qquad \lambda_{orth} \geq 0 \tag{4}$$

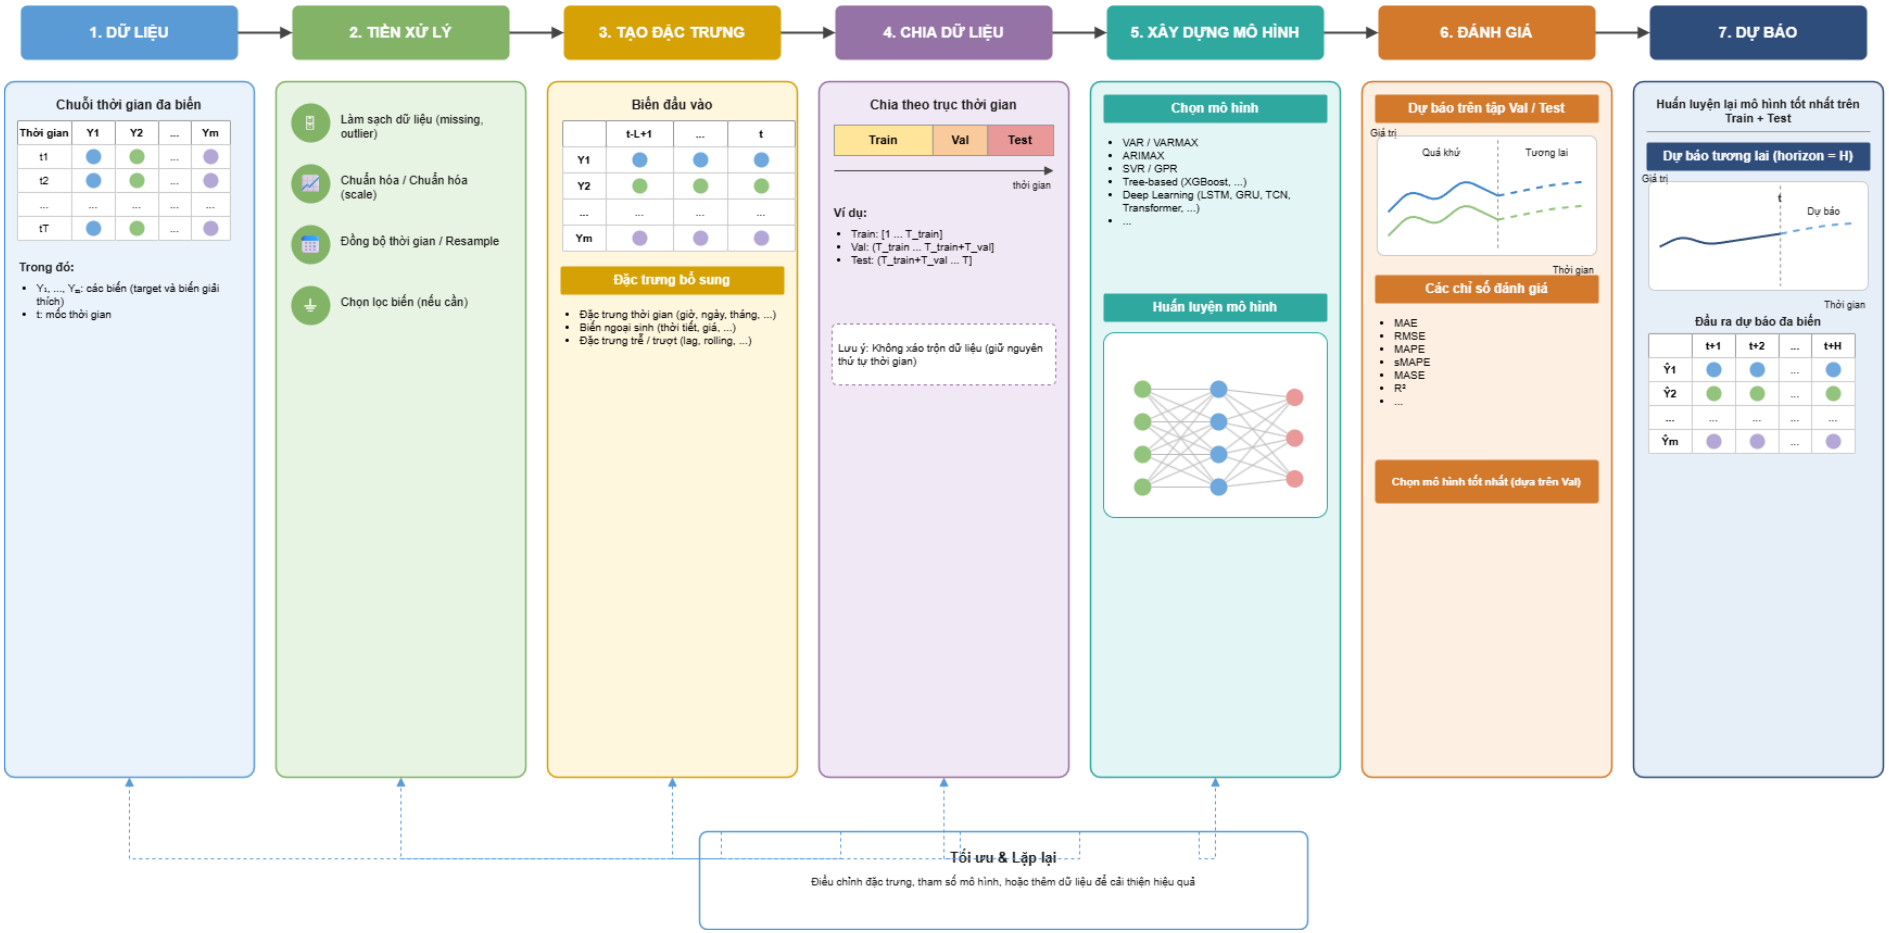
Các kích thước sử dụng trong mô hình

Ký hiệu	Ý nghĩa	ETTh1 ($L = 720$, $S = 96$)
P	Độ dài một đoạn (chu kỳ)	24 (một ngày)
$N = \lceil L/P \rceil$	Số đoạn quá khứ	30 ngày
$N' = \lceil S/P \rceil$	Số đoạn tương lai	4 ngày
$R \ll N$	Số thành phần cơ sở	6
D	Số chiều ẩn của nhánh trộn biến	64
$C' = \lfloor 0.75\, C \rfloor$	Số chiều nút thắt của CrossVBlock	5
$D_{ff} = 2D$	Số chiều ẩn của FFN trong IntraVBlock	128

Quy ước ký hiệu

Ký hiệu	Ý nghĩa	Ví dụ
Chữ thường, không đậm: x	Một số (vô hướng)	$x_t^{(i)}$: giá trị của biến i tại thời điểm t
Chữ thường, in đậm: $\mathbf{x}$	Một vector cột	$\mathbf{x}^{(i)}$: cả chuỗi của biến i
Chữ hoa, in đậm: $\mathbf{X}$	Ma trận (của một biến, trọng số, trung gian)	$\mathbf{X}^{(i)} \in \mathbb{R}^{P\times N}$: ma trận đoạn của biến i
Chữ hoa nghiêng: $\mathcal{X}$	Dữ liệu, đặc trưng ẩn của *mọi* biến	$\mathcal{X}$, $\mathcal{Y}$, $\mathcal{X}_{enc} \in \mathbb{R}^{D\times C}$
Ngoại lệ	$\mathcal{M}$: mặt nạ; $\mathcal{L}$: hàm mất mát	$\mathcal{M}_1$, $\mathcal{L}_{MSE}$
Chỉ số trên $^{(i)}$	Thuộc biến thứ i	$\mathbf{E}^{(i)}$: cơ sở của biến i
Ngoặc vuông $[\cdot]_{p,n}$	Phần tử hàng p, cột n của ma trận	$\left[\mathbf{X}^{(i)}\right]_{p,n}$
Chỉ số dưới của vector in đậm	Cột thứ mấy của ma trận	$\mathbf{e}_r^{(i)}$: cột thứ r của $\mathbf{E}^{(i)}$
Chỉ số dưới $_b$ của ma trận	Mẫu thứ b trong một lô	$\mathbf{G}_b^{(i)}$: ma trận Gram của mẫu b
Dấu ngã, mũ, phẩy: $\tilde{\mathbf{X}}$, $\hat{\mathbf{Y}}$, $\mathbf{E}'$	Đã chuẩn hóa / dự báo / đã hiệu chỉnh	$\tilde{\mathcal{X}}_{enc} = \mathrm{LN}(\mathcal{X}_{enc})$

Kiến trúc cơ bản của các mô hình dự báo CTG



Tổng quan các bước của DyBAS-Net

1. **Phân đoạn theo chu kỳ:** cắt chuỗi dài L thành N đoạn dài P.
2. **Chuẩn hóa theo pha:** trừ trung bình của từng pha trong chu kỳ.
3. **Trích xuất cơ sở:** nén N đoạn thành R thành phần cơ sở $\mathrm{E}^{(i)}$.
4. **Mã hóa hệ số cơ sở** của mỗi biến thành vector D chiều.
5. **CrossVBlock + DropFusion:** trộn thông tin giữa các biến.
6. **IntraVBlock:** biến đổi phi tuyến trong từng biến.
7. **Chiếu ngược:** sinh lượng hiệu chỉnh $\Delta\mathrm{E}^{(i)}$, cộng vào cơ sở.
8. **Dự báo theo đoạn và khôi phục:** sinh N' đoạn tương lai, cộng lại trung bình theo pha.

1. Phân đoạn theo chu kỳ

Chuỗi của biến i, $\mathrm{x}^{(i)} = (x_1^{(i)}, \ldots, x_L^{(i)})$, được xếp thành **ma trận đoạn** $\mathrm{X}^{(i)} \in \mathbb{R}^{P \times N}$, mỗi cột là một đoạn dài P:

$$\mathrm{X}^{(i)} = \begin{bmatrix} x_1^{(i)} & x_{P+1}^{(i)} & \cdots & x_{(N-1)P+1}^{(i)} \\ x_2^{(i)} & x_{P+2}^{(i)} & \cdots & x_{(N-1)P+2}^{(i)} \\ \vdots & \vdots & \ddots & \vdots \\ x_P^{(i)} & x_{2P}^{(i)} & \cdots & x_{NP}^{(i)} \end{bmatrix}, \qquad \left[\mathrm{X}^{(i)}\right]_{p,n} = x_{(n-1)P+p}^{(i)} \tag{5}$$

- Ví dụ ETTh1: $L = 720$, $P = 24 \Rightarrow N = 30$ cột, mỗi cột là một ngày.
- $\left[\mathrm{X}^{(i)}\right]_{p,n}$: phần tử ở hàng p, cột n là giá trị ở giờ thứ p của ngày thứ n.
  Trước ngày thứ n có $(n-1)$ ngày đầy đủ, tức $(n-1)P$ điểm; đi thêm p bước vào ngày n là tới vị trí $(n-1)P + p$ trong chuỗi gốc.

2. Chuẩn hóa theo pha

- **Trung bình theo pha:** trung bình của từng hàng (từng pha) qua N đoạn:

$$\mu_p^{(i)} = \frac{1}{N}\sum_{n=1}^{N} \left[\mathrm{X}^{(i)}\right]_{p,n}, \qquad \boldsymbol{\mu}^{(i)} = (\mu_1^{(i)}, \ldots, \mu_P^{(i)})^\top \in \mathbb{R}^P \tag{6}$$

- **Trừ trung bình:**

$$\left[\tilde{\mathrm{X}}^{(i)}\right]_{p,n} = \left[\mathrm{X}^{(i)}\right]_{p,n} - \mu_p^{(i)} \qquad \text{(trừ } \mu_p^{(i)} \text{ cho mọi phần tử của hàng } p\text{)} \tag{7}$$

- **Ý nghĩa:** $\boldsymbol{\mu}^{(i)}$ là "đoạn trung bình" của biến i. Các bước sau chỉ học phần dao động quanh nó.

3. Trích xuất thành phần cơ sở (Basis Extraction)

- Ánh xạ tuyến tính **dùng chung cho mọi biến** nén N đoạn thành R thành phần cơ sở ($\mathrm{W}_B \in \mathbb{R}^{N\times R}$, $\mathrm{b}_B \in \mathbb{R}^R$ học được):

$$\mathrm{E}^{(i)} = \tilde{\mathrm{X}}^{(i)}\,\mathrm{W}_B + \mathrm{b}_B \quad \in \mathbb{R}^{P\times R} \qquad (\mathrm{b}_B \text{ cộng vào mọi hàng}) \tag{8}$$

- **Cột thứ r của** $\mathrm{E}^{(i)}$ là tổ hợp tuyến tính của N đoạn quá khứ $\tilde{\mathrm{x}}_n^{(i)}$, tức một "đoạn đại diện":

$$\mathrm{e}_r^{(i)} = \sum_{n=1}^{N} [\mathrm{W}_B]_{n,r}\,\tilde{\mathrm{x}}_n^{(i)} + [\mathrm{b}_B]_r \quad \in \mathbb{R}^P \tag{9}$$

- **Ý nghĩa:** tóm $N = 30$ ngày thành $R = 6$ "ngày điển hình", dựa trên tính hạng thấp của chuỗi dài[34].

[34] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

3. Ràng buộc trực giao trên các thành phần cơ sở

- **Ma trận Gram:** tích vô hướng giữa từng cặp thành phần cơ sở

$$\mathrm{G}^{(i)} = \mathrm{E}^{(i)\top}\mathrm{E}^{(i)} \in \mathbb{R}^{R\times R}, \qquad \left[\mathrm{G}^{(i)}\right]_{r,s} = \langle \mathrm{e}_r^{(i)}, \mathrm{e}_s^{(i)} \rangle \tag{10}$$

- **Phạt phần ngoài đường chéo** (trung bình trên B mẫu của một lô và C biến):

$$\mathcal{L}_{orth} = \frac{1}{B\,C}\sum_{b=1}^{B}\sum_{i=1}^{C}\left\|\mathrm{G}_b^{(i)} - \mathrm{diag}\left(\mathrm{G}_b^{(i)}\right)\right\|_F \tag{11}$$

- $\mathcal{L}_{orth} = 0$ khi các thành phần cơ sở đôi một trực giao, nên mỗi thành phần mang một kiểu biến thiên riêng, không trùng lặp.
- Chỉ dùng khi huấn luyện; khi đánh giá chỉ đo MSE và MAE.

4. Mã hóa hệ số cơ sở (Basis Encoding)

- **Làm phẳng:** trải $\mathrm{E}^{(i)}$ theo hàng thành vector, rồi ghép C biến thành ma trận:

$$\mathrm{e}^{(i)} = \mathrm{vec}\left(\mathrm{E}^{(i)}\right) \in \mathbb{R}^{PR}, \qquad \bar{\mathrm{E}} = \left[\mathrm{e}^{(1)}, \ldots, \mathrm{e}^{(C)}\right] \in \mathbb{R}^{PR \times C} \tag{12}$$

- **Mã hóa:** ánh xạ tuyến tính sang không gian ẩn D chiều:

$$\mathcal{X}_{enc} = \mathrm{W}_{enc}^{\top} \bar{\mathrm{E}} + \mathrm{b}_{enc} \quad \in \mathbb{R}^{D \times C} \qquad (\mathrm{b}_{enc} \text{ cộng vào mọi cột}) \tag{13}$$

  - $\mathrm{W}_{enc} \in \mathbb{R}^{PR \times D}$: ma trận trọng số có thể học; $\mathrm{b}_{enc} \in \mathbb{R}^{D}$: vector độ lệch.

Chuẩn hóa LayerNorm và hàm kích hoạt GELU

- **LayerNorm**[35]: chuẩn hóa D đặc trưng của từng biến (cột $\mathrm{h} \in \mathbb{R}^D$), đưa mọi biến về cùng thang đo trước khi trộn:

$$\mathrm{LN}(\mathrm{h}) = \boldsymbol{\gamma} \odot \frac{\mathrm{h} - \mu_{\mathrm{h}}}{\sqrt{\sigma_{\mathrm{h}}^2 + \varepsilon}} + \boldsymbol{\beta} \tag{14}$$

  - $\mu_{\mathrm{h}}, \sigma_{\mathrm{h}}^2$: trung bình, phương sai các phần tử của h; $\boldsymbol{\gamma}, \boldsymbol{\beta} \in \mathbb{R}^D$ học được.
- **Hàm kích hoạt GELU**[36]:

$$\mathrm{GELU}(x) = x \cdot \Phi(x) = \frac{x}{2}\left(1 + \mathrm{erf}\left(\frac{x}{\sqrt{2}}\right)\right) \tag{15}$$

  - $\Phi(x)$: Hàm phân phối tích lũy của $\mathcal{N}(0,1)$; $\mathrm{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2}\, dt$.

[35] Ba, Kiros, and Hinton (2016): "Layer Normalization".

[36] Hendrycks and Gimpel (2016): "Gaussian Error Linear Units (GELUs)".

5. Khối Liên biến (CrossVBlock)

- **Chuẩn hóa:**

$$\tilde{\mathcal{X}}_{enc} = \mathrm{LN}(\mathcal{X}_{enc}) \quad \in \mathbb{R}^{D\times C}$$

- **MLP nút thắt trên trục biến** $C \to C' \to C$ (khi kiểm thử), với $\mathrm{W}_{df,1} \in \mathbb{R}^{C\times C'}$, $\mathrm{W}_{df,2} \in \mathbb{R}^{C'\times C}$ (độ lệch b_1, b_2 cộng vào mọi hàng):

$$\mathrm{H} = \mathrm{GELU}\big(\tilde{\mathcal{X}}_{enc}\,\mathrm{W}_{df,1} + \mathrm{b}_1\big) \qquad \in \mathbb{R}^{D\times C'} \qquad (16)$$

$$\mathcal{X}_{cross} = \mathrm{H}\,\mathrm{W}_{df,2} + \mathrm{b}_2 \qquad \in \mathbb{R}^{D\times C} \qquad (17)$$

- **Vì sao là trộn liên biến:** mỗi *hàng* của $\tilde{\mathcal{X}}_{enc}$ là một đặc trưng của cả C biến. Nhân phải với W_{df} tạo mỗi biến mới bằng tổ hợp của mọi biến trên từng đặc trưng.
- Khi huấn luyện, hai lớp tuyến tính này được thay bằng lớp **DropFusion**[37].

[37] Chen et al. (2026): "DyTimeNet: Dynamic cross-variable dependency network with sparse strategy for multivariate time series forecasting".

5a. DropFusion: Mặt nạ Cạnh $\mathcal{M}_1$ và Mặt nạ Nút $\mathcal{M}_2$

Khi huấn luyện, hai lớp tuyến tính của CrossVBlock được can thiệp bởi DropFusion. Xét lớp thứ nhất (đầu vào $\tilde{\mathcal{X}}_{enc} \in \mathbb{R}^{D\times C}$, trọng số $\mathrm{W}_{df,1} \in \mathbb{R}^{C\times C'}$):

- **Giai đoạn 1 – Mặt nạ Cạnh** $\mathcal{M}_1 \in \{0,1\}^{C\times C'}$**:** mỗi phần tử bằng 0 với xác suất p_1, tức tắt liên kết giữa một biến đầu vào và một nút ẩn. Lấy mẫu lại ở mỗi lô dữ liệu.

$$\mathrm{W}_{masked} = \mathrm{W}_{df,1} \odot \mathcal{M}_1 \tag{18}$$

- **Giai đoạn 2 – Mặt nạ Nút** $\mathcal{M}_2 \in \{0,1\}^{D\times C'}$**:** mỗi phần tử bằng 0 với xác suất p_2, tức tắt ngẫu nhiên từng phần tử đầu ra. Lấy mẫu riêng cho từng mẫu.

$$\mathrm{Y}_{masked} = \left(\tilde{\mathcal{X}}_{enc}\,\mathrm{W}_{masked} + \mathrm{b}_1\right) \odot \mathcal{M}_2 \tag{19}$$

Lớp thứ hai làm tương tự, với đầu vào H và trọng số $\mathrm{W}_{df,2}$.

5b. DropFusion: Chuẩn hóa kỳ vọng

- **Vấn đề năng lượng tín hiệu:** khi huấn luyện, một phần kết nối bị tắt (p_1, p_2); khi kiểm thử mạng mở lại 100% kết nối nên tổng tín hiệu tăng vọt, gây sai lệch.
- **Giải pháp:** nhân hệ số bù để kỳ vọng tín hiệu không đổi giữa hai giai đoạn.

Công thức DropFusion hoàn chỉnh (khi huấn luyện)

$$\mathrm{DF}(\tilde{\mathcal{X}}_{enc}) = \frac{1}{1-p_2}\left[\frac{\tilde{\mathcal{X}}_{enc}\,(\mathrm{W}_{df,1} \odot \mathcal{M}_1)}{1-p_1} + \mathrm{b}_1\right] \odot \mathcal{M}_2 \tag{20}$$

6. Khối Nội biến (IntraVBlock)

- **Kết nối thặng dư:** cộng đặc trưng chéo với đặc trưng đã chuẩn hóa để giữ thông tin gốc của từng biến:

$$\mathcal{X}_{intra} = \mathcal{X}_{cross} + \tilde{\mathcal{X}}_{enc} \quad \in \mathbb{R}^{D \times C} \tag{21}$$

- **Mạng truyền thẳng dùng chung**, áp dụng cho *từng cột* (từng biến) $\mathrm{h} \in \mathbb{R}^{D}$:

$$\mathrm{FFN}(\mathrm{h}) = \mathrm{W}_4\,\mathrm{GELU}(\mathrm{W}_3\mathrm{h}+\mathrm{b}_3)+\mathrm{b}_4, \qquad \mathrm{W}_3 \in \mathbb{R}^{D_{ff} \times D},\ \mathrm{W}_4 \in \mathbb{R}^{D \times D_{ff}} \tag{22}$$

- **Đầu ra** (LayerNorm phía trước, thặng dư phía sau):

$$\hat{\mathcal{X}}_{intra} = \mathcal{X}_{intra} + \mathrm{FFN}\big(\,\mathrm{LN}(\mathcal{X}_{intra})\big) \quad \in \mathbb{R}^{D \times C} \tag{23}$$

7. Chiếu ngược và Hiệu chỉnh thành phần cơ sở

- **Chiếu ngược** về không gian cơ sở:

$$\Delta \bar{\mathrm{E}} = \mathrm{W}_{out}^{\top}\, \hat{\mathcal{X}}_{intra} + \mathrm{b}_{out} \quad \in \mathbb{R}^{PR \times C}, \qquad \mathrm{W}_{out} \in \mathbb{R}^{D \times PR} \tag{24}$$

- Cột i được xếp lại thành $\Delta \mathrm{E}^{(i)} \in \mathbb{R}^{P \times R}$ và **cộng vào cơ sở**:

$$\mathrm{E}'^{(i)} = \mathrm{E}^{(i)} + \Delta \mathrm{E}^{(i)} \tag{25}$$

- **Khởi tạo bằng 0:** $\mathrm{W}_{out} = 0$, $\mathrm{b}_{out} = 0$ nên lúc bắt đầu huấn luyện $\Delta \mathrm{E}^{(i)} = 0$.
- **Ý nghĩa:** nhánh trộn biến chỉ học *phần hiệu chỉnh*: dùng thông tin của các biến khác để sửa các "ngày điển hình" của biến i.

8. Dự báo theo đoạn và Khôi phục thang đo

- **Dự báo theo đoạn:** ánh xạ tuyến tính dùng chung sinh N' đoạn tương lai từ R cơ sở đã hiệu chỉnh:

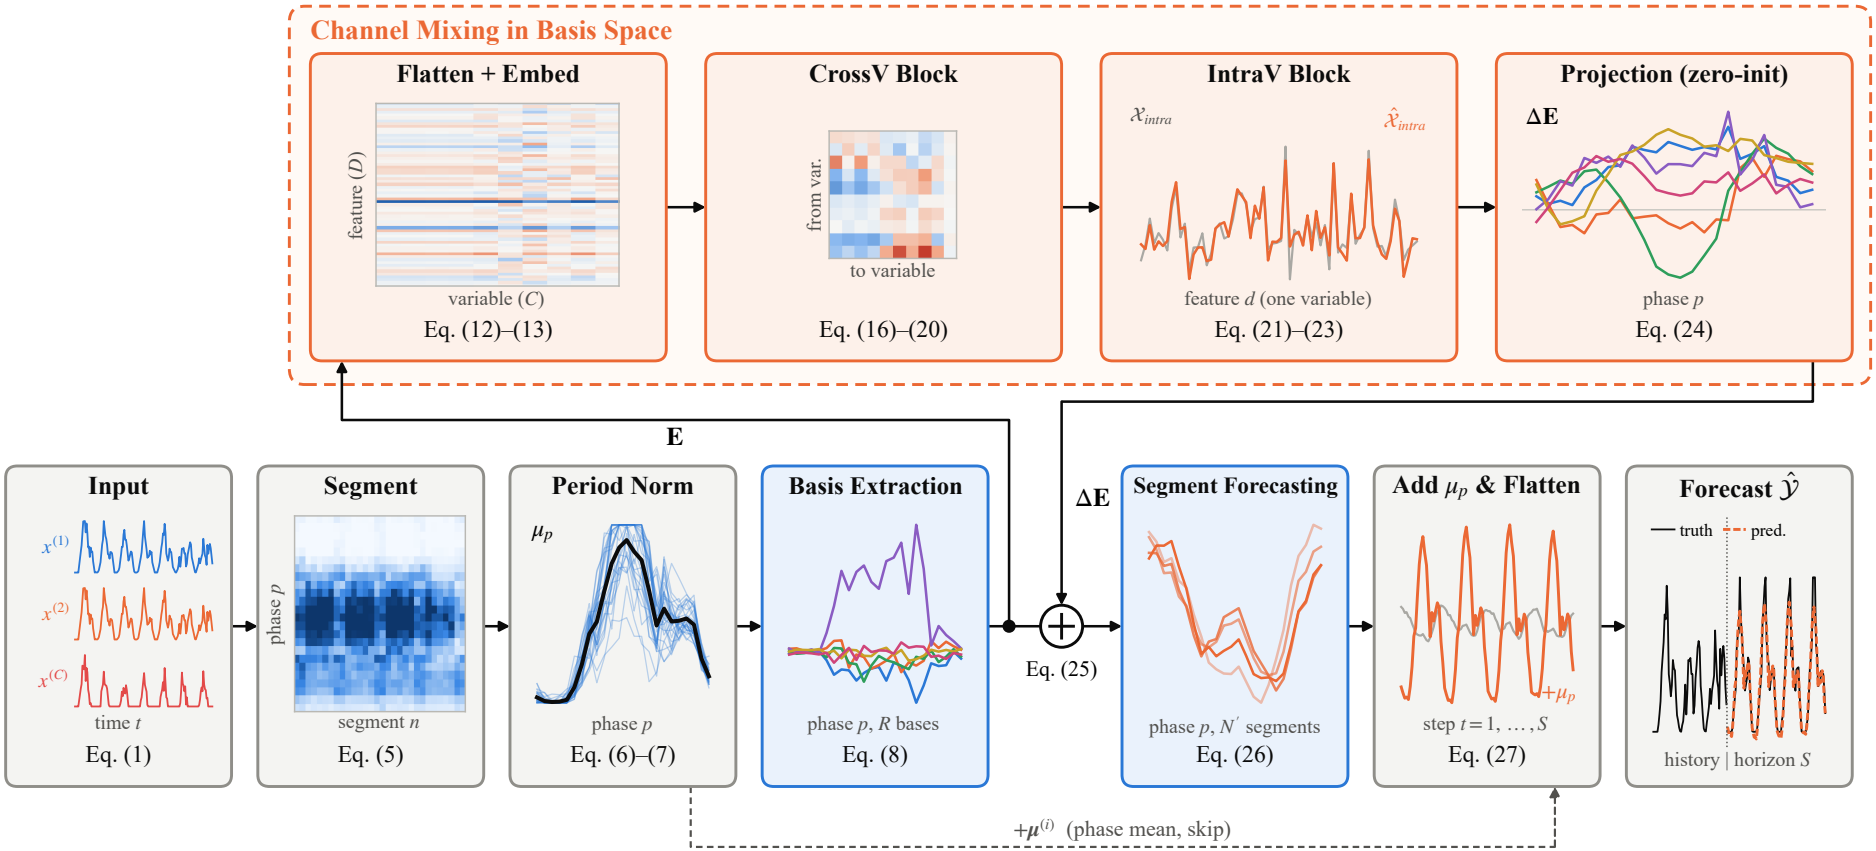
$$\hat{\mathrm{Y}}^{(i)} = \mathrm{E}'^{(i)}\,\mathrm{W}_F + \mathrm{b}_F \quad \in \mathbb{R}^{P\times N'}, \qquad \mathrm{W}_F \in \mathbb{R}^{R\times N'} \tag{26}$$

- **Khôi phục thang đo và ghép đoạn:** cộng trả trung bình theo pha cho mọi đoạn tương lai, nối các cột thành chuỗi và giữ S bước đầu:

$$\hat{x}^{(i)}_{L+t} = \left[\hat{\mathrm{Y}}^{(i)}\right]_{p,n} + \mu^{(i)}_p, \quad t = (n-1)P + p, \quad t = \overline{1,S} \tag{27}$$

- Ghép C biến cho dự báo $\hat{\mathcal{Y}} \in \mathbb{R}^{S\times C}$.

9. Overview Pipeline



Điều chỉnh và Tối ưu hóa Trọng số

- Trọng số được cập nhật ngược hướng gradient của hàm mục tiêu $\mathcal{L}$:

$$\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - \alpha \frac{\partial \mathcal{L}}{\partial \boldsymbol{\theta}_k} \tag{28}$$

  với $\boldsymbol{\theta}$ gồm mọi trọng số W và độ lệch b, k là bước cập nhật.
- **Hai tốc độ học:** $\alpha = \alpha_B$ cho $\mathrm{W}_B, \mathrm{b}_B, \mathrm{W}_F, \mathrm{b}_F$, $\alpha = \alpha_M$ cho nhánh trộn biến.
- **Tốc độ học** theo epoch τ: giữ nguyên 4 epoch đầu, sau đó nhân 0.8 mỗi epoch: $\alpha^{(\tau)} = \alpha$ nếu $\tau \leq 4$, $\alpha^{(\tau)} = \alpha \cdot 0.8^{\tau-4}$ nếu $\tau > 4$ (29)

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
4. Kết luận
5. Tài liệu tham khảo

Mô tả dữ liệu thực nghiệm

Dataset	Số biến C	Tần suất	Số bước dùng	Chia Train/Val/Test	Số cửa sổ ($L = 720$, $S = 96$)
ETTh1, ETTh2	7	1 giờ	14 400	12/4/4 tháng	7 825 / 2 785 / 2 785
ETTm1, ETTm2	7	15 phút	57 600	12/4/4 tháng	33 745 / 11 425 / 11 425
Weather	21	10 phút	52 696	7 : 1 : 2	36 072 / 5 174 / 10 445
Tetouan	8	10 phút	52 416	7 : 1 : 2	35 876 / 5 146 / 10 389
Panama	13	1 giờ	48 048	7 : 1 : 2	32 818 / 4 709 / 9 516

- **ETT**: nhiệt độ dầu và 6 chỉ số phụ tải của máy biến áp điện.
- **Weather**: 21 chỉ số khí tượng (nhiệt độ, độ ẩm, áp suất, gió. . .), có quan hệ vật lý giữa các biến.
- **Tetouan** (Maroc, năm 2017): phụ tải 3 khu vực, 3 biến thời tiết và 2 biến bức xạ; **Panama** (01/2015–06/2020): phụ tải quốc gia và thời tiết 3 thành phố.
- **Tiền xử lý:** chuẩn hóa Z-score theo từng biến (chỉ tính trên tập train); cửa sổ trượt $L = 720$, $S \in \{96, 192, 336, 720\}$; đánh giá trên *mọi* cửa sổ của tập test.

Siêu tham số của DyBAS-Net

	Theo $S = 96/192/336/720$		Nhánh trộn biến	
Dataset	P	R	p_1	p_2
ETTh1	24/24/24/24	6/6/6/6	0.1	0.1
ETTh2	24/24/24/24	6/4/6/6	0.3	0.5
ETTm1	4/4/4/6	18/20/20/20	0.1	0.2
ETTm2	4/4/4/6	20/20/20/20	0.4	0.6
Weather	4/4/4/4	6/6/6/6	0.1	0.1
Tetouan	144/144/144/144	3/3/3/3	0.2	0.5
Panama	24/24/24/24	6/6/6/6	0.2	0.1

Panama dùng lịch huấn luyện chính thức của ETTh1, Tetouan dùng của Weather. Với Tetouan, Panama: P, R chọn theo chu kỳ ngày của dữ liệu train (ACF/FFT, phần dư SVD hạng R); p_1, p_2 chọn bằng grid search $\{0.1, \ldots, 0.6\}^2$ theo val loss.

Chỉ số đánh giá

- **Độ chính xác:** MSE và MAE, lấy trung bình trên M cửa sổ của tập test (m: cửa sổ thứ m):

$$\text{MSE} = \frac{1}{MSC} \sum_{m=1}^{M} \sum_{t=1}^{S} \sum_{i=1}^{C} \left(x_{m,L+t}^{(i)} - \hat{x}_{m,L+t}^{(i)} \right)^2$$

$$\text{MAE} = \frac{1}{MSC} \sum_{m=1}^{M} \sum_{t=1}^{S} \sum_{i=1}^{C} \left| x_{m,L+t}^{(i)} - \hat{x}_{m,L+t}^{(i)} \right|$$

- **Hiệu năng**, đo theo cấu hình của TimeBase[38]: Electricity ($C = 321$, $L = S = 720$):
  - **Params**: số tham số; **MACs**: số phép nhân–cộng cho một mẫu.
  - **Epoch Time**: thời gian một epoch huấn luyện; **Infer Time**: dự báo một mẫu trên CPU.

[38] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

Kết quả: MSE / MAE trung bình trên 4 độ dài dự báo

Mô hình	ETTh1		ETTh2		ETTm1		ETTm2		Weather	
	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
DyBAS-Net	0.407±0.002	0.420±0.001	0.356±0.007	0.404±0.006	**0.354±0.003**	**0.381±0.003**	0.252±0.003	0.315±0.003	**0.218±0.000**	0.266±0.001
TimeBase	0.411±0.003	0.420±0.002	0.363±0.003	0.410±0.006	0.367±0.007	0.391±0.005	0.254±0.003	0.317±0.003	0.219±0.000	0.265±0.000
MS-FLOW	0.455±0.013	0.458±0.007	0.363±0.004	0.401±0.003	0.384±0.010	0.399±0.005	0.279±0.005	0.329±0.002	0.231±0.001	**0.260±0.001**
CycleNet/Linear	0.434±0.002	0.443±0.002	0.346±0.001	0.394±0.001	0.358±0.004	0.383±0.003	**0.249±0.001**	**0.312±0.001**	0.237±0.000	0.277±0.000
CycleNet/MLP	0.440±0.006	0.452±0.005	0.365±0.000	0.405±0.000	0.364±0.000	0.391±0.000	0.262±0.001	0.325±0.001	0.226±0.001	0.268±0.001
TQNet	0.434±0.001	0.446±0.001	0.359±0.003	0.401±0.001	0.359±0.003	0.387±0.002	0.264±0.002	0.322±0.001	0.236±0.004	0.275±0.003
GTR	0.433±0.003	0.445±0.002	0.358±0.001	0.401±0.001	0.358±0.005	0.385±0.002	0.262±0.001	0.324±0.000	0.228±0.001	0.269±0.001
SparseTSF [13]	**0.407**	**0.419**	0.344	0.387	0.362	0.384	0.253	0.317	0.244	0.285
TimeMixer [27]	0.454	0.474	0.379	0.426	0.381	0.414	0.283	0.347	0.238	0.281
FITS [28]	0.417	0.430	**0.334**	**0.382**	0.359	0.382	0.252	0.314	0.244	0.286
iTransformer [29]	0.454	0.467	0.392	0.422	0.370	0.401	0.278	0.338	0.233	0.273
PatchTST [11]	0.420	0.440	0.344	0.391	0.355	0.385	0.251	0.319	0.224	0.264
TimesNet [12]	0.505	0.499	0.433	0.455	0.408	0.425	0.299	0.353	0.254	0.293
FEDformer [15]	0.523	0.523	0.429	0.470	0.439	0.466	0.409	0.462	0.355	0.391
Autoformer [30]	0.727	0.641	1.086	0.801	0.564	0.522	0.431	0.463	0.446	0.457
Informer [14]	1.445	0.929	5.486	1.891	1.138	0.818	3.594	1.473	0.567	0.513

Đỏ: μ thấp nhất; xanh: khoảng $[\mu - \sigma, \mu + \sigma]$ chồng lấn với khoảng của mô hình tốt nhất.

Kết quả trên hai bộ dữ liệu phụ tải đa biến công khai

Tetouan ($C = 8$, 10 phút, $P = 144$, $R = 3$) và Panama ($C = 13$, theo giờ, $P = 24$, $R = 6$); $L = 720$. Mọi mô hình tự chạy trong cùng quy trình: $\mu \pm \sigma$ qua 3 seed của MSE/MAE trung bình 4 horizon $S \in \{96, 192, 336, 720\}$. **Đỏ**: μ thấp nhất; xanh: khoảng $\mu \pm \sigma$ chồng lấn với mô hình tốt nhất.

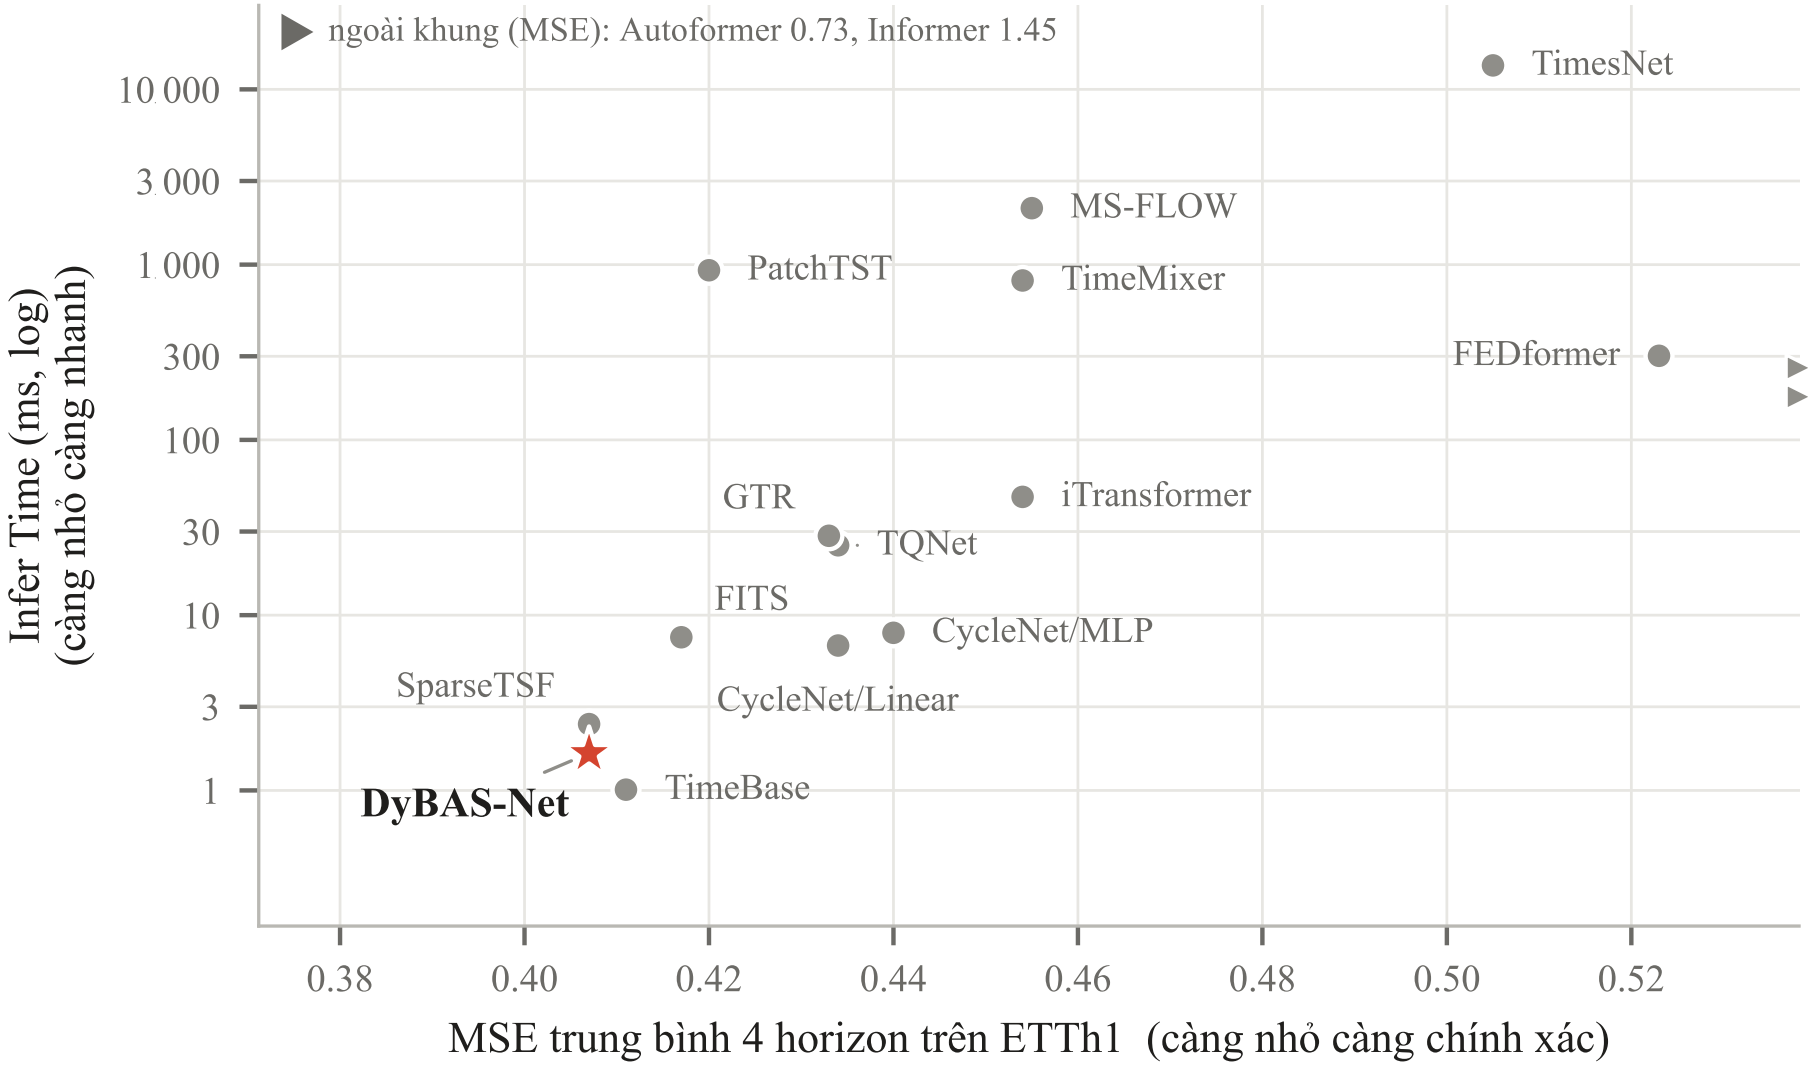
Mô hình	Tetouan		Panama	
	MSE	MAE	MSE	MAE
DyBAS-Net	0.201±0.004	0.259±0.004	0.420±0.002	**0.475±0.002**
TQNet	0.206±0.003	0.270±0.002	**0.418±0.003**	0.476±0.002
CycleNet/Linear	**0.198±0.001**	0.263±0.000	0.426±0.001	0.478±0.001
GTR	0.202±0.001	0.265±0.001	0.424±0.001	0.479±0.001
FITS	0.200±0.000	0.263±0.000	0.426±0.000	0.477±0.000
CycleNet/MLP	0.204±0.000	0.266±0.000	0.429±0.001	0.482±0.000
MS-FLOW	0.208±0.001	**0.252±0.001**	0.426±0.004	0.478±0.002
SparseTSF	0.207±0.000	0.269±0.001	0.435±0.000	0.484±0.000
TimeMixer	0.206±0.002	0.273±0.005	0.447±0.004	0.494±0.002
PatchTST	0.209±0.003	0.275±0.001	0.447±0.003	0.492±0.002
iTransformer	0.224±0.004	0.281±0.002	0.434±0.002	0.486±0.001
TimeBase	0.230±0.000	0.272±0.000	0.444±0.003	0.490±0.002

Hiệu năng tính toán trên cùng một thiết bị

Electricity ($C = 321$), $L = S = 720$. Epoch Time: thời gian một bước huấn luyện (lô 12) $\times$ 1 414 bước. Infer Time: dự báo 1 mẫu trên CPU. Sắp xếp theo Infer Time.

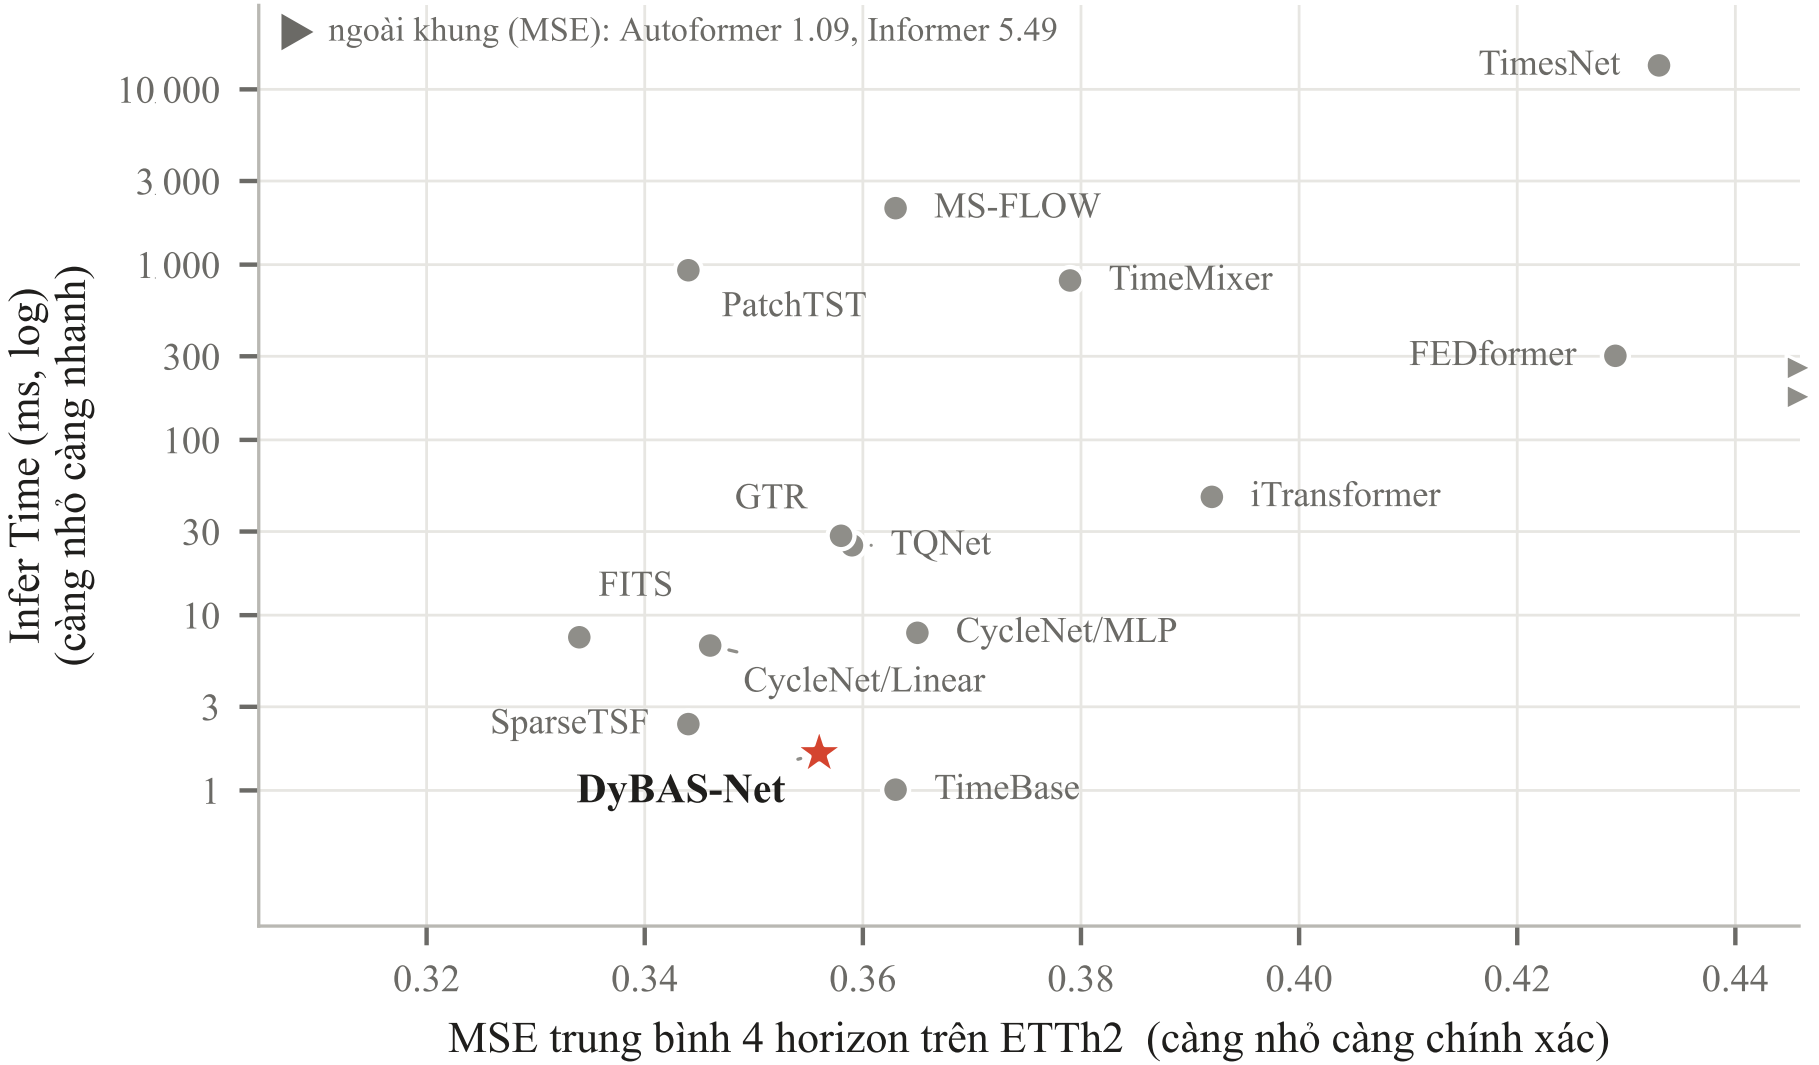
Mô hình	Params	MACs	Epoch Time (s)	Infer Time (ms)	So với DyBAS-Net
TimeBase	0.40K	2.77M	24	1.01	0.62×
DyBAS-Net	190.51K	23.81M	40	1.63	1.00×
SparseTSF	0.93K	12.71M	54	2.39	1.46×
CycleNet/Linear	573.05K	166.41M	74	6.71	4.11×
FITS	133.64K	42.73M	81	7.48	4.58×
CycleNet/MLP	792.44K	236.67M	92	7.93	4.86×
TQNet	3.39M	1.22G	309	25.04	15.35×
GTR	1.84M	582.93M	435	28.37	17.39×
iTransformer	5.47M	2.10G	747	47.30	28.99×
Informer	12.45M	7.91G	2 819	176.13	107.96×
Autoformer	12.14M	8.97G	5 579	257.63	157.91×
FEDformer	18.44M	8.99G	5 080	301.83	185.01×
TimeMixer	5.58M	29.97G	25 557	812.01	497.73×
PatchTST	8.69M	16.08G	76 888	928.74	569.27×
MS-FLOW	17.55M	44.47G	71 191	2 099.54	1 286.92×
TimesNet	151.32M	1081.75G	147 660	13 700.21	8 397.57×

Độ chính xác và tốc độ: ETTh1



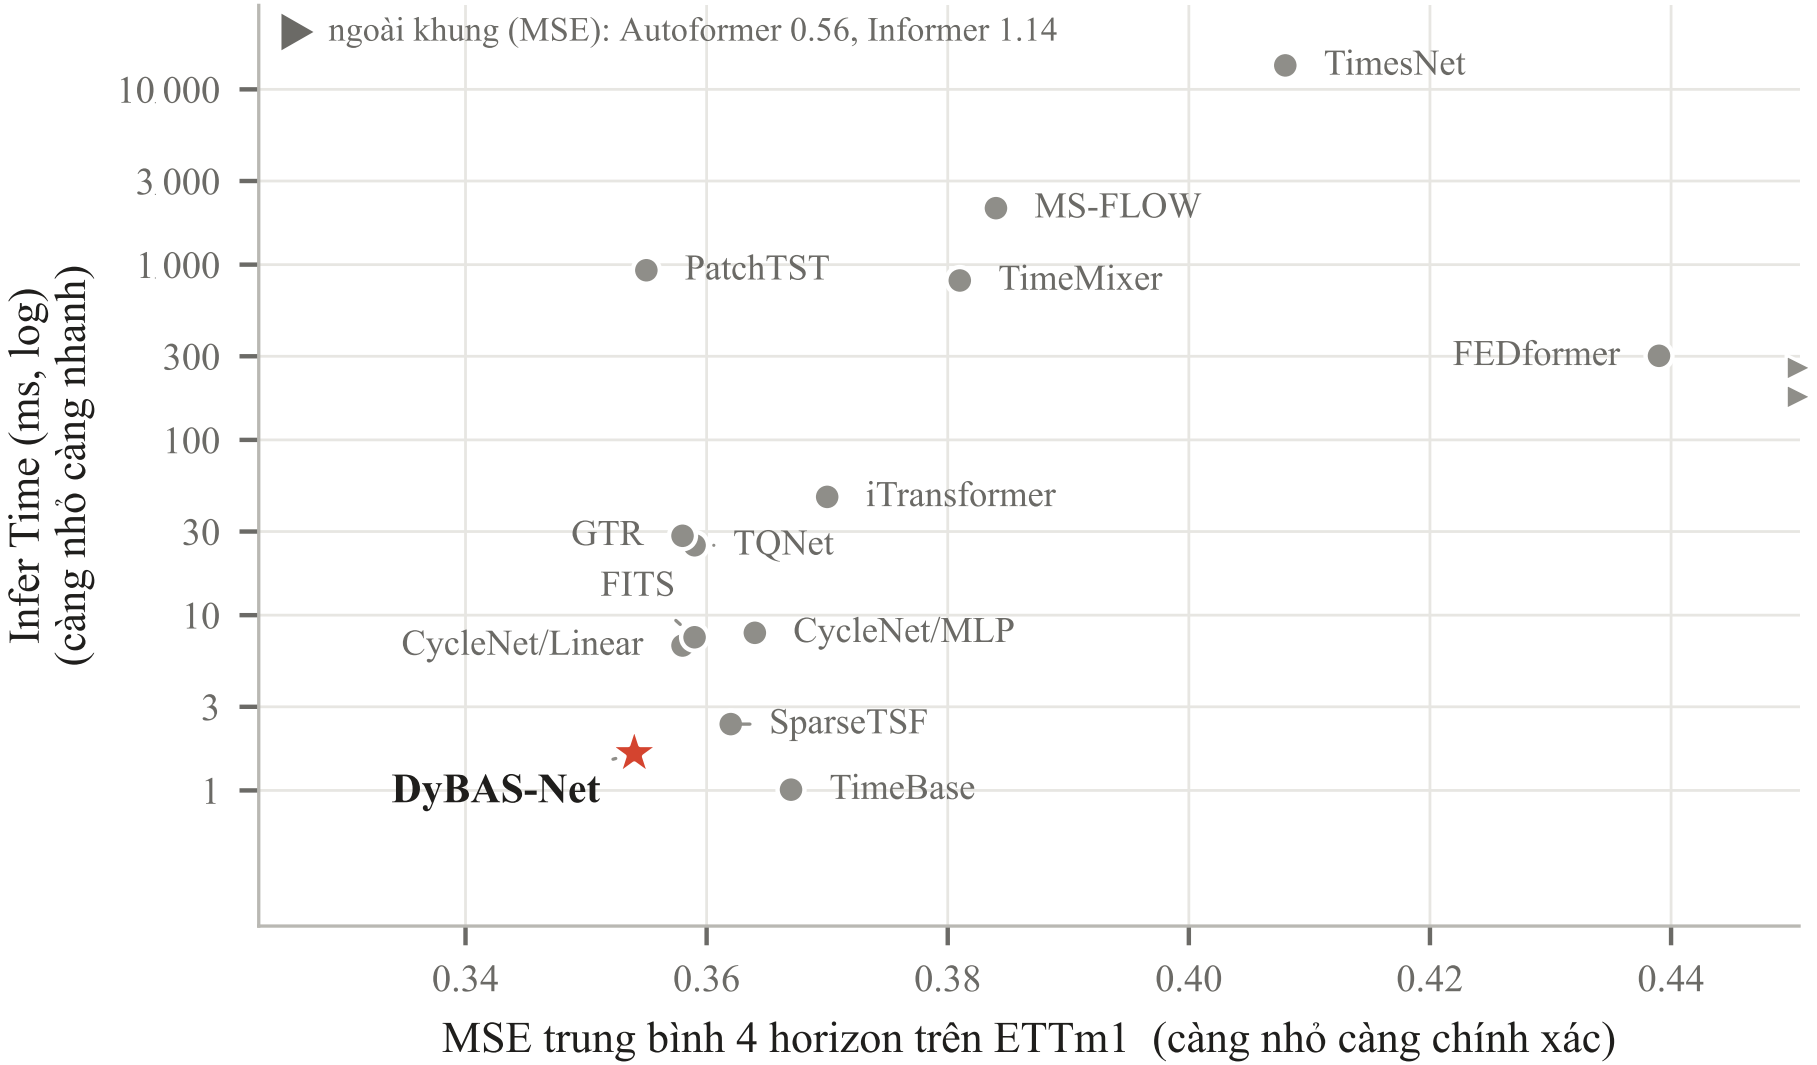
MSE: trung bình 4 horizon trên ETTh1 (như bảng kết quả). Infer Time: đo một lần ở cấu hình Electricity ($C = 321$, $L = S = 720$, như bảng hiệu năng). Góc dưới trái là vừa chính xác vừa nhanh.

Độ chính xác và tốc độ: ETTh2



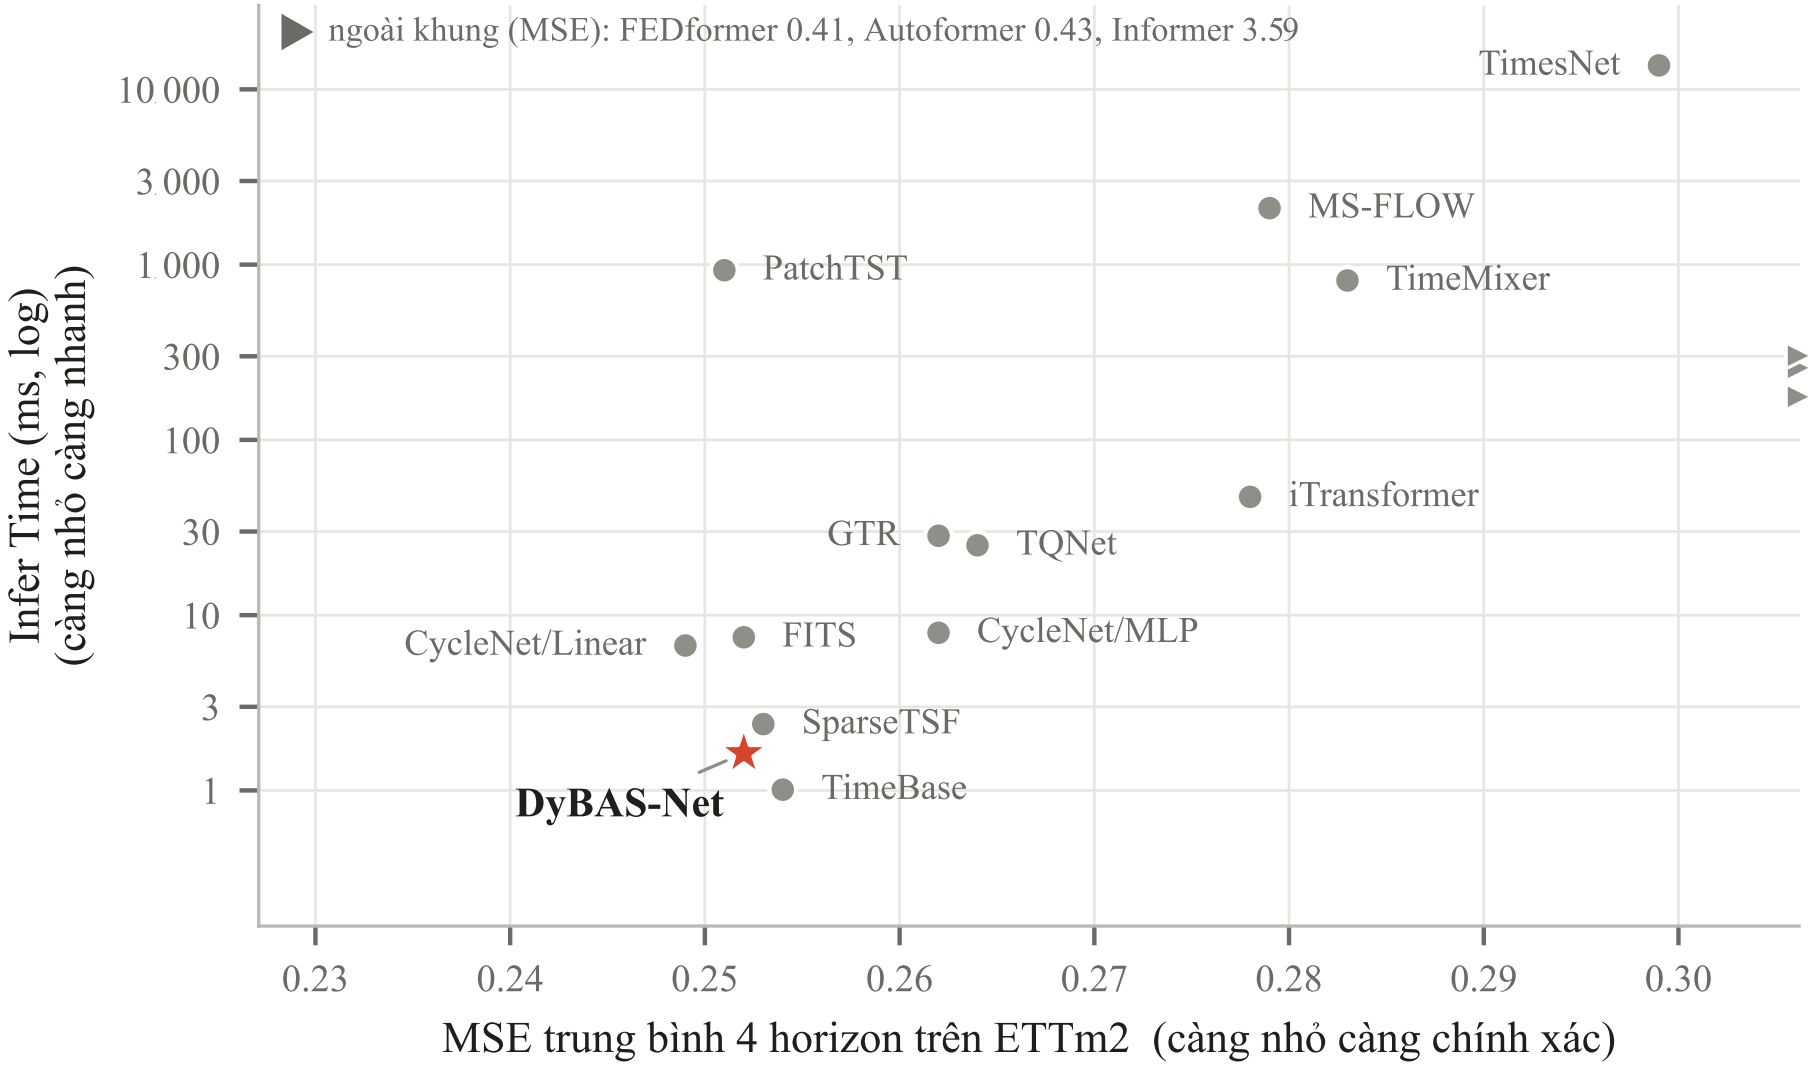
MSE: trung bình 4 horizon trên ETTh2 (như bảng kết quả). Infer Time: đo một lần ở cấu hình Electricity ($C = 321$, $L = S = 720$, như bảng hiệu năng). Góc dưới trái là vừa chính xác vừa nhanh.

Độ chính xác và tốc độ: ETTm1



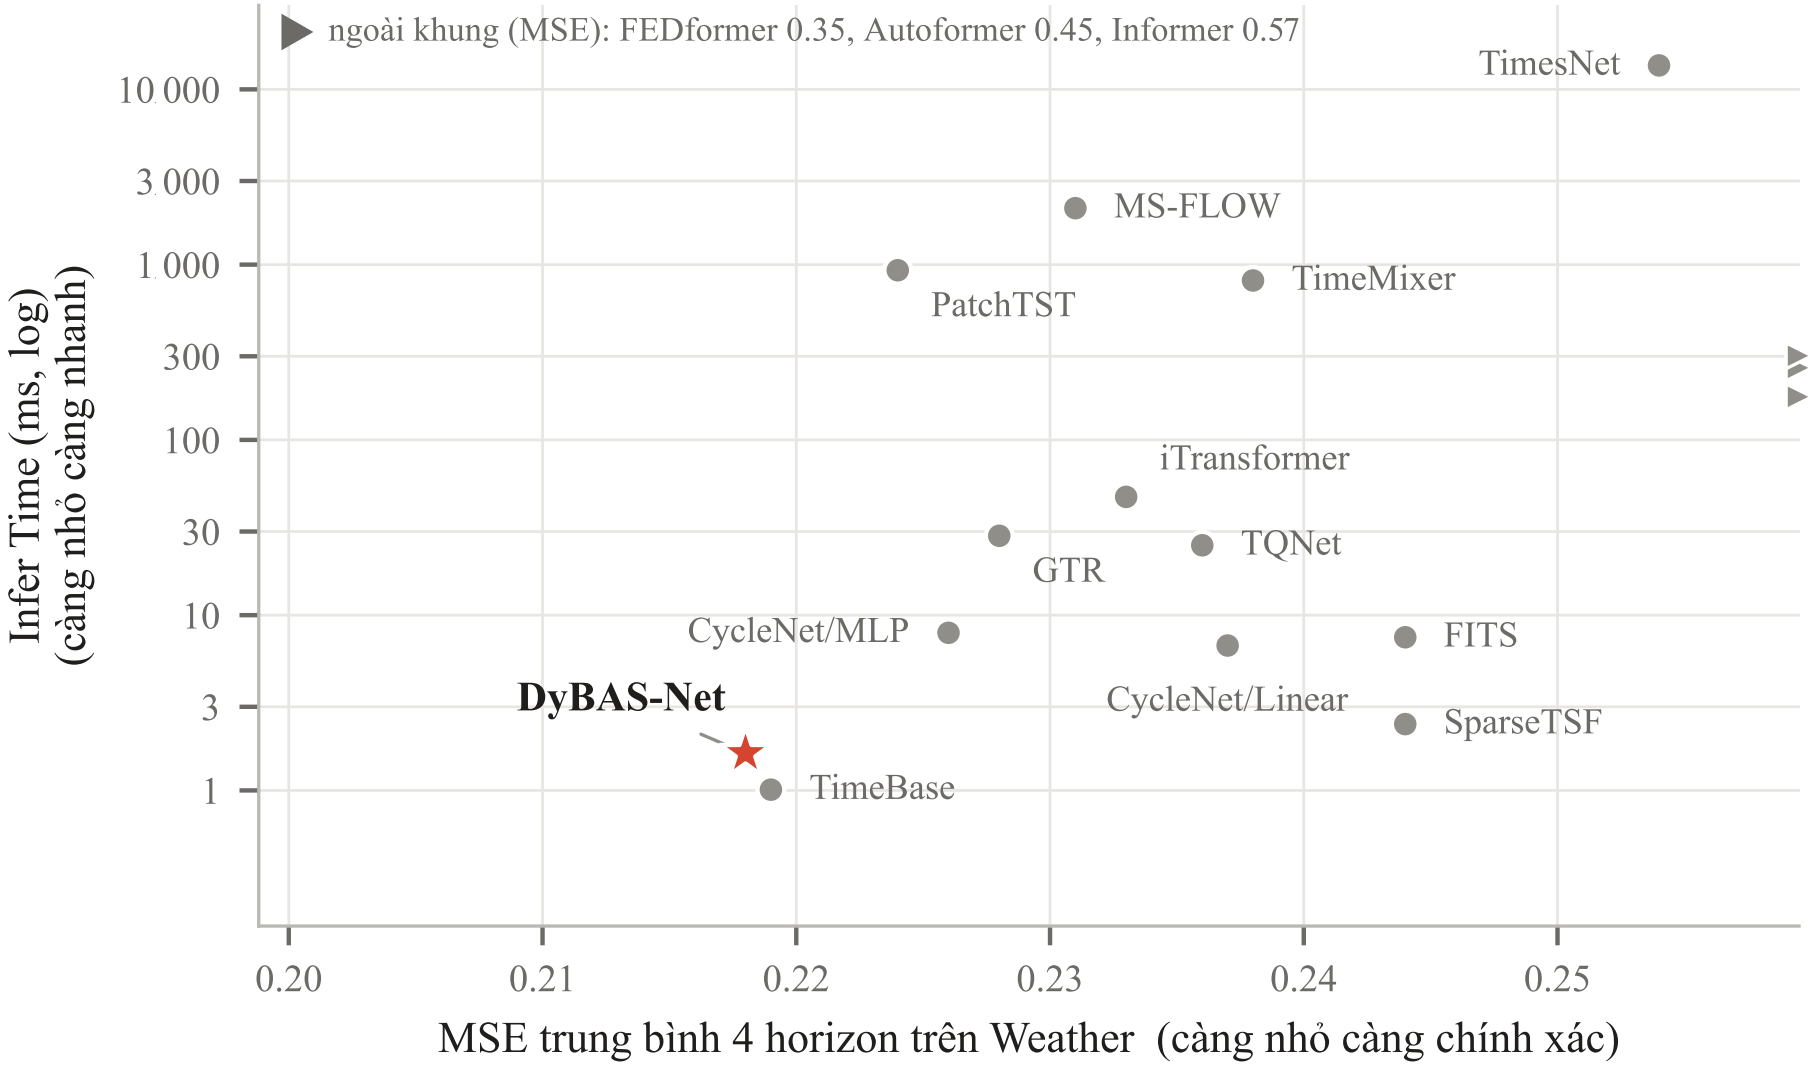
MSE: trung bình 4 horizon trên ETTm1 (như bảng kết quả). Infer Time: đo một lần ở cấu hình Electricity ($C = 321$, $L = S = 720$, như bảng hiệu năng). Góc dưới trái là vừa chính xác vừa nhanh.

Độ chính xác và tốc độ: ETTm2



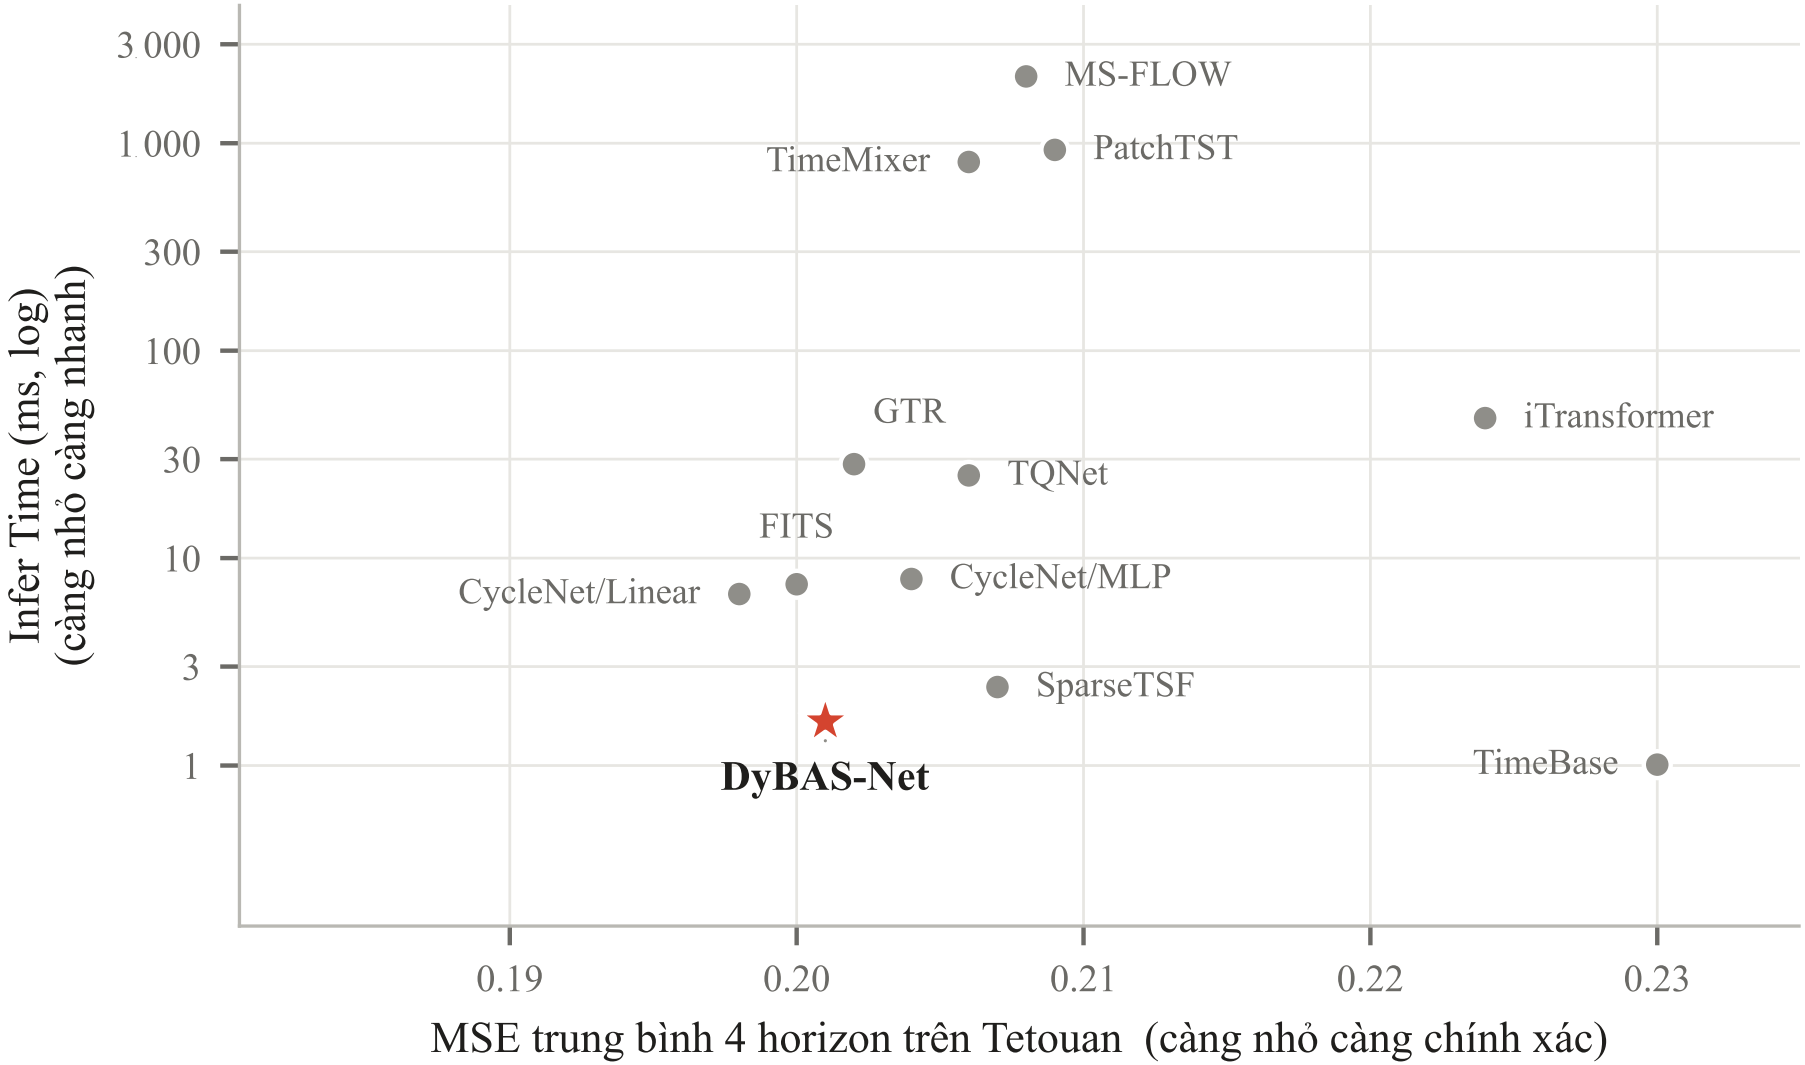
MSE: trung bình 4 horizon trên ETTm2 (như bảng kết quả). Infer Time: đo một lần ở cấu hình Electricity ($C = 321$, $L = S = 720$, như bảng hiệu năng). Góc dưới trái là vừa chính xác vừa nhanh.

Độ chính xác và tốc độ: Weather



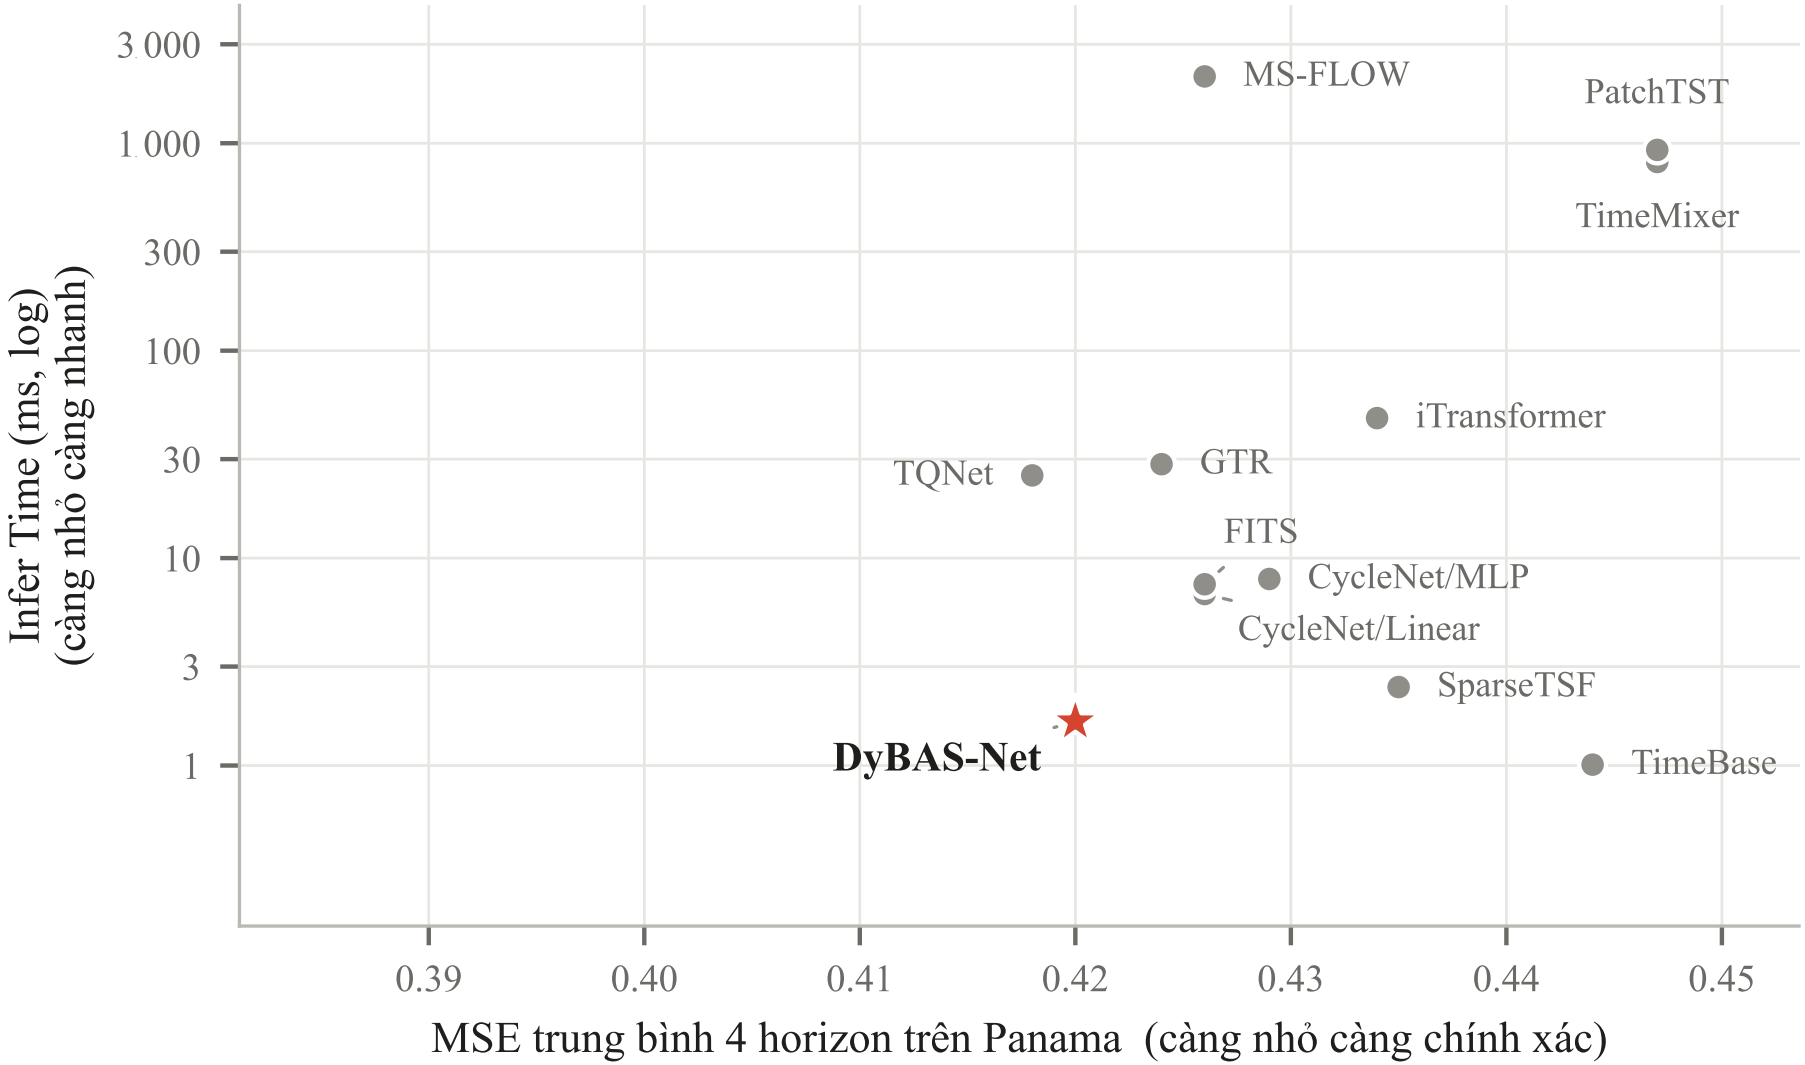
MSE: trung bình 4 horizon trên Weather (như bảng kết quả). Infer Time: đo một lần ở cấu hình Electricity ($C = 321$, $L = S = 720$, như bảng hiệu năng). Góc dưới trái là vừa chính xác vừa nhanh.

Độ chính xác và tốc độ: Tetouan



MSE: trung bình 4 horizon trên Tetouan (như bảng kết quả). Infer Time: đo một lần ở cấu hình Electricity ($C = 321$, $L = S = 720$, như bảng hiệu năng). Góc dưới trái là vừa chính xác vừa nhanh.

Độ chính xác và tốc độ: Panama



MSE: trung bình 4 horizon trên Panama (như bảng kết quả). Infer Time: đo một lần ở cấu hình Electricity ($C = 321$, $L = S = 720$, như bảng hiệu năng). Góc dưới trái là vừa chính xác vừa nhanh.

Nhận xét hiệu năng

- DyBAS-Net **nhanh thứ hai trong 16 mô hình** khi suy luận (1.63 ms một mẫu), chỉ sau TimeBase (1.01 ms).
- Nhanh hơn SparseTSF (2.39 ms), CycleNet/Linear (6.71 ms), FITS (7.48 ms), CycleNet/MLP (7.93 ms), TQNet (25.04 ms, gấp 15 lần) và GTR (28.37 ms, gấp 17 lần).
- So với các mô hình sâu: nhanh hơn iTransformer ∼29 lần, TimeMixer ∼500 lần, PatchTST ∼570 lần, MS-FLOW ∼1 300 lần, TimesNet hơn 8 000 lần.
- Huấn luyện nhẹ: 40 s một epoch.

Nguyên nhân

Biến đổi theo trục thời gian chạy trên N, R, P (vài chục) thay vì L, S (hàng trăm); không có attention.

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
4. Kết luận
5. Tài liệu tham khảo

Kết luận

- **Đề xuất DyBAS-Net:** kết hợp dự báo theo đoạn dựa trên thành phần cơ sở (TimeBase) với học phụ thuộc chéo có điều chuẩn thưa (CrossVBlock, DropFusion, IntraVBlock của DyTimeNet), đặt trong *không gian cơ sở*.
- **Rất nhẹ:** 23.8M MACs, 1.63 ms một mẫu trên CPU ở cấu hình Electricity; nhanh thứ hai trong 16 mô hình, nhanh hơn TQNet 15 lần và nhanh hơn iTransformer, TimeMixer, PatchTST, TimesNet từ 29 đến hơn 8 000 lần.
- **Nhánh trộn biến có ích:** so với TimeBase cùng quy trình, giảm MSE trung bình trên cả 5/5 bộ dữ liệu (tới 3.7% trên ETTm1).

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
4. Kết luận
5. Tài liệu tham khảo

Tài liệu tham khảo I

[1] Tao Hong and Shu Fan. "Probabilistic electric load forecasting: A tutorial review". In: *International Journal of Forecasting* 32.3 (2016), pp. 914–938. DOI: 10.1016/j.ijforecast.2015.11.011.

[2] Jongseon Kim et al. "A comprehensive survey of deep learning for time series forecasting: architectural diversity and open challenges". In: *Artificial Intelligence Review* 58 (2025), p. 216. DOI: 10.1007/s10462-025-11223-9.

[3] Qihe Huang et al. "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting". In: *Proceedings of the 42nd International Conference on Machine Learning*. Vol. 267. Proceedings of Machine Learning Research. 2025, pp. 26227–26246.

[4] Fanpu Cao et al. "Enhancing Multivariate Time Series Forecasting with Global Temporal Retrieval". In: *The Fourteenth International Conference on Learning Representations*. 2026.

[5] Shengsheng Lin et al. "CycleNet: Enhancing Time Series Forecasting through Modeling Periodic Patterns". In: *Advances in Neural Information Processing Systems*. Vol. 37. 2024.

[6] Lu Han, Han-Jia Ye, and De-Chuan Zhan. "The Capacity and Robustness Trade-off: Revisiting the Channel Independent Strategy for Multivariate Time Series Forecasting". In: *IEEE Transactions on Knowledge and Data Engineering* 36.11 (2024), pp. 7129–7142. DOI: 10.1109/TKDE.2024.3400008.

[7] Xiangfei Qiu et al. "DUET: Dual Clustering Enhanced Multivariate Time Series Forecasting". In: *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2025, pp. 1185–1196. DOI: 10.1145/3690624.3709325.

[8] Fan Zhang, Shiming Fan, and Hua Wang. "What If We Let Forecasting Forget? A Sparse Bottleneck for Cross-Variable Dependencies". In: *Proceedings of the 43rd International Conference on Machine Learning*. Vol. 306. Proceedings of Machine Learning Research. 2026.

[9] Shengsheng Lin et al. "Temporal Query Network for Efficient Multivariate Time Series Forecasting". In: *Proceedings of the 42nd International Conference on Machine Learning*. Vol. 267. Proceedings of Machine Learning Research. 2025, pp. 37797–37814.

[10] Ting Chen et al. "DyTimeNet: Dynamic cross-variable dependency network with sparse strategy for multivariate time series forecasting". In: *Neurocomputing* 676 (2026), p. 132964. DOI: 10.1016/j.neucom.2026.132964.

Tài liệu tham khảo II

[11] Yuqi Nie et al. "A Time Series is Worth 64 Words: Long-term Forecasting with Transformers". In: *The Eleventh International Conference on Learning Representations*. 2023.

[12] Haixu Wu et al. "TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis". In: *The Eleventh International Conference on Learning Representations*. 2023.

[13] Shengsheng Lin et al. "SparseTSF: Modeling Long-term Time Series Forecasting with 1k Parameters". In: *Proceedings of the 41st International Conference on Machine Learning*. 2024, pp. 30211–30226.

[14] Haoyi Zhou et al. "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting". In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 35. 2021, pp. 11106–11115.

[15] Tian Zhou et al. "FEDformer: Frequency Enhanced Decomposed Transformer for Long-term Series Forecasting". In: *Proceedings of the 39th International Conference on Machine Learning*. Vol. 162. Proceedings of Machine Learning Research. 2022, pp. 27268–27286.

[16] Yushu Chen et al. "A Joint Time-Frequency Domain Transformer for multivariate time series forecasting". In: *Neural Networks* 176 (2024), p. 106334. DOI: 10.1016/j.neunet.2024.106334.

[17] Himanshu Nagpal et al. "An adaptive multi-seasonal ARIMA approach for domestic hot water load forecasting: A pilot study". In: *Energy and Buildings* 347 (2025), p. 116226. DOI: 10.1016/j.enbuild.2025.116226.

[18] Eric Augusto Melchor Cruz, Luis Alberto Hernández Armenta, and Mohamed Badaoui. "Seasonal forecasting of peak electricity demand using spectral analysis". In: *Results in Engineering* 28 (2025), p. 107338. DOI: 10.1016/j.rineng.2025.107338.

[19] Hyunji Moon, Hyeonseop Lee, and Bomi Song. "Mixed pooling of seasonality for time series forecasting: An application to pallet transport data". In: *Expert Systems with Applications* 201 (2022), p. 117195. DOI: 10.1016/j.eswa.2022.117195.

[20] David Salinas et al. "DeepAR: Probabilistic forecasting with autoregressive recurrent networks". In: *International Journal of Forecasting* 36.3 (2020), pp. 1181–1191. DOI: 10.1016/j.ijforecast.2019.07.001.

Tài liệu tham khảo III

[21] Bryan Lim et al. "Temporal Fusion Transformers for interpretable multi-horizon time series forecasting". In: *International Journal of Forecasting* 37.4 (2021), pp. 1748–1764. DOI: 10.1016/j.ijforecast.2021.03.012.

[22] Dongyuan Li et al. "Routing Channel-Patch Dependencies in Time Series Forecasting with Graph Spectral Decomposition". In: *The Fourteenth International Conference on Learning Representations*. 2026.

[23] Mingyuan Xia et al. "TimeEmb: A Lightweight Static-Dynamic Disentanglement Framework for Time Series Forecasting". In: *Advances in Neural Information Processing Systems*. Vol. 38. 2025.

[24] Yihang Wang et al. "LightGTS: A Lightweight General Time Series Forecasting Model". In: *Proceedings of the 42nd International Conference on Machine Learning*. Vol. 267. Proceedings of Machine Learning Research. 2025, pp. 64109–64126.

[25] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. "Layer Normalization". In: *arXiv preprint arXiv:1607.06450* (2016).

[26] Dan Hendrycks and Kevin Gimpel. "Gaussian Error Linear Units (GELUs)". In: *arXiv preprint arXiv:1606.08415* (2016).

[27] Shiyu Wang et al. "TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting". In: *The Twelfth International Conference on Learning Representations*. 2024.

[28] Zhijian Xu, Ailing Zeng, and Qiang Xu. "FITS: Modeling Time Series with 10k Parameters". In: *The Twelfth International Conference on Learning Representations*. 2024.

[29] Yong Liu et al. "iTransformer: Inverted Transformers Are Effective for Time Series Forecasting". In: *The Twelfth International Conference on Learning Representations*. 2024.

[30] Haixu Wu et al. "Autoformer: Decomposition Transformers with Auto-Correlation for Long-term Series Forecasting". In: *Advances in Neural Information Processing Systems*. Vol. 34. 2021, pp. 22419–22430.