DyBAS-Net: Kết hợp học quan hệ động giữa các biến và dự báo theo đoạn dựa trên thành phần cơ sở cho chuỗi thời gian đa biến

Giảng viên hướng dẫn: PGS. TS. Nguyễn Thị Ngọc Anh
Sinh viên thực hiện: Nguyễn Hải Long
Mã số sinh viên: 20237355

Hà Nội, 10/2026

Nội dung chính

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
   - Nghiên cứu loại bỏ
4. Kết luận
5. Tài liệu tham khảo

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
   - Nghiên cứu loại bỏ
4. Kết luận
5. Tài liệu tham khảo

Bài toán dự báo dài hạn chuỗi thời gian đa biến

- **Bài toán:** từ L bước quá khứ của C biến, dự báo đồng thời S bước tương lai của cả C biến (năng lượng, thời tiết, giao thông...).
- **Xu hướng hiện nay:** dùng cửa sổ quá khứ rất dài ($L = 720$) để nắm phụ thuộc dài hạn, kéo theo số tham số và khối lượng tính toán tăng mạnh. Ví dụ, với Electricity ($L = S = 720$)[1]:
  - PatchTST: 8.69M tham số, 14.17G phép nhân–cộng (MACs) cho một mẫu.
  - TimeMixer: 30.30G MACs cho một mẫu.
- **Hai yêu cầu cần đáp ứng cùng lúc:**
  - *Nhẹ và nhanh*, để triển khai được trên thiết bị hạn chế tài nguyên.
  - *Khai thác quan hệ giữa các biến*, vì các biến trong hệ thống thực ảnh hưởng lẫn nhau.

[1] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

Đặc điểm 1: Tính lặp lại và hạng thấp

- **Tương đồng theo chu kỳ:** các đoạn dài một chu kỳ (ví dụ mỗi ngày) có hình dạng rất giống nhau, với hệ số tương quan Pearson giữa các đoạn cao[2].
- **Xấp xỉ hạng thấp:** khi xếp các đoạn thành ma trận, các giá trị suy biến giảm rất nhanh trên ETTh1, ETTh2, ETTm1, ETTm2, Weather, Electricity, Traffic. Thông tin tập trung ở một vài thành phần, phần còn lại là dư thừa.
- **Hệ quả:** không nhất thiết phải mô hình hóa từng điểm thời gian. TimeBase chỉ dùng **0.39K tham số**, ít hơn DLinear hơn 2.6×10^3 lần về tham số và 120 lần về MACs, mà vẫn đạt độ chính xác cạnh tranh.

Dự báo trên **một vài "đoạn đại diện"** thay vì trên L điểm thời gian.

[2] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

Đặc điểm 2: Phụ thuộc chéo giữa các biến

- Các phương pháp chia làm hai nhóm theo cách xử lý biến[3]:
  - **Độc lập kênh (CI)** (PatchTST, DLinear, TimeBase): mỗi biến dự báo riêng, bỏ qua các quan hệ hiệp biến quan trọng.
  - **Phụ thuộc kênh (CD)** (iTransformer, DyTimeNet): học mọi phụ thuộc mà không phân biệt, đưa thêm nhiễu và giảm khả năng khái quát[4].
- **Mức phụ thuộc khác nhau theo miền dữ liệu:** biến khí hậu có ràng buộc vật lý tự nhiên với nhau, còn mức tiêu thụ điện của từng hộ gần như độc lập.
- **Phụ thuộc chéo thay đổi theo thời gian và thưa:** DyTimeNet dùng chiến lược thưa *DropFusion* để giảm thông tin dư thừa khi học quan hệ liên biến[5].

[3] Han, Ye, and Zhan (2024): "The Capacity and Robustness Trade-off: Revisiting the Channel Independent Strategy for Multivariate Time Series Forecasting".

[4] Hu et al. (2025): "TimeFilter: Patch-Specific Spatial-Temporal Graph Filtration for Time Series Forecasting".

[5] Chen et al. (2026): "DyTimeNet: Dynamic cross-variable dependency network with sparse strategy for multivariate time series forecasting".

Khoảng trống nghiên cứu

Nhóm mô hình	Ví dụ	Rất nhẹ	Học quan hệ liên biến
Tuyến tính theo đoạn / tần số, CI	TimeBase, SparseTSF, FITS	✓	×
Transformer	PatchTST, iTransformer	×	một phần
Đồ thị, lọc phụ thuộc theo patch	TimeFilter	×	✓
MLP trộn kênh trên chuỗi gốc (chi phí theo L, S)	DyTimeNet	×	✓

- TimeBase giả định các biến *đồng nhất* nên dùng chiến lược độc lập kênh[6].
- TimeFilter dựng đồ thị trên $n = C \times N$ nút (biến, patch); ma trận khoảng cách có kích thước $n \times n$[7].

Khoảng trống

Chưa có mô hình vừa giữ chi phí siêu nhẹ của dự báo theo đoạn, vừa học được phụ thuộc chéo có điều chuẩn thưa.

[6] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

[7] Hu et al. (2025): "TimeFilter: Patch-Specific Spatial-Temporal Graph Filtration for Time Series Forecasting".

Mục đích nghiên cứu

Đề xuất mô hình **DyBAS-Net** (**Dy**namic cross-variable dependency on **BAS**is components), kết hợp hai hướng tiếp cận:

- **Xương sống dự báo theo đoạn:** phân đoạn theo chu kỳ, trích xuất R thành phần cơ sở và dự báo theo đoạn, kế thừa từ TimeBase[8].
- **Học phụ thuộc chéo trong không gian cơ sở:** đưa CrossVBlock với chiến lược DropFusion và IntraVBlock của DyTimeNet[9] vào xử lý $P \cdot R$ hệ số cơ sở của mỗi biến, thay vì L điểm thời gian.
- **Hiệu chỉnh có kiểm soát:** nhánh trộn kênh chỉ cộng một lượng hiệu chỉnh vào các thành phần cơ sở, được khởi tạo bằng 0.
- **Đánh giá toàn diện:** 5 bộ dữ liệu, so sánh với 11 mô hình về độ chính xác và chi phí tính toán trên *cùng một thiết bị*, kèm nghiên cứu loại bỏ (ablation).

[8] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

[9] Chen et al. (2026): "DyTimeNet: Dynamic cross-variable dependency network with sparse strategy for multivariate time series forecasting".

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
   - Nghiên cứu loại bỏ
4. Kết luận
5. Tài liệu tham khảo

Input

Dữ liệu tập train $\mathcal{X}_{train} \in \mathbb{R}^{L \times C}$: Chuỗi lịch sử độ dài L của C biến $X^{(i)}$ với $i = \overline{1, C}$.

$$\mathcal{X}_{train} = \begin{bmatrix} x_1^{(1)} & x_1^{(2)} & \cdots & x_1^{(C)} \\ x_2^{(1)} & x_2^{(2)} & \cdots & x_2^{(C)} \\ \vdots & \vdots & \ddots & \vdots \\ x_L^{(1)} & x_L^{(2)} & \cdots & x_L^{(C)} \end{bmatrix}$$

Định nghĩa thành phần:

- $x_t^{(i)}$: Giá trị của biến $X^{(i)}$ tại thời điểm t.
- $i = \overline{1, C}$: Chỉ số biến.
- $t = \overline{1, L}$: Chỉ số mốc thời gian.

Dữ liệu tập test $\mathcal{X}_{test} \in \mathbb{R}^{S \times C}$: Giá trị thực tế trong S bước tiếp theo:

$$\mathcal{X}_{test} = \begin{bmatrix} x_{L+1}^{(1)} & x_{L+1}^{(2)} & \cdots & x_{L+1}^{(C)} \\ \vdots & \vdots & \ddots & \vdots \\ x_{L+S}^{(1)} & x_{L+S}^{(2)} & \cdots & x_{L+S}^{(C)} \end{bmatrix}$$

Output và Hàm mục tiêu

- **Ma trận kết quả dự báo ($\hat{\mathcal{X}} \in \mathbb{R}^{S \times C}$):** được ước lượng đồng thời bởi mô hình $\mathcal{F}$ (**DyBAS-Net**):

$$\hat{\mathcal{X}} = \mathcal{F}(\mathcal{X}_{train})$$

- **Sai số dự báo (MSE):**

$$\mathcal{L}_{MSE} = \frac{1}{S \times C} \sum_{t=1}^{S} \sum_{i=1}^{C} \left(x_{L+t}^{(i)} - \hat{x}_{L+t}^{(i)} \right)^2$$

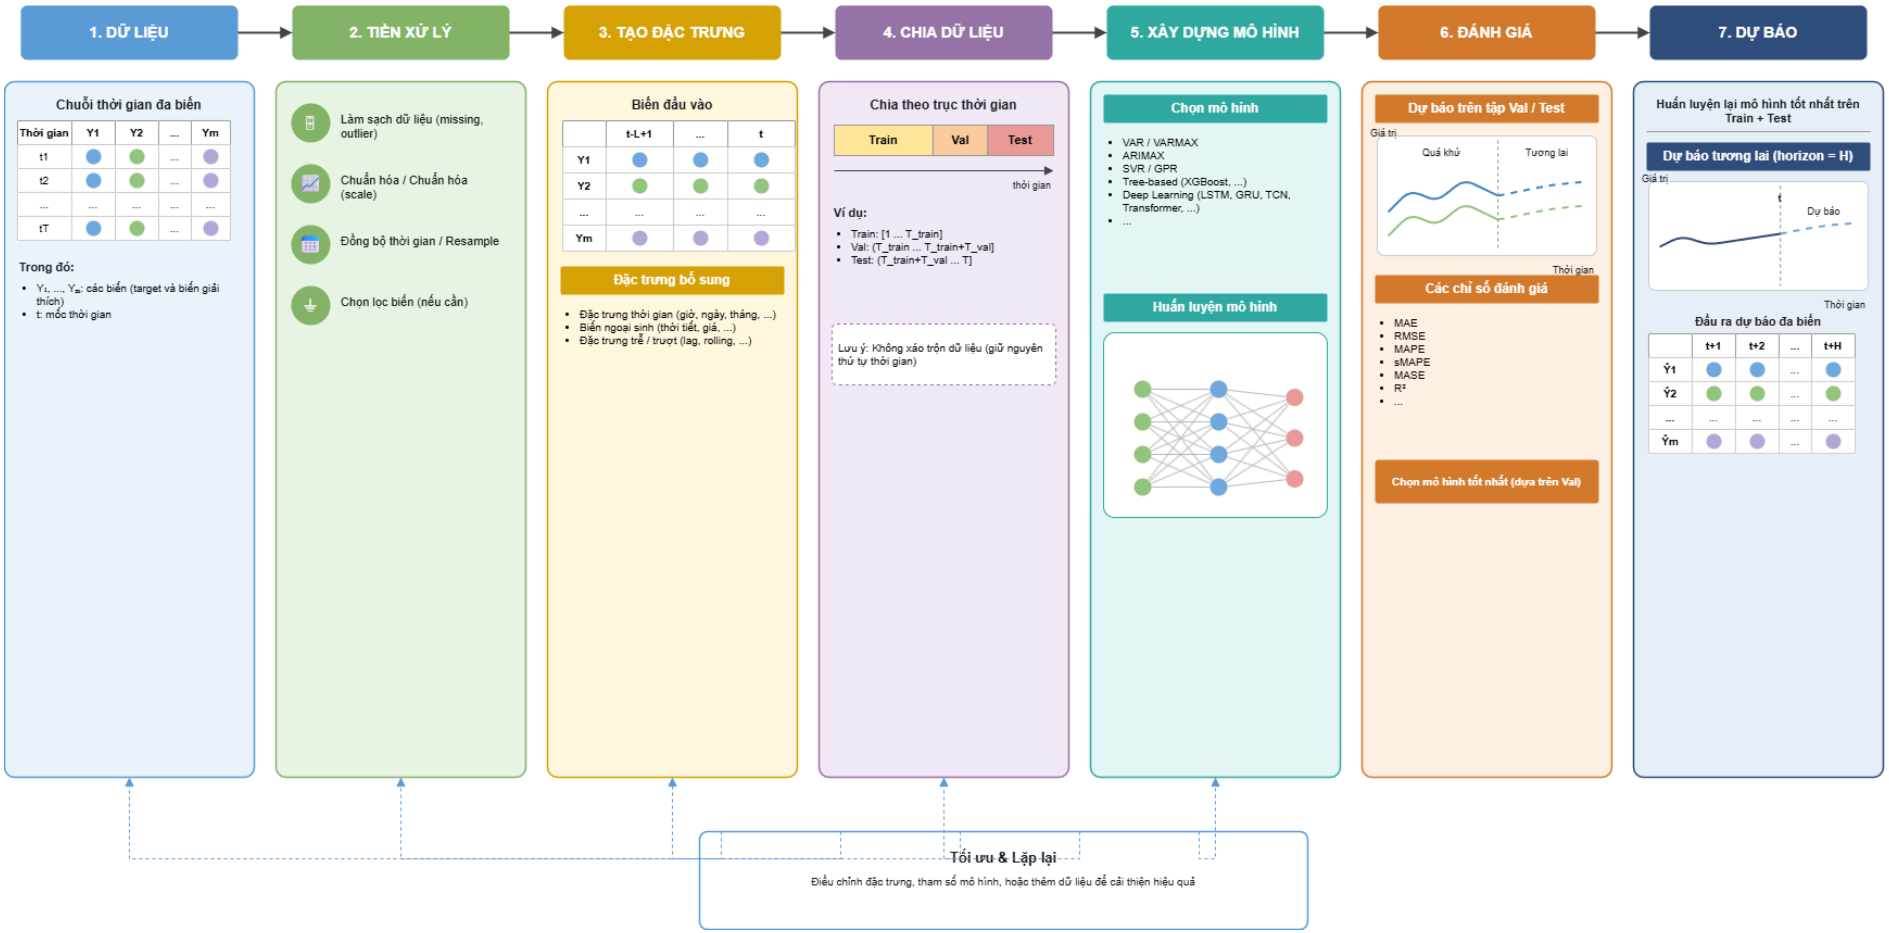
- **Hàm mục tiêu khi huấn luyện:** thêm ràng buộc trực giao trên các thành phần cơ sở (trình bày ở bước 3):

$$\mathcal{L} = \mathcal{L}_{MSE} + \lambda_{orth} \mathcal{L}_{orth}, \qquad \lambda_{orth} \geq 0$$

Các kích thước sử dụng trong mô hình

Ký hiệu	Ý nghĩa	ETTh1 ($L = 720$, $S = 96$)
P	Độ dài một đoạn (chu kỳ)	24 (một ngày)
$N = \lceil L/P \rceil$	Số đoạn quá khứ	30 ngày
$N' = \lceil S/P \rceil$	Số đoạn tương lai	4 ngày
$R \ll N$	Số thành phần cơ sở	6
D	Số chiều ẩn của nhánh trộn kênh	64
$C' = \lfloor 0.75\, C \rfloor$	Số chiều nút thắt của CrossVBlock	5
$D_{ff} = 2D$	Số chiều ẩn của FFN trong IntraVBlock	128

Kiến trúc cơ bản của các mô hình dự báo CTG



Tổng quan các bước của DyBAS-Net

1. **Phân đoạn theo chu kỳ:** cắt chuỗi dài L thành N đoạn dài P.
2. **Chuẩn hóa theo pha:** trừ trung bình của từng pha trong chu kỳ.
3. **Trích xuất cơ sở:** nén N đoạn thành R thành phần cơ sở $\mathrm{E}^{(i)}$.
4. **Mã hóa hệ số cơ sở** của mỗi biến thành vector D chiều.
5. **CrossVBlock + DropFusion:** trộn thông tin giữa các biến.
6. **IntraVBlock:** biến đổi phi tuyến trong từng biến.
7. **Chiếu ngược:** sinh lượng hiệu chỉnh $\Delta\mathrm{E}^{(i)}$, cộng vào cơ sở.
8. **Dự báo theo đoạn và khôi phục:** sinh N' đoạn tương lai, cộng lại trung bình theo pha.

Các bước 1–3 và 8 xử lý *từng biến riêng*; chỉ bước 5 trao đổi thông tin giữa các biến.

1. Phân đoạn theo chu kỳ

Chuỗi của biến i, $\mathrm{x}^{(i)} = (x_1^{(i)}, \ldots, x_L^{(i)})$, được xếp thành **ma trận đoạn** $\mathrm{X}^{(i)} \in \mathbb{R}^{P \times N}$, mỗi cột là một đoạn dài P:

$$\mathrm{X}^{(i)} = \begin{bmatrix} x_1^{(i)} & x_{P+1}^{(i)} & \cdots & x_{(N-1)P+1}^{(i)} \\ x_2^{(i)} & x_{P+2}^{(i)} & \cdots & x_{(N-1)P+2}^{(i)} \\ \vdots & \vdots & \ddots & \vdots \\ x_P^{(i)} & x_{2P}^{(i)} & \cdots & x_{NP}^{(i)} \end{bmatrix}, \qquad \left[\mathrm{X}^{(i)}\right]_{p,n} = x_{(n-1)P+p}^{(i)}$$

- **Cột** n: đoạn thứ n (ví dụ ngày thứ n). **Hàng** p: cùng một pha (ví dụ cùng một giờ) qua N chu kỳ.
- Ví dụ ETTh1: $L = 720$, $P = 24 \Rightarrow N = 30$ cột, mỗi cột là một ngày.
- Nếu L không chia hết cho P, chuỗi được đệm thêm ở đầu cho đủ $N \cdot P$ điểm.

2. Chuẩn hóa theo pha (Period Normalization)

- **Trung bình theo pha:** trung bình của từng hàng (từng pha) qua N đoạn:

$$\mu_p^{(i)} = \frac{1}{N}\sum_{n=1}^{N} \left[\mathrm{X}^{(i)}\right]_{p,n}, \qquad \boldsymbol{\mu}^{(i)} = (\mu_1^{(i)}, \ldots, \mu_P^{(i)})^\top \in \mathbb{R}^P$$

- **Trừ trung bình:**

$$\left[\tilde{\mathrm{X}}^{(i)}\right]_{p,n} = \left[\mathrm{X}^{(i)}\right]_{p,n} - \mu_p^{(i)} \qquad \Longleftrightarrow \qquad \tilde{\mathrm{X}}^{(i)} = \mathrm{X}^{(i)} - \boldsymbol{\mu}^{(i)} 1_N^\top$$

- **Ý nghĩa:** $\boldsymbol{\mu}^{(i)}$ là "đoạn trung bình" của biến i (ví dụ ban ngày phụ tải cao hơn ban đêm). Các bước sau chỉ học phần dao động quanh nó.
- Khác RevIN[10] trong DyTimeNet: trừ trung bình *theo từng pha*, không chia độ lệch chuẩn. $\boldsymbol{\mu}^{(i)}$ được giữ lại để cộng trả ở bước cuối.

[10] Kim et al. (2022): "Reversible Instance Normalization for Accurate Time-Series Forecasting against Distribution Shift".

3. Trích xuất thành phần cơ sở (Basis Extraction)

- Ánh xạ tuyến tính **dùng chung cho mọi biến** nén N đoạn thành R thành phần cơ sở ($\mathrm{W}_B \in \mathbb{R}^{N\times R}$, $\mathrm{b}_B \in \mathbb{R}^R$ học được):

$$\mathrm{E}^{(i)} = \tilde{\mathrm{X}}^{(i)}\,\mathrm{W}_B + 1_P\,\mathrm{b}_B^\top \quad \in \mathbb{R}^{P\times R}$$

- **Cột thứ r của** $\mathrm{E}^{(i)}$ là tổ hợp tuyến tính của N đoạn quá khứ $\tilde{\mathrm{x}}_n^{(i)}$, tức một "đoạn đại diện":

$$\mathrm{e}_r^{(i)} = \sum_{n=1}^{N} [\mathrm{W}_B]_{n,r}\,\tilde{\mathrm{x}}_n^{(i)} + [\mathrm{b}_B]_r \quad \in \mathbb{R}^P$$

- **Ý nghĩa:** tóm $N = 30$ ngày thành $R = 6$ "ngày điển hình", dựa trên tính hạng thấp của chuỗi dài[11].

[11] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

3. Ràng buộc trực giao trên các thành phần cơ sở

- **Ma trận Gram:** tích vô hướng giữa từng cặp thành phần cơ sở

$$\mathrm{G}^{(i)} = \mathrm{E}^{(i)\top}\mathrm{E}^{(i)} \in \mathbb{R}^{R\times R}, \qquad \left[\mathrm{G}^{(i)}\right]_{r,s} = \langle \mathrm{e}_r^{(i)}, \mathrm{e}_s^{(i)} \rangle$$

- **Phạt phần ngoài đường chéo** (trung bình trên B mẫu của một lô và C biến):

$$\mathcal{L}_{orth} = \frac{1}{B\,C}\sum_{b=1}^{B}\sum_{i=1}^{C}\left\|\mathrm{G}_b^{(i)} - \mathrm{diag}\left(\mathrm{G}_b^{(i)}\right)\right\|_F$$

- $\mathcal{L}_{orth} = 0$ khi các thành phần cơ sở đôi một trực giao, nên mỗi thành phần mang một kiểu biến thiên riêng, không trùng lặp.
- Chỉ dùng khi huấn luyện; khi đánh giá chỉ đo MSE và MAE.

Ghi chú: bài báo TimeBase viết $\|\cdot\|_F^2$; mô hình này cài đặt theo mã nguồn chính thức của TimeBase, dùng $\|\cdot\|_F$.

4. Mã hóa hệ số cơ sở (Basis Encoding)

- **Làm phẳng:** trải $\mathrm{E}^{(i)}$ theo hàng thành vector, rồi ghép C biến thành ma trận:

$$\mathrm{e}^{(i)} = \mathrm{vec}\left(\mathrm{E}^{(i)}\right) \in \mathbb{R}^{PR}, \qquad \bar{\mathrm{E}} = \left[\mathrm{e}^{(1)}, \ldots, \mathrm{e}^{(C)}\right] \in \mathbb{R}^{PR \times C}$$

- **Mã hóa:** chiếu tuyến tính xuống không gian ẩn D chiều:

$$\mathcal{X}_{enc} = \mathrm{W}_{enc}^{\top} \bar{\mathrm{E}} + \mathrm{b}_{enc} 1_C^{\top} \quad \in \mathbb{R}^{D \times C}$$

  - $\mathrm{W}_{enc} \in \mathbb{R}^{PR \times D}$: ma trận trọng số có thể học; $\mathrm{b}_{enc} \in \mathbb{R}^{D}$: vector độ lệch.
- **So với DyTimeNet:** cùng dạng $\mathcal{X}_{enc} = \mathrm{W}_{enc}^{\top} \mathcal{X}' + \mathrm{b}_{enc}$, nhưng đầu vào là $P \cdot R$ hệ số cơ sở thay cho L điểm (ETTh1: 144 thay cho 720).

Chuẩn hóa LayerNorm và hàm kích hoạt GELU

- **LayerNorm**[12]: chuẩn hóa D đặc trưng của từng biến (cột $\mathrm{h} \in \mathbb{R}^D$), đưa mọi biến về cùng thang đo trước khi trộn:

$$\mathrm{LN}(\mathrm{h}) = \boldsymbol{\gamma} \odot \frac{\mathrm{h} - \mu_{\mathrm{h}}}{\sqrt{\sigma_{\mathrm{h}}^2 + \varepsilon}} + \boldsymbol{\beta}$$

  - $\mu_{\mathrm{h}}, \sigma_{\mathrm{h}}^2$: trung bình, phương sai các phần tử của h; $\boldsymbol{\gamma}, \boldsymbol{\beta} \in \mathbb{R}^D$ học được.
- **Hàm kích hoạt GELU**[13]:

$$\mathrm{GELU}(x) = x \cdot \Phi(x) = \frac{x}{2}\left(1 + \mathrm{erf}\left(\frac{x}{\sqrt{2}}\right)\right)$$

  - $\Phi(x)$: Hàm phân phối tích lũy của $\mathcal{N}(0,1)$; $\mathrm{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2}\, dt$.

[12] Ba, Kiros, and Hinton (2016): "Layer Normalization".

[13] Hendrycks and Gimpel (2016): "Gaussian Error Linear Units (GELUs)".

5. Khối Liên biến (CrossVBlock)

- **Chuẩn hóa:**

$$\mathcal{X}'_{enc} = \mathrm{LN}(\mathcal{X}_{enc}) \quad \in \mathbb{R}^{D\times C}$$

- **MLP nút thắt trên trục biến** $C \to C' \to C$ (khi kiểm thử), với $\mathrm{W}_{df,1} \in \mathbb{R}^{C\times C'}$, $\mathrm{W}_{df,2} \in \mathbb{R}^{C'\times C}$:

$$\mathrm{H} = \mathrm{GELU}\left(\mathcal{X}'_{enc}\,\mathrm{W}_{df,1} + 1_D \mathrm{b}_1^\top\right) \qquad \in \mathbb{R}^{D\times C'}$$

$$\mathcal{X}_{cross} = \mathrm{H}\,\mathrm{W}_{df,2} + 1_D \mathrm{b}_2^\top \qquad \in \mathbb{R}^{D\times C}$$

- **Vì sao là trộn liên biến:** mỗi *hàng* của $\mathcal{X}'_{enc}$ là một đặc trưng của cả C biến. Nhân phải với W_{df} tạo mỗi biến mới bằng tổ hợp của mọi biến trên từng đặc trưng.
- Khi huấn luyện, hai lớp tuyến tính này được thay bằng lớp **DropFusion**[14].

[14] Chen et al. (2026): "DyTimeNet: Dynamic cross-variable dependency network with sparse strategy for multivariate time series forecasting".

5a. DropFusion: Mặt nạ Cạnh $\mathcal{M}_1$ và Mặt nạ Nút $\mathcal{M}_2$

Để loại bỏ các tương quan rác mang tính ngẫu nhiên, mỗi lớp tuyến tính trên trục biến (đầu vào $\mathrm{Z} \in \mathbb{R}^{D \times C_{in}}$) được can thiệp bởi DropFusion khi huấn luyện:

- **Giai đoạn 1 – Mặt nạ Cạnh $\mathcal{M}_1 \in \{0,1\}^{C_{in} \times C_{out}}$:** mỗi phần tử bằng 0 với xác suất p_1, tức tắt liên kết giữa một cặp biến. Lấy mẫu lại ở mỗi lô.

$$\mathrm{W}_{masked} = \mathrm{W}_{df} \odot \mathcal{M}_1$$

- **Giai đoạn 2 – Mặt nạ Nút $\mathcal{M}_2 \in \{0,1\}^{D \times C_{out}}$:** mỗi phần tử bằng 0 với xác suất p_2, tức tắt đầu ra của một số biến. Lấy mẫu lại ở mỗi mẫu.

$$\mathrm{Y}_{masked} = \left(\mathrm{Z}\,\mathrm{W}_{masked} + 1_D \mathrm{b}^\top\right) \odot \mathcal{M}_2$$

5b. DropFusion: Chuẩn hóa kỳ vọng

- **Vấn đề năng lượng tín hiệu:** khi huấn luyện, một phần kết nối bị tắt (p_1, p_2); khi kiểm thử mạng mở lại 100% kết nối nên tổng tín hiệu tăng vọt, gây sai lệch.
- **Giải pháp:** nhân hệ số bù để kỳ vọng tín hiệu không đổi giữa hai giai đoạn.

Công thức DropFusion hoàn chỉnh (khi huấn luyện)

$$\mathrm{DF}(\mathrm{Z}) = \frac{1}{1-p_2}\left[\frac{\mathrm{Z}\,(\mathrm{W}_{df} \odot \mathcal{M}_1)}{1-p_1} + 1_D \mathrm{b}^\top\right] \odot \mathcal{M}_2$$

- **Khi kiểm thử:** $\mathcal{M}_1 = \mathcal{M}_2 = 1$, không nhân hệ số bù: $\mathrm{DF}(\mathrm{Z}) = \mathrm{Z}\,\mathrm{W}_{df} + 1_D \mathrm{b}^\top$.

6. Khối Nội biến (IntraVBlock)

- **Kết nối thặng dư:** cộng đặc trưng chéo với đặc trưng đã chuẩn hóa để giữ thông tin gốc của từng biến:

$$\mathcal{X}_{intra} = \mathcal{X}_{cross} + \mathcal{X}'_{enc} \qquad \in \mathbb{R}^{D \times C}$$

- **Mạng truyền thẳng dùng chung**, áp dụng cho *từng cột* (từng biến) $\mathrm{h} \in \mathbb{R}^{D}$:

$$\mathrm{FFN}(\mathrm{h}) = \mathrm{W}_2\,\mathrm{GELU}(\mathrm{W}_1\mathrm{h}+\mathrm{b}_1)+\mathrm{b}_2, \qquad \mathrm{W}_1 \in \mathbb{R}^{D_{ff} \times D},\ \mathrm{W}_2 \in \mathbb{R}^{D \times D_{ff}}$$

- **Đầu ra** (LayerNorm phía trước, thặng dư phía sau):

$$\hat{\mathcal{X}}_{intra} = \mathcal{X}_{intra} + \mathrm{FFN}\big(\,\mathrm{LN}(\mathcal{X}_{intra})\big) \qquad \in \mathbb{R}^{D \times C}$$

- FFN không trộn các biến; nó biến đổi phi tuyến D đặc trưng bên trong mỗi biến.

7. Chiếu ngược và Hiệu chỉnh thành phần cơ sở

- **Chiếu ngược** về không gian cơ sở:

$$\Delta \bar{\mathrm{E}} = \mathrm{W}_{out}^{\top}\, \hat{\mathcal{X}}_{intra} + \mathrm{b}_{out} 1_{C}^{\top} \quad \in \mathbb{R}^{PR \times C}, \qquad \mathrm{W}_{out} \in \mathbb{R}^{D \times PR}$$

- Cột i được xếp lại thành $\Delta \mathrm{E}^{(i)} \in \mathbb{R}^{P \times R}$ và **cộng vào cơ sở**:

$$\mathrm{E}'^{(i)} = \mathrm{E}^{(i)} + \Delta \mathrm{E}^{(i)}$$

- **Khởi tạo bằng 0:** $\mathrm{W}_{out} = 0$, $\mathrm{b}_{out} = 0$ nên lúc bắt đầu huấn luyện $\Delta \mathrm{E}^{(i)} = 0$ và DyBAS-Net trùng với TimeBase.
- **Ý nghĩa:** nhánh trộn kênh chỉ học *phần hiệu chỉnh*: dùng thông tin của các biến khác để sửa các "ngày điển hình" của biến i.

8. Dự báo theo đoạn và Khôi phục thang đo

- **Dự báo theo đoạn:** ánh xạ tuyến tính dùng chung sinh N' đoạn tương lai từ R cơ sở đã hiệu chỉnh:

$$\hat{\mathrm{Y}}^{(i)} = \mathrm{E}'^{(i)}\,\mathrm{W}_F + 1_P\,\mathrm{b}_F^{\top} \quad \in \mathbb{R}^{P\times N'}, \qquad \mathrm{W}_F \in \mathbb{R}^{R\times N'}$$

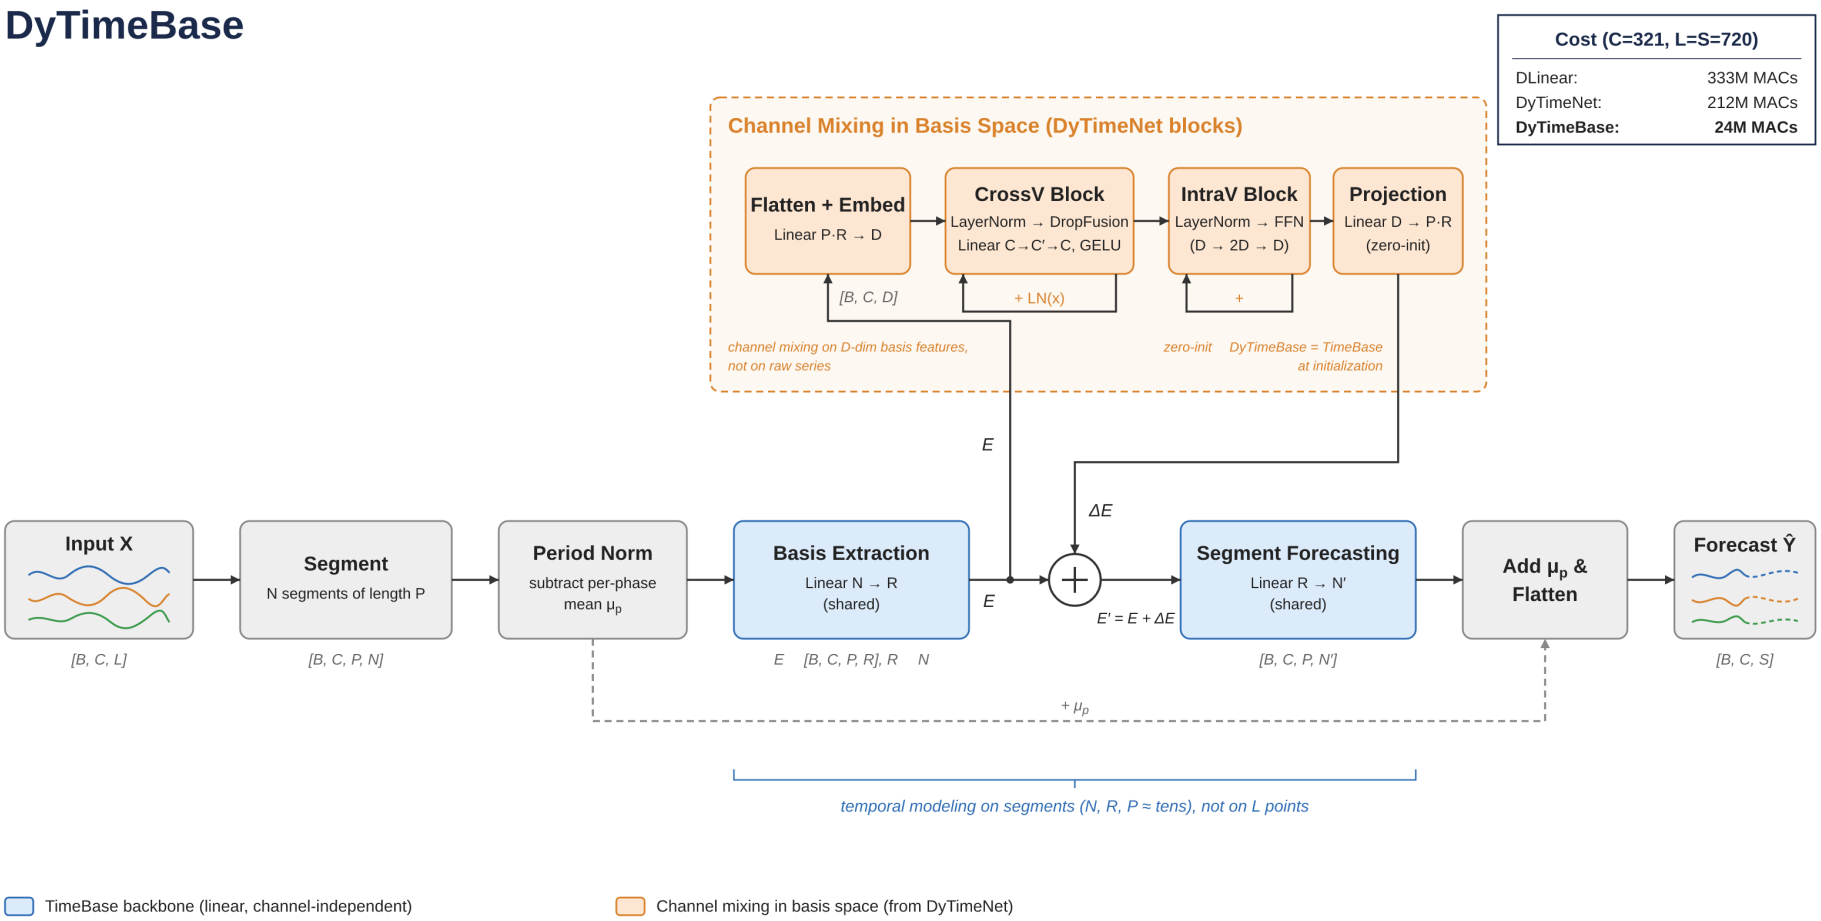
- **Khôi phục thang đo:** cộng trả trung bình theo pha cho mọi đoạn tương lai:

$$\hat{\mathrm{Y}}'^{(i)} = \hat{\mathrm{Y}}^{(i)} + \boldsymbol{\mu}^{(i)} 1_{N'}^{\top}$$

- **Ghép đoạn:** nối các cột thành chuỗi và giữ S bước đầu:

$$\hat{x}_{L+t}^{(i)} = \left[\hat{\mathrm{Y}}'^{(i)}\right]_{p,n}, \quad t = (n-1)P + p, \quad t = \overline{1, S}$$

9. Overview Pipeline



Khối xanh: xương sống TimeBase (tuyến tính, độc lập kênh). Khối cam: nhánh trộn kênh trong không gian cơ sở (khối của DyTimeNet). Trong mã nguồn, mô hình có tên DyTimeBase.

Điều chỉnh và Tối ưu hóa Trọng số

- Trọng số được cập nhật ngược hướng gradient của hàm mục tiêu $\mathcal{L}$ (bộ tối ưu Adam[15]):

$$W_{k+1} = W_k - \alpha \frac{\partial \mathcal{L}}{\partial W_k}, \qquad b_{k+1} = b_k - \alpha \frac{\partial \mathcal{L}}{\partial b_k}$$

- **Hai tốc độ học:** $\alpha = \alpha_B$ cho xương sống (W_B, b_B, W_F, b_F), $\alpha = \alpha_M$ cho nhánh trộn kênh.
- **Lịch tốc độ học** theo epoch e: giữ nguyên 4 epoch đầu, sau đó nhân 0.8 mỗi epoch: $\alpha^{(e)} = \alpha$ nếu $e \leq 4$, $\alpha^{(e)} = \alpha \cdot 0.8^{\,e-4}$ nếu $e > 4$.
- Tối đa 30 epoch; dừng sớm nếu MSE trên tập Validation không giảm sau 5 epoch.

[15] Kingma and Ba (2014): "Adam: A Method for Stochastic Optimization".

Vì sao DyBAS-Net nhẹ: Độ phức tạp tính toán

Số phép nhân–cộng (MACs) cho một mẫu:

- **Xương sống** (trích xuất cơ sở, dự báo theo đoạn):
  $\text{MACs}_B = C \cdot P \cdot R \cdot (N + N')$
- **Nhánh trộn kênh:**

$$\text{MACs}_M = \underbrace{2\,C\,PR\,D}_{\text{mã hóa, chiếu ngược}} + \underbrace{2\,D\,C\,C'}_{\text{CrossVBlock}} + \underbrace{2\,C\,D\,D_{ff}}_{\text{IntraVBlock}}$$

- Không có số hạng nào tỉ lệ với $L \cdot S$; nhánh trộn kênh không phụ thuộc L và S.

Ví dụ Electricity: $C = 321$, $L = S = 720$, $P = 24$, $R = 6$, $D = 64$

$\text{MACs}_B \approx 2.8\text{M}$, $\text{MACs}_M \approx 21.0\text{M}$, tổng $\approx 23.8\text{M}$.
So sánh: DLinear $2CLS \approx 333\text{M}$; DyTimeNet $\approx 212\text{M}$.

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
   - Nghiên cứu loại bỏ
4. Kết luận
5. Tài liệu tham khảo

Mô tả dữ liệu thực nghiệm

Dataset	Số biến C	Tần suất	Số bước dùng	Chia Train/Val/Test	Số cửa sổ ($L = 720$, $S = 96$)
ETTh1, ETTh2	7	1 giờ	14 400	12/4/4 tháng	7 825 / 2 785 / 2 785
ETTm1, ETTm2	7	15 phút	57 600	12/4/4 tháng	33 745 / 11 425 / 11 425
Weather	21	10 phút	52 696	7 : 1 : 2	36 072 / 5 174 / 10 445

- **ETT**: nhiệt độ dầu và 6 chỉ số phụ tải của máy biến áp điện.
- **Weather**: 21 chỉ số khí tượng (nhiệt độ, độ ẩm, áp suất, gió. . .), có quan hệ vật lý giữa các biến.
- **Tiền xử lý:** chuẩn hóa Z-score theo từng biến (chỉ tính trên tập train); cửa sổ trượt $L = 720$, $S \in \{96, 192, 336, 720\}$; đánh giá trên *mọi* cửa sổ của tập test.

Thiết lập huấn luyện

- **Xương sống:** P, R, α_B, kích thước lô, λ_{orth} theo script chính thức của TimeBase[16] cho từng bộ dữ liệu và từng S.
- **Nhánh trộn kênh:** giữ nguyên D, p_1, p_2 đã tối ưu bằng Grid Search cho DyTimeNet trong Đồ án I; $\alpha_M = 5 \cdot 10^{-4}$. *Không tinh chỉnh thêm* cho DyBAS-Net.
- Mỗi cấu hình chạy 3 seed (2021, 2022, 2023); báo cáo trung bình.
- **Thiết bị:** máy tính xách tay không GPU, CPU AMD Ryzen 7 7840HS (8 nhân), 16 GB RAM, PyTorch 2.6 (CPU).

[16] Huang et al. (2025): "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting".

Siêu tham số của DyBAS-Net

	Xương sống (theo $S = 96/192/336/720$)			Nhánh trộn kênh		
Dataset	P	R	Riêng kênh	D	p_1	p_2
ETTh1	24/24/24/24	6/6/6/6	không	64	0.1	0.1
ETTh2	24/24/24/24	6/4/6/6	không	64	0.6	0.6
ETTm1	4/4/4/6	18/20/20/20	không	64	0.1	0.2
ETTm2	4/4/4/6	20/20/20/20	không	32	0.1	0.1
Weather	4/4/4/4	6/6/6/6	có	64	0.1	0.1

- P, R (và tốc độ học, kích thước lô, λ_{orth}) đổi theo S, đúng như script chính thức của TimeBase.
- "Riêng kênh": Weather dùng W_B, W_F riêng cho từng biến (số MACs không đổi).
- D, p_1, p_2: lấy nguyên từ Bảng 3.1 của Đồ án I; $C' = \lfloor 0.75\, C \rfloor$, $D_{ff} = 2D$, Dropout 0.1.

Các mô hình so sánh

- **TimeBase***: TimeBase cài đặt lại theo mã nguồn chính thức (đầu ra lệch $< 3 \cdot 10^{-7}$ so với bản gốc khi cùng trọng số), chạy *cùng quy trình* với DyBAS-Net. Hai mô hình chỉ khác nhau ở nhánh trộn kênh.
- **Số liệu công bố** ($L = 720$, Table 10 của TimeBase [1]):
  - Tuyến tính nhẹ: TimeBase†, SparseTSF [9], FITS [10], DLinear [11].
  - MLP, Transformer, CNN: TimeMixer [12], iTransformer [13], PatchTST [14], TimesNet [15], FEDformer [16], Autoformer [17], Informer [18].
- Các mô hình lớn không được huấn luyện lại vì chi phí trên CPU quá cao (một epoch của PatchTST ở cấu hình Electricity mất khoảng 23 giờ).

Chỉ số đánh giá

- **Độ chính xác:** MSE và MAE trên thang Z-score, lấy trung bình trên mọi cửa sổ test, mọi bước, mọi biến:

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2, \qquad \mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

- **Hiệu năng** (theo TimeBase), cấu hình Electricity ($C = 321$, $L = S = 720$):
  - **Params**: số tham số; **MACs**: số phép nhân–cộng cho một mẫu.
  - **Max Mem**: bộ nhớ đỉnh khi huấn luyện, lô 12 mẫu (RAM, vì không có GPU).
  - **Epoch Time**: thời gian một epoch huấn luyện; **Infer Time**: dự báo một mẫu trên CPU.
- Đo *tất cả mô hình trên cùng máy*, dựng từ mã nguồn chính thức (Time-Series-Library [19], kho mã của PatchTST và FITS).

Kết quả: MSE / MAE trung bình trên 4 độ dài dự báo

Mô hình	ETTh1		ETTh2		ETTm1		ETTm2		Weather	
	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
DyBAS-Net	0.403	0.421	0.358	0.406	**0.351**	0.386	0.263	0.330	0.221	0.277
TimeBase*	0.411	0.420	0.363	0.410	0.367	0.391	0.254	0.317	**0.219**	0.265
TimeBase†	**0.396**	**0.414**	0.347	0.397	0.356	**0.381**	**0.251**	**0.314**	**0.219**	**0.263**
SparseTSF	0.407	0.419	0.344	0.387	0.362	0.384	0.253	0.317	0.244	0.285
TimeMixer	0.454	0.474	0.379	0.426	0.381	0.414	0.283	0.347	0.238	0.281
FITS	0.417	0.430	**0.334**	**0.382**	0.359	0.382	0.252	**0.314**	0.244	0.286
iTransformer	0.454	0.467	0.392	0.422	0.370	0.401	0.278	0.338	0.233	0.273
DLinear	0.437	0.448	0.479	0.471	0.361	0.383	0.271	0.337	0.242	0.299
PatchTST	0.420	0.440	0.344	0.391	0.355	0.385	**0.251**	0.319	0.224	0.264
TimesNet	0.505	0.499	0.433	0.455	0.408	0.425	0.299	0.353	0.254	0.293
FEDformer	0.523	0.523	0.429	0.470	0.439	0.466	0.409	0.462	0.355	0.391
Autoformer	0.727	0.641	1.086	0.801	0.564	0.522	0.431	0.463	0.446	0.457
Informer	1.445	0.929	5.486	1.891	1.138	0.818	3.594	1.473	0.567	0.513

* tự chạy, trung bình 3 seed. † số công bố của TimeBase (chạy 1 lần). Các mô hình dưới vạch kẻ: số công bố trong [1], cùng $L = 720$; trung bình tính từ kết quả theo từng S (Table 10).
Đậm: tốt nhất; gạch chân: thứ hai.

Nhận xét kết quả độ chính xác

- **ETTm1:** DyBAS-Net có MSE **thấp nhất trong cả 13 mô hình** (0.351), tốt hơn PatchTST (0.355) và TimeBase† (0.356).
- **ETTh1, Weather:** DyBAS-Net đứng **thứ hai** về MSE (0.403 và 0.221), chỉ sau TimeBase; tốt hơn PatchTST, SparseTSF, FITS và mọi mô hình Transformer.
- **ETTh2, ETTm2:** DyBAS-Net (0.358 và 0.263) kém nhóm tuyến tính mạnh (FITS, SparseTSF, TimeBase) và PatchTST.
- **MAE:** cải thiện ít hơn MSE; trên phần lớn bộ dữ liệu, MAE của DyBAS-Net không tốt hơn TimeBase.

Kết quả theo độ dài dự báo S (MSE): ETTh1, ETTh2

Dataset	S	**DyBAS-Net**	TimeBase*	TimeBase†	SparseTSF	FITS	PatchTST	iTransformer	DLinear	TimeMixer
ETTh1	96	**0.347**	0.358	0.349	0.362	0.380	0.377	0.389	0.378	0.410
	192	0.388	0.396	**0.387**	0.404	0.415	0.413	0.424	0.415	0.448
	336	0.420	0.423	**0.408**	0.435	0.439	0.436	0.456	0.449	0.482
	720	0.456	0.466	0.439	**0.426**	0.433	0.455	0.545	0.507	0.475
ETTh2	96	0.286	0.295	0.292	0.294	**0.271**	0.276	0.305	0.294	0.315
	192	0.347	0.352	0.339	0.340	**0.332**	0.342	0.405	0.412	0.383
	336	0.378	0.390	0.358	0.360	**0.355**	0.364	0.411	0.471	0.385
	720	0.421	0.413	0.400	0.383	**0.378**	0.395	0.448	0.740	0.432

Hạng (**đậm**, gạch chân) tính trên cả 13 mô hình. Không hiển thị TimesNet, FEDformer, Autoformer, Informer (DyBAS-Net tốt hơn ở mọi ô).

Kết quả theo độ dài dự báo S (MSE): ETTm1, ETTm2

Dataset	S	**DyBAS-Net**	TimeBase*	TimeBase†	SparseTSF	FITS	PatchTST	iTransformer	DLinear	TimeMixer
ETTm1	96	**0.296**	0.318	0.311	0.314	0.313	0.298	0.315	0.314	0.332
	192	**0.328**	0.363	0.338	0.348	0.339	0.335	0.349	0.347	0.355
	336	**0.364**	0.372	**0.364**	0.368	0.367	0.366	0.381	0.367	0.386
	720	0.416	0.418	**0.413**	0.419	0.417	0.420	0.437	0.415	0.452
ETTm2	96	0.167	0.166	**0.162**	0.167	0.166	0.165	0.179	0.163	0.192
	192	0.237	**0.218**	**0.218**	0.219	**0.218**	0.219	0.239	0.223	0.253
	336	0.284	0.277	0.270	0.271	0.271	**0.268**	0.309	0.291	0.307
	720	0.366	0.355	**0.352**	0.353	**0.352**	**0.352**	0.387	0.407	0.380

Hạng (**đậm**, gạch chân) tính trên cả 13 mô hình.

Kết quả theo độ dài dự báo S (MSE): Weather

Dataset	S	**DyBAS-Net**	TimeBase*	TimeBase†	SparseTSF	FITS	PatchTST	iTransformer	DLinear	TimeMixer
Weather	96	**0.143**	0.144	0.146	0.174	0.176	0.149	0.159	0.174	0.163
	192	0.187	0.187	**0.185**	0.216	0.216	0.193	0.203	0.215	0.201
	336	0.240	0.238	**0.236**	0.260	0.261	0.240	0.253	0.262	0.258
	720	0.314	**0.309**	**0.309**	0.325	0.325	0.312	0.317	0.319	0.329

- Weather có nhiều biến nhất (21) và quan hệ vật lý giữa các biến rõ nhất.
- DyBAS-Net tốt nhất ở $S = 96$ (0.143); ở $S = 192$ ngang TimeBase* (0.187); ở $S = 336$ và $S = 720$ kém TimeBase một chút.

DyBAS-Net đối đầu từng mô hình

Đối thủ	Thắng	Hòa	Thua	DyBAS-Net tốt hơn (MSE TB)	DyBAS-Net kém hơn (MSE TB)
TimeBase*	12	1	7	ETTh1, ETTh2, ETTm1	ETTm2, Weather
TimeBase†	5	1	14	ETTm1	ETTh1, ETTh2, ETTm2, Weather
SparseTSF	12	1	7	ETTh1, ETTm1, Weather	ETTh2, ETTm2
TimeMixer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
FITS	11	0	9	ETTh1, ETTm1, Weather	ETTh2, ETTm2
iTransformer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
DLinear	17	0	3	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
PatchTST	9	1	10	ETTh1, ETTm1, Weather	ETTh2, ETTm2
TimesNet	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
FEDformer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
Autoformer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–
Informer	20	0	0	ETTh1, ETTh2, ETTm1, ETTm2, Weather	–

Đếm trên 20 ô (5 bộ dữ liệu $\times$ 4 độ dài dự báo) theo MSE, làm tròn 3 chữ số.

- **Hơn hẳn:** TimeMixer, iTransformer, TimesNet, FEDformer, Autoformer, Informer (20/20) và DLinear (17/20).
- **Ngang ngửa:** SparseTSF, FITS, PatchTST (thắng trên ETTh1, ETTm1, Weather; thua trên ETTh2, ETTm2).
- **Kém hơn:** số công bố của TimeBase (thắng 5/20).

So sánh với TimeBase trong cùng quy trình

Thay đổi MSE của DyBAS-Net so với TimeBase* (âm là tốt hơn). Hai mô hình dùng cùng xương sống, cùng siêu tham số xương sống, cùng 3 seed, chỉ khác ở nhánh trộn kênh:

Dataset	$S = 96$	$S = 192$	$S = 336$	$S = 720$	Trung bình
ETTh1	-2.8%	-2.0%	-0.5%	-2.1%	-1.8%
ETTh2	-3.3%	-1.7%	-2.9%	$+1.9\%$	-1.3%
ETTm1	-6.8%	-9.6%	-2.0%	-0.5%	-4.5%
ETTm2	$+0.3\%$	$+8.6\%$	$+2.5\%$	$+3.2\%$	$+3.7\%$
Weather	-0.4%	$+0.1\%$	$+0.9\%$	$+1.6\%$	$+0.8\%$

- Nhánh trộn kênh **cải thiện 3/5 bộ dữ liệu**: ETTh1 (-1.8%), ETTh2 (-1.3%), ETTm1 (-4.5%).
- Cải thiện lớn nhất ở dự báo ngắn: ETTm1 với $S = 192$ giảm 9.6%.
- **ETTm2** kém hơn ($+3.7\%$): các lần chạy thường dừng sau 6–7 epoch, nhánh phi tuyến quá khớp trên chuỗi tương đối trơn.

Hiệu năng tính toán trên cùng một thiết bị

Electricity ($C = 321$), $L = S = 720$. Max Mem: đỉnh RAM khi huấn luyện, lô 12 mẫu. Epoch Time: thời gian một bước huấn luyện (lô 12) $\times$ 1 414 bước. Infer Time: dự báo 1 mẫu, 8 luồng. Sắp xếp theo Infer Time.

Mô hình	Params	MACs	Max Mem (MB)	Epoch Time (s)	Infer Time (ms)	So với DyBAS-Net
TimeBase	0.40K	2.77M	117	20	0.34	0.52×
DyBAS-Net	190.51K	23.81M	147	38	0.66	1.00×
SparseTSF	0.93K	12.71M	276	56	0.76	1.15×
FITS	133.64K	42.73M	210	78	1.70	2.59×
DLinear	1.04M	332.81M	150	55	1.93	2.94×
DyTimeNet	785.14K	211.80M	285	131	2.14	3.25×
iTransformer	5.47M	2.10G	997	695	10.66	16.23×
Informer	12.45M	7.91G	2 052	2 926	66.16	100.66×
Autoformer	12.14M	8.97G	5 057	5 302	83.39	126.88×
FEDformer	18.44M	8.99G	3 289	5 367	135.93	206.81×
TimeMixer	5.58M	29.97G	>11 264‡	16 716	247.46	376.51×
PatchTST	8.69M	16.08G	10 346	82 400	285.51	434.40×
TimesNet	151.32M	1081.75G	4 078	170 983	3 449.01	5 247.64×

‡ Vượt ngưỡng 11 GB RAM ở lô 12; Epoch Time của mô hình này đo ở lô 4.

Nhận xét hiệu năng

- DyBAS-Net **nhanh thứ hai trong 13 mô hình** khi suy luận (0.66 ms một mẫu), chỉ sau TimeBase (0.34 ms).
- Nhanh hơn SparseTSF (0.76 ms), FITS (1.70 ms), DLinear (1.93 ms).
- So với Transformer: nhanh hơn iTransformer $\sim$16 lần, TimeMixer $\sim$377 lần, PatchTST $\sim$434 lần.
- Huấn luyện nhẹ: 38 s một epoch, 147 MB bộ nhớ (PatchTST: hơn 10 GB, khoảng 23 giờ một epoch).
- So với DyTimeNet (Đồ án I): ít hơn $\sim$4.1 lần tham số, $\sim$8.9 lần MACs, suy luận nhanh hơn $\sim$3.2 lần.

Nguyên nhân

Biến đổi theo trục thời gian chạy trên N, R, P (vài chục) thay vì L, S (hàng trăm); không có attention.

Nghiên cứu loại bỏ (Ablation study)

MSE trung bình trên 4 độ dài dự báo và 3 seed; mỗi biến thể chỉ bỏ một khối, giữ nguyên mọi siêu tham số khác.

Biến thể	ETTh1	ETTh2	ETTm1	ETTm2	Weather	Trung bình
DyBAS-Net (đầy đủ)	0.4030	0.3580	**0.3509**	0.2634	0.2211	0.3193
bỏ CrossVBlock	0.4028	0.3595	0.3554	0.2615	0.2226	0.3204
bỏ IntraVBlock	0.4004	0.3668	0.3524	0.2661	**0.2186**	0.3209
bỏ cả nhánh (= TimeBase*)	0.4105	0.3627	0.3674	**0.2539**	0.2195	0.3228
đầy đủ, $\alpha_M = 2 \cdot 10^{-3}$	**0.3992**	**0.3569**	0.3554	0.2627	0.2203	**0.3189**

Các biến thể "bỏ khối" chỉ dùng để kiểm chứng; mô hình đề xuất là DyBAS-Net đầy đủ.

Nhận xét nghiên cứu loại bỏ

- Tính trung bình, **bản đầy đủ tốt hơn mọi bản đã bỏ khối**: bỏ CrossVBlock (0.3204), bỏ IntraVBlock (0.3209), bỏ cả nhánh (0.3228) so với 0.3193.
- **Weather** (21 biến): bỏ CrossVBlock cho kết quả kém nhất (0.2226); chỉ giữ CrossVBlock cho kết quả tốt nhất (0.2186), tốt hơn TimeBase*. Trộn kênh có ích hơn khi có nhiều biến.
- Tăng α_M lên $2 \cdot 10^{-3}$ gần như không đổi (0.3189), nên giữ cấu hình của Đồ án I.

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
   - Nghiên cứu loại bỏ
4. Kết luận
5. Tài liệu tham khảo

Kết luận

- **Đề xuất DyBAS-Net:** kết hợp dự báo theo đoạn dựa trên thành phần cơ sở (TimeBase) với học phụ thuộc chéo có điều chuẩn thưa (CrossVBlock, DropFusion, IntraVBlock của DyTimeNet), đặt trong *không gian cơ sở*.
- **Rất nhẹ:** 23.8M MACs, 0.66 ms một mẫu trên CPU ở cấu hình Electricity; nhanh thứ hai trong 13 mô hình, nhanh hơn các mô hình Transformer từ 16 đến hàng nghìn lần.
- **Chính xác cạnh tranh:** tốt nhất trên ETTm1, thứ hai trên ETTh1 và Weather; vượt toàn bộ mô hình Transformer và DLinear; ngang ngửa SparseTSF, FITS, PatchTST.
- **Nhánh trộn kênh có ích:** so với TimeBase cùng quy trình, giảm MSE trên 3/5 bộ dữ liệu (tới 4.5% trên ETTm1); ablation cho thấy cả CrossVBlock và IntraVBlock đều đóng góp.

Hạn chế

- **Chưa vượt số công bố của TimeBase** về độ chính xác; kém các mô hình tuyến tính mạnh trên ETTh2, ETTm2.
- **Quá khớp trên dữ liệu trơn:** trên ETTm2, nhánh phi tuyến làm MSE tăng 3.7% so với TimeBase.
- **Mức cải thiện nhỏ:** các chênh lệch trong ablation (0.3–1.1%) cùng cỡ độ lệch chuẩn giữa các seed.
- **Chậm hơn TimeBase** khoảng 2 lần, cái giá của nhánh trộn kênh.
- **Phạm vi đánh giá:** số liệu của 10 mô hình lớn là số trích dẫn; hiệu năng đo trên CPU (Max Mem là RAM, Epoch Time của mô hình lớn là ước tính từ một bước huấn luyện).

Mục lục

1. Tổng quan vấn đề nghiên cứu và mục đích nghiên cứu
   - Tổng quan vấn đề nghiên cứu
   - Mục đích nghiên cứu
2. Phương pháp luận
   - Mô hình hóa toán học
   - Xây dựng mô hình
3. Thực nghiệm và kết quả
   - Thiết lập thực nghiệm
   - Kết quả độ chính xác
   - Kết quả hiệu năng
   - Nghiên cứu loại bỏ
4. Kết luận
5. Tài liệu tham khảo

Tài liệu tham khảo I

[1] Qihe Huang et al. "TimeBase: The Power of Minimalism in Efficient Long-term Time Series Forecasting". In: *Proceedings of the 42nd International Conference on Machine Learning*. Vol. 267. Proceedings of Machine Learning Research. 2025, pp. 26227–26246.

[2] Lu Han, Han-Jia Ye, and De-Chuan Zhan. "The Capacity and Robustness Trade-off: Revisiting the Channel Independent Strategy for Multivariate Time Series Forecasting". In: *IEEE Transactions on Knowledge and Data Engineering* (2024), pp. 7129–7142.

[3] Yifan Hu et al. "TimeFilter: Patch-Specific Spatial-Temporal Graph Filtration for Time Series Forecasting". In: *Proceedings of the 42nd International Conference on Machine Learning*. Vol. 267. Proceedings of Machine Learning Research. 2025.

[4] Ting Chen et al. "DyTimeNet: Dynamic cross-variable dependency network with sparse strategy for multivariate time series forecasting". In: *Neurocomputing* 676 (2026), p. 132964. ISSN: 0925-2312. DOI: 10.1016/j.neucom.2026.132964.

[5] Taesung Kim et al. "Reversible Instance Normalization for Accurate Time-Series Forecasting against Distribution Shift". In: *International Conference on Learning Representations*. 2022.

[6] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. "Layer Normalization". In: *arXiv preprint arXiv:1607.06450* (2016).

[7] Dan Hendrycks and Kevin Gimpel. "Gaussian Error Linear Units (GELUs)". In: *arXiv preprint arXiv:1606.08415* (2016).

[8] Diederik P. Kingma and Jimmy Ba. "Adam: A Method for Stochastic Optimization". In: *arXiv preprint arXiv:1412.6980* (2014).

[9] Shengsheng Lin et al. "SparseTSF: Modeling Long-term Time Series Forecasting with 1k Parameters". In: *Proceedings of the 41st International Conference on Machine Learning*. 2024.

[10] Zhijian Xu, Ailing Zeng, and Qiang Xu. "FITS: Modeling Time Series with 10k Parameters". In: *The Twelfth International Conference on Learning Representations*. 2024.

Tài liệu tham khảo II

[11] Ailing Zeng et al. "Are Transformers Effective for Time Series Forecasting?". In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 37. 9. 2023, pp. 11121–11128. DOI: 10.1609/aaai.v37i9.26317.

[12] Shiyu Wang et al. "TimeMixer: Decomposable Multiscale Mixing for Time Series Forecasting". In: *The Twelfth International Conference on Learning Representations*. 2024.

[13] Yong Liu et al. "iTransformer: Inverted Transformers Are Effective for Time Series Forecasting". In: *The Twelfth International Conference on Learning Representations*. 2024.

[14] Yuqi Nie et al. "A Time Series is Worth 64 Words: Long-term Forecasting with Transformers". In: *The Eleventh International Conference on Learning Representations*. 2023.

[15] Haixu Wu et al. "TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis". In: *The Eleventh International Conference on Learning Representations*. 2023.

[16] Tian Zhou et al. "FEDformer: Frequency Enhanced Decomposed Transformer for Long-term Series Forecasting". In: *Proceedings of the 39th International Conference on Machine Learning*. 2022, pp. 27268–27286.

[17] Haixu Wu et al. "Autoformer: Decomposition Transformers with Auto-Correlation for Long-term Series Forecasting". In: *Advances in Neural Information Processing Systems*. Vol. 34. 2021, pp. 22419–22430.

[18] Haoyi Zhou et al. "Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting". In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 35. 2021, pp. 11106–11115.

[19] Yuxuan Wang et al. "Deep Time Series Models: A Comprehensive Survey and Benchmark". In: *arXiv preprint arXiv:2407.13278* (2024).